CEFET/RJ
DIRETORIA DE PESQUISA E PÓS-GRADUAÇÃO

DA ANOTAÇÃO AO MODELO: DIVERGÊNCIAS ANOTATIVAS DE GÊNERO AMPLIFICADAS POR CLASSIFICADORES SUPERVISIONADOS DE SENTIMENTOS EM PORTUGUÊS BRASILEIRO

Alexander Ramos Feitosa

Proposta de Dissertação de Mestrado apresentada ao Programa de Pós-graduação em Ciência da Computação, Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ, como parte dos requisitos necessários à obtenção do grau de mestre.

Orientador:
Gustavo Guedes Paiva e Silva

Rio de Janeiro,

Outubro de 2026

Da Anotação ao Modelo: Divergências Anotativas de Gênero Amplificadas por Classificadores Supervisionados de Sentimentos em Português Brasileiro

Proposta de Dissertação de Mestrado em Ciência da Computação, Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, CEFET/RJ.

Alexander Ramos Feitosa

Aprovada por:

Presidente, Prof. D.Sc. Gustavo Guedes Paiva e Silva (orientador)

Rio de Janeiro,

Outubro de 2026

RESUMO

Da Anotação ao Modelo: Divergências Anotativas de Gênero Amplificadas por Classificadores Supervisionados de Sentimentos em Português Brasileiro

Alexander Ramos Feitosa

Orientador:
Gustavo Guedes Paiva e Silva

Resumo da proposta de Dissertação submetida ao Programa de Pós-graduação em Ciência da Computação do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ como parte dos requisitos necessários à obtenção do grau de mestre.

A etapa de anotação colaborativa em tarefas de Processamento de Linguagem Natural (PLN) é moldada pelas características sociodemográficas dos anotadores. Diante de uma pluralidade de características, o gênero se apresenta como um fator de notável diferença. Este trabalho explora se classificadores de Análise de Sentimentos (AS), quando treinados sobre rótulos que incorporam divergências sistemáticas de gênero, tendem a amplificar essas divergências em suas predições. Em resposta a isso, a Metodologia de Análise de Divergências Anotativas (MADA) é introduzida, centrada no cálculo de $\Delta\kappa$, definido como a diferença entre o κ de Cohen entre os anotadores e anotadoras originais e o κ estimado entre os grupos de predições do modelo.

A MADA é avaliada empiricamente sobre o corpus MQD-1222 (N = 1.222), anotado por 46 colaboradores estratificados por gênero (26 do grupo masculino e 20 do feminino), com consolidação por maioria estrita de quatro votos por grupo e um nível de concordância inicial κ = 0,7664 (IC 95% [0,7348; 0,7958]), considerado substancial pela classificação de Landis and Koch [1977]. Os resultados indicam que os quatro classificadores clássicos avaliados produziram predições com menor concordância do que a observada entre as fontes anotadoras originais, com magnitude e severidade que variaram em função do tipo de classificador escolhido. A validação sintética, conduzida sobre doze conjuntos paramétricos com taxas de concordância controladas (SynSA-50 a SynSA-99, N = 999 cada), forneceu evidências adicionais de que o comportamento observado não se restringe ao corpus empírico, manifestando-se também sob diferentes taxas sintéticas de concordância entre fontes de supervisão.

A análise integrada, consolidada nas duas fases complementares da pesquisa, indica que a MADA constitui um instrumento operacional para a detecção e mensuração da amplificação de divergências anotativas no protocolo experimental avaliado.

Este estudo foi aprovado pelo Comitê de Ética em Pesquisa, sob o parecer CAAE nº 82267824.8.0000.5289.

Palavras-chave: análise de sentimentos; amplificação de divergências anotativas; κ de Cohen; MADA; processamento de linguagem natural.

Rio de Janeiro,

Outubro de 2026

ABSTRACT

From Annotation to Model: Gender-Based Annotation Divergences Amplified by Supervised Sentiment Classifiers in Brazilian Portuguese

Alexander Ramos Feitosa

Advisor:
Gustavo Guedes Paiva e Silva

Abstract of dissertation proposal submitted to Programa de Pós-graduação em Ciência da Computação - Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ as partial fulfillment of the requirements for the degree of master.

The collaborative annotation step in Natural Language Processing (NLP) tasks is shaped by the sociodemographic characteristics of the annotators. Among a plurality of characteristics, gender emerges as a factor of notable difference. This work explores whether Sentiment Analysis (SA) classifiers, when trained on labels that incorporate systematic gender-based divergences, tend to amplify these divergences in their predictions. In response to this, the Annotative Divergence Analysis Methodology (MADA) is introduced, centered on the calculation of $\Delta\kappa$, defined as the difference between Cohen's κ for the original male and female annotators and the estimated κ for the model's prediction groups.

MADA is empirically evaluated on the MQD-1222 corpus (N = 1,222), annotated by 46 collaborators stratified by gender (26 male and 20 female), with labels consolidated by strict majority vote over four votes per group and an initial agreement level of $\kappa = 0.7664$ (95% CI [0.7348; 0.7958]), which is considered substantial according to the classification by Landis and Koch [1977]. The results indicate that the four classical classifiers evaluated produced predictions with lower agreement than that observed between the original annotative sources, with the magnitude and severity of this reduction varying across classifiers. Synthetic validation, conducted on twelve parametric sets with controlled agreement rates (SynSA-50 to SynSA-99, N = 999 each), provided additional evidence that the observed behavior is not restricted to the empirical corpus, also appearing under different synthetic agreement rates between supervision sources.

The integrated analysis, consolidated across the two complementary phases of the research, indicates that MADA constitutes an operational instrument for detecting and measuring the amplification of annotative divergences within the evaluated experimental protocol.

This study was approved by the Research Ethics Committee under opinion CAAE No. 82267824.8.0000.5289.

Keywords: sentiment analysis; annotative divergence amplification; Cohen's κ; MADA; natural language processing.

Rio de Janeiro,

Outubro de 2026

Sumário

I Introdução **2**

I.1 Definição do problema 4

I.2 Contribuições 5

I.3 Organização do documento 7

II Fundamentação Teórica **9**

II.1 Análise de sentimentos e divergência anotativa 9

II.2 Mensuração da concordância e da associação 10

II.3 Viés em PLN 12

II.4 Amplificação de divergências no aprendizado supervisionado 13

II.5 Classificadores supervisionados avaliados 13

II.6 Validação cruzada e reamostragem 15

III Trabalhos relacionados **17**

III.1 Representação da divergência anotativa 18

III.2 Divergências demográficas 19

III.3 Análise de sentimentos 20

III.4 Amplificação de viés 21

III.5 Estudos em língua portuguesa 22

IV Apresentação dos conjuntos de dados **25**

IV.1 Corpus empírico: do MQD-1465 ao MQD-1222 25

IV.1.1 Coleta via PCIbex 26

IV.1.2 Consolidação majoritária 27

IV.2 Conjuntos de dados sintéticos (SynSA-XX) 31

IV.2.1 Construção dos vetores de rótulos 31

IV.2.2 Geração dos dados sintéticos 32

V Metodologia **34**

V.1 Visão geral da MADA 34

V.2 Módulo I: Concordância entre as fontes anotadoras 34
V.3 Módulo II: Treinamento pareado e concordância entre predições 36
V.3.1 Paridade entre treinamentos 36
V.3.2 Ajuste da representação e validação cruzada 36
V.4 Módulo III: Quantificação da amplificação 37
V.4.1 Definição de $\Delta\kappa$ 37
V.4.2 Deslocamento entre categorias como recurso descritivo auxiliar 38

VI Experimentos 39
VI.1 Configurações experimentais 39
VI.1.1 Variável estratificadora 41
VI.1.2 Instanciação empírica 41
VI.1.3 Instanciação sintética 41
VI.1.4 Representação textual 42
VI.1.5 Validação cruzada 42
VI.1.6 Classificadores avaliados 43
VI.1.7 Cálculo de κ_{pred} 43
VI.1.8 Significância estatística 43
VI.1.9 Estratégia de integração entre as instanciações 44
VI.2 Resultados empíricos 45
VI.2.1 Módulo I: Concordância entre as fontes anotadoras 45
VI.2.2 Módulo II: Treinamento pareado e concordância entre predições 47
VI.2.3 Módulo III: Quantificação da amplificação ($\Delta\kappa$) 49
VI.3 Resultados sintéticos 50
VI.3.1 Módulo I: Concordância entre as fontes anotadoras 51
VI.3.2 Módulo II: Treinamento pareado e concordância entre as predições 52
VI.3.3 Módulo III: Quantificação da amplificação ($\Delta\kappa$) 53
VI.4 Resultados integrados: evidência empírica e controle sintético 55
VI.4.1 Cenário empírico vs. cenário sintético 56
VI.4.2 Intervalos *bootstrap* da análise complementar 58
VI.4.3 Síntese interpretativa 59

VII Conclusões 61
VII.1 Síntese dos achados 62
VII.2 Limitações 62
VII.3 Contribuições 65

VII.4 Trabalhos futuros 66

A *Strings* de busca da revisão da literatura 69

A.1 *String* em português brasileiro 69

A.2 *String* em inglês 69

B *Pipeline* de processamento dos logs do PCIbex 71

B.1 Visão geral do pipeline 71

B.2 Etapa 1: extração dos *logs* brutos 71

B.3 Etapa 2: *parsing* e estruturação dos eventos 71

B.4 Etapa 3: segmentação por gênero autodeclarado 72

B.5 Etapa 4: consolidação por voto majoritário 72

B.6 Etapa 5: geração do *dataset* final 73

B.7 Reprodutibilidade 74

C Ambiente computacional e recursos de pré-processamento 75

C.1 Ambiente computacional 75

C.2 Stopwords utilizadas no TF-IDF 76

Referências 77

Lista de Figuras

III.1 Diagrama de fluxo PRISMA 2020 do processo de identificação, triagem, elegibilidade e inclusão dos estudos. 18

V.1 Diagrama de fluxo da MADA. O fluxo é organizado em três módulos sequenciais: o Módulo I estima a concordância entre as fontes anotadoras (κ_{anot}); o Módulo II realiza o treinamento pareado de dois modelos com rótulos provenientes de fontes distintas e estima a concordância entre suas predições (κ_{pred}); o Módulo III computa $\Delta\kappa = \kappa_{\text{anot}} - \kappa_{\text{pred}}$ e classifica o resultado. A amplificação é identificada quando o limite inferior do intervalo de confiança de $\Delta\kappa$ é positivo; um intervalo que inclui zero indica resultado inconclusivo quanto à direção da alteração, e um limite superior negativo, convergência induzida. 35

VI.1 Distribuição das classes por grupo de anotadores no conjunto de dados MQD-1222. O grupo feminino atribuiu proporcionalmente mais rótulos neutros (365 contra 291) e menos rótulos positivos (411 contra 481), sugerindo maior concentração relativa em rótulos de polaridade atenuada. 46

VI.2 Matriz de contingência entre as anotações majoritárias dos grupos masculino e feminino no corpus MQD-1222. A intensidade de cor é proporcional à frequência absoluta. A concentração ao longo da diagonal principal sugere o elevado alinhamento direto entre os grupos. 46

VI.3 Comparação entre κ_{anot} e κ_{pred} por classificador, no corpus MQD-1222. A linha tracejada demarca o valor de referência κ_{anot}. Todos os modelos apresentaram redução sistemática da concordância após o treinamento supervisionado, com κ_{pred} variando entre 0,4680 (Naive Bayes (NB)) e 0,5140 (Logistic Regression (LR)), na faixa moderada de [Landis and Koch, 1977]. 47

VI.4 Matrizes de contingência entre as predições dos modelos masculino e feminino para cada um dos quatro classificadores avaliados no corpus MQD-1222. A diagonal principal concentra as concordâncias diretas entre os pares de modelos. As discordâncias fora da diagonal revelam padrões qualitativamente distintos entre os algoritmos: o NB apresenta maior dispersão na fronteira entre as classes negativa e positiva (199 instâncias), enquanto o Random Forest (RF) exibe a maior célula de concordância absoluta na classe positiva (447). Os valores de κ_{pred} nos títulos dos subgráficos correspondem aos da Tabela VI.2 e resultam da média dos cinco κ por *fold* (Equação VI.2); por resultarem de uma agregação não linear, diferem em no máximo 0,0016 do κ recalculado sobre a matriz agregada aqui exibida (0,4792, 0,4665, 0,5034 e 0,5133 para SVM, NB, RF e LR). 49

VI.5 Comparação entre os valores de κ_{anot} obtidos nos doze cenários sintéticos, representados por SynSA-XX, e o valor empírico de referência do MQD-1222. 52

VI.6 Evolução de κ_{pred} em função da taxa de concordância dos conjuntos de dados sintéticos, por classificador. A linha tracejada amarela representa os valores dos kappas originais (κ_{anot}). Todos os modelos apresentam κ_{pred} sistematicamente inferiores à concordância original em toda a extensão da escala. O RF exibe os menores valores em todos os cenários, indicando maior redução de concordância sob as condições avaliadas, enquanto Support Vector Machine (SVM), NB e LR seguem trajetórias aproximadamente paralelas entre si. 53

VI.7 Deslocamento entre as faixas de Landis and Koch [1977] para os conjuntos de dados sintéticos. Cada célula indica o deslocamento por faixas interpretativas perdidas entre κ_{anot} e κ_{pred}: cinza = nulo; azul = restrito; laranja = amplo; vermelho = acentuado. A coluna RF apresenta deslocamento acentuado de SynSA-99 a SynSA-75, amplo em SynSA-70 e SynSA-65 e restrito de SynSA-60 a SynSA-50; SVM, NB e LR concentram deslocamentos restritos. 55

VI.8 Amplificação de divergências ($\Delta\kappa$) por algoritmo no cenário SynSA-85 (concordância nominal de 85%, $\kappa_{\text{anot}} = 0{,}7748$), com codificação de cor segundo o deslocamento entre as faixas propostas por Landis and Koch [1977]. O RF apresenta deslocamento acentuado (+0,6076, 3 faixas), enquanto SVM (+0,3091), NB (+0,2968) e LR (+0,3022) apresentam deslocamento restrito (1 faixa). Esse cenário é o mais próximo do contexto empírico do MQD-1222 e constitui o principal ponto de articulação interpretativa entre as duas instanciações. 56

VI.9 $\Delta\kappa$ por classificador: valor empírico (MQD-1222) sobreposto à curva sintética (SynSA-50 a SynSA-99). O fundo delimita a região de amplificação ($\Delta\kappa > 0$). A linha tracejada horizontal representa o $\Delta\kappa$ empírico de cada classificador; a curva laranja representa o $\Delta\kappa$ sintético em função do nível de concordância nominal. 57

VI.10 Para o RF, o valor empírico ($\Delta\kappa = 0{,}2645$) aproxima-se dos valores de concordância nominal de 60% da curva sintética e é inferior ao resultado de SynSA-85 ($\Delta\kappa = 0{,}6076$), cenário com κ_{anot} próximo ao do corpus empírico. Essa comparação é descritiva e não pressupõe que a curva sintética determine a magnitude esperada em textos reais. 58

VI.11 Amplificação de divergências: queda de κ por classificador nas instanciações empírica (MQD-1222) e sintética (média SynSA). As setas ilustram a transição de κ_{anot} (linha de base) para κ_{pred} (predições); a seta sintética parte da média de κ_{anot} dos doze cenários (0,6510). As setas são posicionadas sobre as faixas interpretativas de Landis and Koch [1977]. As anotações indicam a magnitude ($\Delta\kappa$) e o número de faixas percorridas em cada caso. Na instanciação empírica, todos os classificadores percorrem uma faixa (deslocamento restrito). Na sintética, SVM, NB e LR concentram deslocamentos nulos ou de uma faixa, com deslocamento amplo em três cenários do SVM e em um do LR, enquanto o RF atinge a maior magnitude média ($\overline{\Delta\kappa} = +0{,}4738$) e percorre três faixas em sete cenários, duas em dois e uma nos três restantes (Tabela VI.4). 60

VII.1 Cronograma das atividades previstas entre a qualificação e a defesa da dissertação. Os números na faixa superior indicam as semanas de cada mês, de novembro de 2026 a janeiro de 2027. Fonte: elaboração própria. 68

Lista de Tabelas

II.1 Escala de interpretação do coeficiente κ [Landis and Koch, 1977] 11

II.2 Convenção terminológica adotada na dissertação 14

III.1 Comparação dos trabalhos examinados segundo os quatro eixos da pesquisa. O primeiro considera o gênero do anotador como critério de agrupamento; o segundo, a análise de sentimentos como tarefa; o terceiro, a comparação entre a concordância das fontes de rótulos e a concordância das predições de modelos treinados de forma pareada; e o quarto, a utilização de textos em português brasileiro. As marcações indicam atendimento ao critério, conforme os procedimentos descritos em cada estudo. 24

IV.1 Exposição ao descarte e taxa de empate por grupo na consolidação por maioria (N = 1.463 frases). 29

IV.2 Evolução da volumetria dos conjuntos de dados no pré-processamento para este estudo. 30

VI.1 Configuração experimental consolidada da representação textual, da validação cruzada, dos algoritmos supervisionados e do procedimento de *bootstrap*. 40

VI.2 Resultados consolidados da instanciação empírica (MQD-1222). O deslocamento é classificado pelo número de faixas de Landis and Koch [1977] percorridas entre o κ_{anot} e o κ_{pred}: 0 = nulo; 1 = restrito; 2 = amplo; ≥ 3 = acentuado. O V de Cramér é calculado sobre a matriz de contingência global das predições pareadas, conforme a Seção VI.1.7. As estatísticas χ^2 associadas são 573,08 (SVM), 559,49 (NB), 630,99 (RF) e 660,48 (LR), todas com $p < 0{,}001$. 50

VI.3 Concordância entre as fontes anotadoras nos cenários sintéticos. 51

VI.4 Amplificação ($\Delta\kappa$) e deslocamento entre as faixas de Landis and Koch [1977] por classificador nos cenários sintéticos. Nulo (0 faixas), restrito (1 faixa), amplo (2 faixas) e acentuado (≥ 3 faixas). 54

C.1 Ambiente computacional utilizado na execução dos notebooks. 75

C.2 *Stopwords* em português utilizadas no pré-processamento textual. 76

Lista de Acrônimos

AS	Análise de Sentimentos.
IC	Intervalo de Confiança.
LR	Logistic Regression.
MADA	Metodologia de Análise de Divergências Anotativas.
NB	Naive Bayes.
PLN	Processamento de Linguagem Natural.
RF	Random Forest.
SVM	Support Vector Machine.
TF-IDF	Term Frequency-Inverse Document Frequency.

Declaração de Uso de Ferramentas de Inteligência Artificial

O autor declara que utilizou ferramentas de Inteligência Artificial (IA) exclusivamente como apoio à produção textual desta dissertação, incluindo sugestões de redação, revisão linguística, esclarecimento de conceitos técnicos e organização de ideias. Todas as decisões conceituais, análises, interpretações, escolhas metodológicas, resultados experimentais e conclusões apresentadas são de responsabilidade integral do autor.

Nenhum conteúdo gerado por ferramentas de IA foi incorporado sem revisão crítica. O uso dessas ferramentas ocorreu conforme princípios de integridade acadêmica, transparência e responsabilidade, e não substituiu o trabalho intelectual necessário à elaboração desta pesquisa.

Capítulo I Introdução

Classificar o sentimento de um texto envolve uma decisão de leitura. O anotador interpreta uma frase e atribui a ela uma categoria de sentimento negativa, neutra ou positiva. No aprendizado supervisionado, os textos e as categorias atribuídas servem como exemplos para que um sistema aprenda a classificar novos textos. Compreender esses dados exige, portanto, considerar as interpretações humanas que participaram de sua produção [Alm, 2011].

Quando várias pessoas avaliam a mesma frase, suas respostas nem sempre coincidem. Essa divergência pode decorrer de dificuldades na tarefa, mas também de interpretações distintas do conteúdo. Pavlick and Kwiatkowski [2019], por exemplo, observaram que desacordos sobre inferências textuais persistem mesmo com diferentes quantidades de avaliações coletadas. Plank [2022] discute como parte da variação nas anotações constitui informação relevante sobre a linguagem e seus intérpretes. A concordância entre anotadores precisa ser compreendida à luz da tarefa e das condições em que os julgamentos foram produzidos.

A relação entre o perfil dos anotadores e os julgamentos produzidos deve ser investigada em cada contexto. Ding et al. [2022], em uma pesquisa sobre sentimentos que incluiu texto, áudio e vídeo, observaram variação nas avaliações de participantes com diferentes perfis demográficos. Já Biester et al. [2022], ao examinarem quatro conjuntos de dados, não encontraram diferenças estatisticamente significativas entre as distribuições das anotações de homens e mulheres na maioria das tarefas, embora tenham identificado uma diferença no uso de categorias intermediárias na análise de sentimentos. Nas pontuações intermediárias, os anotadores homens atribuíram mais classificações levemente positivas ou levemente negativas. Porém, como discutem Fleisig et al. [2024], as características demográficas explicam apenas uma parte do desacordo e não esgotam a diversidade de experiências dos participantes.

Examinar essas relações depende de conhecer quem produziu os rótulos e como a anotação foi realizada. Essa informação, contudo, nem sempre acompanha os recursos utilizados. Geiger et al. [2020] identificaram omissões na descrição da produção de rótulos em artigos que classificavam publicações do Twitter. Uma investigação posterior, com aplicações de aprendizado supervisionado em diferentes áreas, também identificou artigos que não informavam quem havia realizado a anotação [Geiger et al., 2021]. Essa dificuldade também foi relatada por Biester et al. [2022], que contataram os responsáveis por 23 trabalhos e receberam 16 respostas. A maioria dos respondentes informou

não ter coletado, nem considerado coletar, informações demográficas dos anotadores. Esses relatos indicam que a caracterização demográfica não integrava sistematicamente o planejamento dos recursos examinados, restringindo investigações posteriores sobre a composição dos grupos e sua relação com os julgamentos produzidos.

Essa limitação pode ser observada em recursos de referência de diferentes tarefas de processamento de linguagem natural (PLN). No artigo que apresenta o Stanford Sentiment Treebank, Socher et al. [2013] descrevem a plataforma e o procedimento de anotação, mas não apresentam um perfil demográfico dos anotadores. Na classificação de discurso de ódio, Davidson et al. [2017] informam sobre o recrutamento pela plataforma CrowdFlower e a consolidação por decisão majoritária, sem caracterizar demograficamente os participantes.

No SNLI[1], Bowman et al. [2015] detalham a produção dos exemplos e a validação dos rótulos, mas também não apresentam essa caracterização no artigo. A descrição dos procedimentos, nesses casos, permite compreender como os dados foram produzidos, mas oferece informações limitadas sobre os grupos responsáveis pelos julgamentos.

Outros recursos tornam mais explícitos os limites das informações disponíveis. Na construção do SQuAD[2], Rajpurkar et al. [2016] estabelecem critérios de experiência na plataforma e restringem a participação a trabalhadores localizados nos Estados Unidos ou no Canadá, sem informar a composição por gênero ou idade. Ao apresentarem o MultiNLI[3], Williams et al. [2018] declaram que as informações demográficas dos 387 anotadores recrutados pela plataforma utilizada não estavam disponíveis para os autores. Esses exemplos distinguem a caracterização parcial dos participantes da indisponibilidade declarada de seus dados demográficos. Em ambos os casos, permanecem limites para examinar a relação entre o perfil dos anotadores e as respostas que produziram.

Há também trabalhos que incorporam essa caracterização à apresentação dos recursos. Waseem and Hovy [2016] informam a idade, o gênero e a formação da revisora externa de seu conjunto de discurso de ódio, enquanto Kirk et al. [2023] documentam o perfil das participantes responsáveis pela anotação de sexismo. A coexistência dessas práticas mostra que a documentação dos anotadores tem recebido tratamentos distintos. A proposta de Bender and Friedman [2018] sistematiza informações sobre a população e as condições de produção dos dados, visando tornar mais claros seu alcance e seus limites de utilização.

Essas diferenças de documentação têm consequências para o conhecimento que pode ser produzido a partir dos recursos. Como discutem Paullada et al. [2021], as decisões sobre a construção e disponibilização dos conjuntos participam da definição dos problemas e das análises que a pesquisa

[1]Stanford Natural Language Inference: conjunto de dados para avaliar relações de inferência entre pares de frases.

[2]Stanford Question Answering Dataset: conjunto de perguntas cujas respostas devem ser identificadas em textos de referência.

[3]Multi-Genre Natural Language Inference: conjunto de dados para inferência textual que reúne diferentes gêneros de texto.

consegue desenvolver. No caso da anotação, Prabhakaran et al. [2021] distinguem a disponibilização de rótulos agregados, distribuições de votos e julgamentos vinculados aos indivíduos, acompanhados ou não de informações sociodemográficas. Conhecer o perfil geral dos participantes não é suficiente para reconstruir quais respostas foram produzidas por cada grupo. Essa comparação exige que a vinculação dos julgamentos aos grupos seja preservada ou que seus rótulos sejam disponibilizados separadamente.

A decisão de agregar os votos estabelece, por sua vez, o nível em que as interpretações serão representadas. A revisão de Uma et al. [2021] reúne métodos que aprendem com julgamentos divergentes e Davani et al. [2022] avaliam modelos que procuram prever as respostas de cada anotador. A consolidação em uma única categoria resume essas respostas e pode ocultar diferenças entre elas. Entretanto, produzir um rótulo agregado não implica necessariamente a eliminação dos registros individuais; a regra utilizada no treinamento e as informações preservadas no conjunto de dados podem atender a finalidades distintas.

Esta pesquisa examina o que ocorre com a divergência entre duas fontes de rótulos quando os votos são agregados por uma característica dos anotadores que define fontes pareadas sobre os mesmos textos. Para o experimento, o gênero autodeclarado foi escolhido como variável estratificadora. Cada texto recebe um rótulo de cada grupo, correspondente à classe mais votada na primeira combinação válida de quatro votos desse grupo, desde que exista uma única classe vencedora. Quando nenhuma combinação atende a esse critério, o texto é descartado naquele grupo (Seção IV.1.2). Essa escolha mantém duas fontes de rótulos para os mesmos textos, embora resuma as diferenças entre os participantes de um mesmo grupo. Nesse sentido, o objeto da investigação é a divergência que permanece entre essas fontes após a agregação.

A disponibilidade dessas duas fontes permite examinar uma questão que ultrapassa a descrição dos julgamentos coletados: como a concordância entre elas se relaciona com a concordância entre as classificações produzidas após o treinamento. A investigação reúne dados anotados por participantes e conjuntos sintéticos nos quais a concordância inicial entre as fontes é controlada.

I.1 Definição do problema

Os trabalhos apresentados mostram que o perfil dos anotadores e o tratamento dos julgamentos divergentes constituem questões relevantes para a construção de sistemas de classificação. Estudos sobre características demográficas investigam relações entre o perfil dos participantes e as avaliações produzidas [Ding et al., 2022; Biester et al., 2022], enquanto outras abordagens procuram incorporar ao aprendizado a diversidade dos julgamentos individuais [Uma et al., 2021; Davani et al., 2022]. Essas frentes oferecem fundamentos para investigar como as diferenças presentes nas anotações se relacionam com as classificações produzidas pelos modelos.

A concordância entre grupos de anotadores caracteriza uma relação entre seus julgamentos, mas não determina a concordância entre modelos treinados com esses julgamentos. Quando os mesmos textos recebem rótulos consolidados separadamente por grupo, torna-se possível investigar essa relação em dois momentos: nas referências utilizadas para o treinamento e nas classificações produzidas a partir delas. O problema está em compreender se as divergências entre essas referências se ampliam nas respostas dos modelos e em quais condições isso ocorre.

O enfoque desta pesquisa situa-se na interseção de quatro eixos: (i) o recorte de gênero, em que os anotadores são agrupados pelo gênero autodeclarado; (ii) a análise de sentimentos, tarefa em que os julgamentos desses anotadores são considerados; (iii) a amplificação preditiva, entendida como a comparação entre a concordância das fontes de rótulos e a concordância das predições de modelos treinados de forma pareada; e (iv) a aplicação em português, com textos em português brasileiro. Entre os trabalhos revisados no Capítulo III, não foi identificado estudo que articule os eixos (i) a (iv) para compreender em quais condições as divergências entre grupos aumentam após o treinamento.

A questão central desta pesquisa é: as divergências entre rótulos consolidados por grupos de anotadores definidos pelo gênero autodeclarado são preservadas, atenuadas ou amplificadas por classificadores supervisionados na análise de sentimentos em português brasileiro e, quando amplificadas, em que condições isso ocorre? As condições examinadas são o nível de concordância inicial entre as fontes, controlado nos conjuntos sintéticos, e o algoritmo de classificação, entre quatro classificadores clássicos.

A investigação considera os grupos de participantes que se declararam do gênero masculino e do gênero feminino. Os rótulos consolidados por grupo constituem as referências para a comparação, e a divergência entre essas referências delimita o objeto de estudo. O gênero organiza esse recorte, sem ser assumido como causa isolada das diferenças observadas ou como indicador de que um grupo interpreta melhor os textos. Esta pesquisa não distingue se a amplificação é específica da estratificação por gênero ou se ocorreria em qualquer bipartição arbitrária dos anotadores; essa limitação é discutida na Seção VII.2.

I.2 Contribuições

A proposta reúne três contribuições. A primeira é a formulação de uma metodologia para comparar a concordância entre duas fontes de rótulos com a concordância entre as classificações dos modelos treinados a partir dessas fontes. A metodologia estabelece as condições para essa comparação e os critérios para descrever a direção e a magnitude da diferença entre as concordâncias.

A segunda contribuição é a organização de recursos empíricos e sintéticos para o estudo das divergências anotativas. O MQD-1222 reúne 1.222 frases em português brasileiro, anotadas por 46

participantes, com rótulos consolidados por gênero e preservação dos julgamentos individuais, da distribuição dos votos e dos tempos de resposta [Feitosa et al., 2026]. Complementam esse recurso os doze conjuntos sintéticos SynSA-XX, em que XX indica a concordância nominal entre as fontes de rótulos, variando de 50% a 99%. Esses materiais também oferecem uma base para pesquisas futuras sobre divergências entre grupos de anotadores.

A terceira contribuição consiste nas evidências obtidas com a aplicação da metodologia em dados empíricos e sintéticos. Os experimentos permitem examinar a amplificação das divergências iniciais pelos classificadores avaliados e comparar sua magnitude entre diferentes algoritmos e níveis de concordância das fontes.

O programa de pesquisa que originou esta dissertação gerou as seguintes publicações em coautoria:

- FEITOSA, Alexander; CARNEIRO, Érica; GUEDES, Gustavo. Beyond Systematic Bias: Investigating Gender Differences in Portuguese Text Classification Annotation Patterns. In: SYMPOSIUM ON KNOWLEDGE DISCOVERY, MINING AND LEARNING (KDMiLe), 13., 2025, Fortaleza. *Anais [...]*. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 129–136. DOI: 10.5753/kdmile.2025.247589.

- CARNEIRO, Érica; FEITOSA, Alexander; GUEDES, Gustavo. When Annotators Disagree: A Controlled Evaluation of Gender Bias in Sentiment Analysis Using Synthetic Datasets. In: SIMPÓSIO BRASILEIRO DE TECNOLOGIA DA INFORMAÇÃO E DA LINGUAGEM HUMANA (STIL), 16., 2025, Fortaleza. *Anais [...]*. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 90–100. DOI: 10.5753/stil.2025.37816.

- FEITOSA, Alexander; FASANO, André; GUEDES, Gustavo. MQD-1222: um Dataset de Análise de Sentimentos em Português Brasileiro com Anotação Pareada por Gênero. In: BRAZILIAN WORKSHOP ON SOCIAL NETWORK ANALYSIS AND MINING (BraSNAM), 15., 2026, Gramado. *Anais [...]*. Porto Alegre: Sociedade Brasileira de Computação, 2026. p. 269–275. DOI: 10.5753/brasnam.2026.23296.

As duas primeiras publicações [Feitosa et al., 2025; Carneiro et al., 2025] correspondem a etapas anteriores deste programa de pesquisa e indicaram que a concordância entre as predições de classificadores foi menor do que a concordância entre as fontes de rótulos; a terceira [Feitosa et al., 2026] apresenta o MQD-1222. Nenhuma delas formalizou a diferença entre as duas concordâncias, testou sua significância estatística ou reuniu dados empíricos e sintéticos em um único desenho pareado, o que constitui o objeto desta pesquisa. Por esse motivo, essas publicações são tratadas como antecedentes e não como validação externa dos resultados aqui reportados.

A pesquisa também se relaciona com os Objetivos de Desenvolvimento Sustentável (ODS), especialmente com o ODS 5, relativo à igualdade de gênero, e com o ODS 10, voltado para a redução das desigualdades. Essa aproximação tem como fundamento o papel dos julgamentos de diferentes grupos na construção e na avaliação de sistemas de classificação. A contribuição pretendida é oferecer elementos para analisar a representação dessas perspectivas, sem pressupor que toda divergência entre grupos constitua uma desigualdade ou que sua identificação implique, por si só, a redução da discriminação.

A pertinência dessa discussão encontra respaldo contextual na revisão de Karam et al. [2025], dedicada ao uso de inteligência artificial no governo e às suas relações com os ODS. Na revisão, que abrangeu 73 estudos, as menções ao ODS 5 representaram 0,08% do total de menções aos objetivos contabilizadas pelos autores. O percentual refere-se a estudos sobre inteligência artificial no governo e não à anotação de dados, servindo aqui como indício de que a igualdade de gênero recebe pouca atenção explícita nesse campo, o que motiva explicitar a relação desta pesquisa com o ODS 5.

I.3 Organização do documento

Além desta introdução, o documento apresenta mais seis capítulos e três apêndices. O Capítulo II reúne os fundamentos conceituais: a análise de sentimentos e a divergência anotativa, a mensuração da concordância e da associação, a noção de viés em PLN, a amplificação de divergências no aprendizado supervisionado, com a notação adotada na Seção II.4, os classificadores avaliados e a validação cruzada com reamostragem. O Capítulo III apresenta a revisão da literatura, cujo processo de seleção segue um fluxograma baseado no PRISMA 2020, organizada em torno da representação da divergência anotativa, das divergências demográficas, da análise de sentimentos, da amplificação de viés e dos estudos em língua portuguesa (Seção III.5). O Capítulo IV descreve os conjuntos de dados: a construção do conjunto empírico MQD-1222, da coleta (Seção IV.1.1) à consolidação dos rótulos por grupo (Seção IV.1.2), e os doze conjuntos sintéticos, com a construção dos vetores de rótulos (Seção IV.2.1) e a geração dos textos (Seção IV.2.2).

O Capítulo V detalha a metodologia, composta por três módulos: a concordância entre as fontes de rótulos, o treinamento pareado com a concordância entre as predições e a quantificação da amplificação. O Capítulo VI reúne as configurações experimentais (Seção VI.1), com as escolhas de variáveis, dados, representação, validação cruzada, classificadores, cálculo da concordância entre predições, inferência estatística e integração entre as instanciações, e apresenta os resultados empíricos (Seção VI.2), sintéticos (Seção VI.3) e integrados (Seção VI.4). O Capítulo VII sintetiza os achados, discute as limitações e as contribuições, aponta trabalhos futuros e apresenta o cronograma até a defesa.

Os apêndices documentam as *strings* de busca da revisão da literatura (Apêndice A), o *pipeline*

de processamento dos registros de anotação do PCIbex (Apêndice B) e o ambiente computacional, além das *stopwords* da representação textual (Apêndice C).

Capítulo II Fundamentação Teórica

Este capítulo apresenta os fundamentos para investigar a relação entre as divergências nas anotações e nas predições. A discussão aborda a produção dos rótulos, a mensuração da concordância, o conceito de viés, a amplificação de divergências (com a notação da Seção II.4), os classificadores avaliados e a validação cruzada com reamostragem.

II.1 Análise de sentimentos e divergência anotativa

A classificação de polaridade é uma das tarefas de AS e consiste em atribuir categorias de sentimento a unidades textuais [Abdullah and Ahmet, 2023]. Nesta pesquisa, consideram-se as categorias negativa, neutra e positiva. A atribuição desses rótulos envolve a interpretação do conteúdo e pode variar conforme o contexto e a experiência do leitor [Alm, 2011]. Reconhecer essa dimensão subjetiva permite investigar o desacordo sem pressupor que toda diferença seja um erro ou que esteja necessariamente associada ao perfil demográfico dos anotadores. O português brasileiro delimita o contexto linguístico da investigação empírica.

Os rótulos registram interpretações produzidas sob determinadas condições de anotação. O conteúdo do texto, a familiaridade com o domínio e os critérios apresentados aos participantes podem influenciar esses julgamentos [Hovy and Prabhumoye, 2021; Paullada et al., 2021]. Essa compreensão é convergente com Freitas [2026], para quem dados anotados em PLN codificam dimensões do entendimento humano sobre palavras, frases ou textos, cuja aparente objetividade decorre, muitas vezes, de consensos estabilizados ou do senso comum.

Diretrizes de anotação estabelecem critérios comuns, mas podem deixar margem para interpretações distintas. A divergência anotativa corresponde ao desacordo entre os rótulos atribuídos a uma mesma instância. Nesta pesquisa, o termo designa o desacordo entre os rótulos consolidados das duas fontes (Tabela II.2). Esse desacordo pode refletir diferenças de interpretação, dificuldades na aplicação das diretrizes ou erros de anotação. Como discute Plank [2022], parte dessa variação constitui informação relevante sobre a linguagem e seus intérpretes.

Abordagens que utilizam um único rótulo de referência por instância frequentemente tratam o desacordo como um problema a ser resolvido antes do treinamento [Plank, 2022]. A consolidação facilita o uso dos dados em classificadores convencionais, mas pode ocultar interpretações distintas

quando a análise considera apenas o rótulo resultante. A existência de uma referência operacional não implica, contudo, que ela represente a única interpretação possível do texto.

A revisão de Uma et al. [2021] reúne métodos que incorporam julgamentos divergentes ao aprendizado. Essa perspectiva permite considerar a informação contida no desacordo, sem dispensar a avaliação da qualidade das anotações. Em uma tarefa distinta da AS, Ross et al. [2017] observaram baixa concordância na identificação de discurso de ódio. A apresentação de uma definição a um dos grupos não melhorou a confiabilidade das anotações.

Na anotação de linguagem com viés de gênero, Havens et al. [2022] propõem uma taxonomia que contempla identidades além das categorias binárias na etapa de registro de gênero dos envolvidos no estudo. O trabalho evidencia a importância de explicitar o que as categorias de anotação permitem representar.

Röttger et al. [2022] distinguem dois paradigmas de anotação conforme a finalidade dos dados. No paradigma prescritivo, as diretrizes procuram orientar os anotadores na aplicação consistente de uma perspectiva definida. No paradigma descritivo, o objetivo é registrar a diversidade de julgamentos dos participantes. A distinção diz respeito ao tratamento da subjetividade e não estabelece uma separação fixa entre tarefas objetivas e subjetivas.

Kenyon-Dean et al. [2018] analisam exemplos com elevada discordância em conjuntos de sentimentos do Twitter e questionam sua exclusão antes do treinamento. O resultado se refere aos recursos examinados e reforça a necessidade de explicitar quais julgamentos são representados pelos rótulos utilizados.

A agregação dos votos define o nível em que os julgamentos são representados. Um único rótulo por texto não permite reconstruir, por si só, as diferenças entre grupos, mas sua produção não exige apagar os registros individuais. Nesta pesquisa, os votos são consolidados separadamente por gênero autodeclarado, e o rótulo de cada grupo é a classe estritamente majoritária entre quatro votos; quando nenhuma combinação de quatro votos tem uma única classe vencedora, o texto é descartado naquele grupo (Seção IV.1.2). Os dois rótulos resultantes permitem comparar as fontes, embora não representem todas as diferenças entre os participantes de cada grupo. A preservação dos julgamentos individuais no conjunto de dados atende a análises que ultrapassam esse recorte.

II.2 Mensuração da concordância e da associação

Artstein and Poesio [2008] sistematizam medidas de concordância utilizadas em linguística computacional. Entre elas, o coeficiente κ de Cohen permite comparar duas fontes que atribuem categorias às mesmas instâncias [Cohen, 1960], sendo definido por

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \tag{II.1}$$

em que p_o é a proporção de concordância observada e p_e é a concordância esperada sob independência entre as fontes, calculada a partir de suas distribuições marginais. Quando $p_e < 1$, o coeficiente compara a concordância observada com essa referência. O valor 1 indica concordância perfeita; o valor 0 indica igualdade entre a concordância observada e a esperada; valores negativos indicam uma concordância inferior à esperada. Esses valores descrevem a relação entre as fontes e não estabelecem a correção dos rótulos.

Nesta pesquisa, a comparação envolve dois vetores de rótulos consolidados, y_A e y_B (fontes A e B), e, posteriormente, dois vetores de predições, $\hat{y}_A$ e $\hat{y}_B$, para as mesmas instâncias. O κ de Cohen é adequado a essa estrutura pareada, na qual duas fontes atribuem categorias às mesmas instâncias. Embora o α de Krippendorff também possa ser aplicado a duas fontes, sua flexibilidade adicional não é necessária para a comparação realizada nesta pesquisa.

Landis and Koch [1977] propuseram uma escala interpretativa que divide o coeficiente em seis faixas qualitativas, amplamente utilizada na literatura como referência para a concordância entre avaliadores (Tabela II.1). Neste trabalho, adotam-se as traduções indicadas nesta tabela. Como κ assume valores contínuos, as faixas são aplicadas com cortes em 0,20, 0,40, 0,60 e 0,80, e um valor que excede o corte passa para a faixa seguinte.

Tabela II.1: Escala de interpretação do coeficiente κ [Landis and Koch, 1977]

Termo original	**Tradução adotada**	**Intervalo de κ**
Poor	Ruim	$\kappa < 0{,}00$
Slight	Leve	$0{,}00 \leq \kappa \leq 0{,}20$
Fair	Razoável	$0{,}21 \leq \kappa \leq 0{,}40$
Moderate	Moderada	$0{,}41 \leq \kappa \leq 0{,}60$
Substantial	Substancial	$0{,}61 \leq \kappa \leq 0{,}80$
Almost Perfect	Quase Perfeita	$0{,}81 \leq \kappa \leq 1{,}00$

O coeficiente κ depende da concordância observada e das distribuições marginais das classes. Em determinadas configurações, pode assumir valores baixos mesmo sob alta concordância bruta, fenômeno conhecido como o paradoxo do κ [Feinstein and Cicchetti, 1990]. Na comparação entre anotações e predições, mudanças nas distribuições marginais também podem contribuir para a variação do coeficiente.

Concordância e associação descrevem relações diferentes. A primeira considera a atribuição da mesma categoria à mesma instância; a segunda considera a dependência entre as categorias atribuídas por duas fontes. O teste χ^2 de independência compara as frequências observadas O_{ij} da tabela de contingência com as frequências esperadas E_{ij} sob independência entre as duas fontes,

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \tag{II.2}$$

e avalia se essas frequências são compatíveis com essa independência. Sua interpretação exige observar as condições do teste, incluindo as frequências esperadas e a independência entre as unidades analisadas.

O V de Cramér normaliza a estatística χ^2 pelo tamanho da amostra e pelo número de categorias,

$$V = \sqrt{\frac{\chi^2}{N\,(k-1)}}, \tag{II.3}$$

em que N é o número de instâncias e k o número de categorias de cada fonte (nesta pesquisa, $k = 3$), e expressa a intensidade da associação em uma escala de 0 a 1. Essa normalização não torna a estimativa insensível à composição da amostra ou às partições utilizadas. Duas fontes podem apresentar forte associação mesmo quando atribuem categorias diferentes de maneira sistemática. Assim, essas medidas complementam a descrição dos rótulos, mas não substituem a análise de concordância nem corrigem automaticamente as limitações do κ.

II.3 Viés em PLN

A discussão sobre viés em PLN exige distinguir os comportamentos observados dos critérios utilizados para avaliá-los. Blodgett et al. [2020] mostram que a literatura emprega o termo com sentidos diversos e nem sempre explicita quais comportamentos são considerados prejudiciais, para quem e por quê. Nesta pesquisa, a divergência entre fontes de rótulos constitui o objeto mensurado. Sua relação com o viés depende de uma interpretação adicional das condições de produção dos dados e dos possíveis usos dos sistemas.

Estudos sobre viés de gênero em AS também examinam como os sistemas respondem a referências a pessoas de diferentes gêneros. Kiritchenko and Mohammad [2018] identificaram diferenças sistemáticas nas intensidades atribuídas pelos sistemas avaliados a sentenças em inglês construídas para examinar esse comportamento. Nesse caso, o gênero está representado no conteúdo textual. Na presente pesquisa, o gênero autodeclarado identifica os grupos que produziram os rótulos de supervisão. Os dois recortes relacionam linguagem e gênero, mas investigam relações diferentes. O uso de textos em português brasileiro situa a comparação entre fontes anotadoras nesse contexto linguístico, sem constituir uma replicação direta daquele experimento.

A pesquisa considera os grupos de participantes que se declararam do gênero masculino e do gênero feminino. Esse recorte descreve as categorias analisadas, sem representar toda a diversidade de gênero ou a heterogeneidade das experiências de seus integrantes. O gênero organiza a comparação, mas não é assumido como causa isolada das diferenças observadas.

Uma eventual amplificação das divergências (Seção II.4) não demonstra, por si só, prejuízo a um grupo. A interpretação de suas possíveis consequências depende do contexto de aplicação.

II.4 Amplificação de divergências no aprendizado supervisionado

No aprendizado supervisionado, o modelo ajusta uma função a partir dos exemplos de treinamento e a utiliza para classificar novas instâncias. A generalização depende dos dados, da representação textual e das restrições do algoritmo [Hastie et al., 2009; Izbicki and Santos, 2020]. Essas restrições constituem seu viés indutivo, conceito que designa as preferências do procedimento de aprendizado e que tem um sentido distinto do viés social discutido na Seção II.3.

Quando os mesmos textos recebem rótulos de duas fontes, modelos treinados separadamente podem produzir classificações com níveis de concordância diferentes dos observados entre esses rótulos. A concordância pode diminuir, manter-se no mesmo valor ou aumentar, o que corresponde, respectivamente, à amplificação, à preservação e à atenuação da divergência, esta última denominada convergência induzida na Tabela II.2. Nesta pesquisa, a redução é identificada como amplificação segundo a medida e as condições de comparação adotadas.

Na comparação desenvolvida nesta pesquisa, κ_{anot} representa a concordância entre os rótulos consolidados das duas fontes. Após o treinamento, κ_{pred} representa a concordância entre as predições dos modelos, cujo desacordo constitui a divergência preditiva. A diferença $\Delta\kappa = \kappa_{\text{anot}} - \kappa_{\text{pred}}$ expressa a variação entre esses níveis de concordância. Valores positivos indicam menor concordância entre as predições, segundo essa medida. A Tabela II.2 reúne os termos empregados nessa comparação.

O pareamento das condições de treinamento permite comparar as fontes sob uma configuração comum, mantendo constantes os textos, as partições e os parâmetros dos classificadores entre os membros de cada par. Esse controle não elimina a variabilidade associada a outras realizações experimentais, nem demonstra que o valor de $\Delta\kappa$ se manteria sob outras partições ou sementes.

O estimador e as condições de comparação são apresentados no Capítulo V e os procedimentos de inferência na Seção VI.1.8.

II.5 Classificadores supervisionados avaliados

Os classificadores selecionados nesta pesquisa representam quatro famílias clássicas de aprendizado supervisionado aplicadas à classificação textual: *Support Vector Machine* (SVM), *Logistic Regression* (LR), *Naive Bayes* Multinomial (NB) e *Random Forest* (RF). A escolha desses algoritmos busca comparar mecanismos indutivos distintos sob as mesmas condições experimentais, sem ajuste fino voltado para a maximização de desempenho, uma vez que o objetivo deste estudo é medir a variação de concordância entre as fontes anotadoras e não selecionar o classificador com melhor desempenho preditivo.

Cada algoritmo tem um viés indutivo distinto, o que pode afetar como a variabilidade dos

Tabela II.2: Convenção terminológica adotada na dissertação

Termo	**Definição operacional**	**Seção**
Subjetividade interpretativa	Propriedade da tarefa de AS que admite leituras legítimas distintas de um mesmo texto; origem teórica do fenômeno investigado	Seção II.1
Concordância anotativa (κ_{anot})	Concordância entre os rótulos consolidados das duas fontes, medida antes do treinamento; referência de comparação para κ_{pred}	Seção II.4
Concordância preditiva (κ_{pred})	Concordância entre as predições dos modelos, medida após o treinamento; referência de comparação para κ_{anot}	Seção II.4
Divergência anotativa	Desacordo entre os rótulos consolidados das duas fontes anotadoras; linha de base do desenho experimental	Seções II.1 e II.4
Divergência preditiva	Desacordo entre as predições dos modelos treinados a partir das duas fontes para as mesmas instâncias	Seção II.4
$\Delta\kappa$	$\kappa_{\text{anot}} - \kappa_{\text{pred}}$; quantifica a variação da concordância entre a etapa de anotação e a etapa de predição	Seções II.4 e V.4.1
Amplificação	Padrão descritivo indicado por $\Delta\kappa > 0$, no qual os modelos concordam entre si menos do que as fontes anotadoras concordaram nos rótulos. A evidência inferencial de amplificação é avaliada pelo limite inferior do intervalo de confiança de $\Delta\kappa$, que deve ser estritamente positivo.	Seção V.4.1
Preservação	Equivalência entre κ_{anot} e κ_{pred}, indicada por $\Delta\kappa \approx 0$ (o intervalo de confiança de $\Delta\kappa$ inclui zero), sem implicar identidade dos padrões de desacordo.	Seção V.4.1
Convergência induzida (atenuação da divergência)	Padrão indicado por $\Delta\kappa < 0$, identificado quando o limite superior do intervalo de confiança de $\Delta\kappa$ é estritamente negativo: os modelos concordam entre si mais do que as fontes anotadoras concordaram nos rótulos; possibilidade contemplada pela formulação da métrica	Seção V.4.1
Deslocamento entre categorias	Número de fronteiras da escala de Landis and Koch [1977] (Tabela II.1) cruzadas entre κ_{anot} e κ_{pred}; recurso descritivo ordinal que não constitui medida contínua da magnitude nem critério de identificação da amplificação	Seção V.4.2

Fonte: elaboração própria.

rótulos se reflete nas predições. No caso do SVM com *kernel* linear, a decisão é orientada pela busca de uma fronteira de separação no espaço de atributos, visando à maximização da margem entre as classes [Hastie et al., 2009]. Em representações textuais esparsas e de alta dimensionalidade, como Term Frequency-Inverse Document Frequency (TF-IDF), modelos de margem máxima tendem a apresentar bom desempenho por explorarem propriedades típicas desse espaço, como um grande número de atributos, baixa densidade dos vetores e relativa separabilidade entre as classes [Joachims, 1998].

A Regressão Logística também opera como modelo linear no espaço de atributos, estimando pesos associados às características textuais e produzindo fronteiras de decisão globais entre as classes [Hastie et al., 2009]. O *Naive Bayes* Multinomial, por sua vez, modela a distribuição dos termos condicionada às classes sob o pressuposto de independência condicional [Hastie et al., 2009], sendo frequentemente empregado em dados textuais esparsos.

O RF combina árvores de decisão construídas com amostras dos dados e seleção aleatória de atributos durante sua formação. A agregação das árvores busca reduzir a variância em relação a árvores individuais [Hastie et al., 2009]. A comparação com os modelos lineares permite investigar como essas diferenças de aprendizado se relacionam com a concordância entre as predições.

II.6 Validação cruzada e reamostragem

A validação cruzada permite obter predições para instâncias que não participaram do ajuste do modelo em cada partição. Na versão estratificada, a divisão procura preservar aproximadamente as proporções das classes do vetor utilizado para a estratificação [Géron, 2019; Hastie et al., 2009]. Em comparações pareadas, a utilização das mesmas partições mantém a correspondência entre as instâncias avaliadas pelos modelos. Se a estratificação utilizar os rótulos de apenas uma fonte, a preservação das proporções não estará automaticamente garantida para a outra.

A reamostragem por *bootstrap*, apresentada por Efron and Tibshirani [1994], permite estimar a variabilidade de uma estatística por meio de amostras com reposição. Sua aplicação depende da definição da unidade de reamostragem e das relações de dependência presentes nos dados. Em comparações pareadas, os valores correspondentes a uma mesma unidade devem ser reamostrados conjuntamente. Na comparação entre κ_{anot} e κ_{pred}, o intervalo obtido por *bootstrap* permite avaliar a incerteza de $\Delta\kappa$ sob as condições de reamostragem adotadas. Um limite inferior estritamente positivo fornece evidência de amplificação segundo esse procedimento. Essa interpretação é condicional às predições e partições utilizadas e não abrange, necessariamente, todas as fontes de incerteza do processo experimental. O procedimento adotado e o alcance da incerteza estimada são especificados na Seção VI.1.8.

Com esses conceitos estabelecidos, o Capítulo III examina como a literatura tratou a

representação da divergência anotativa, as divergências demográficas, a análise de sentimentos, a amplificação de viés e os estudos em língua portuguesa. Essa revisão permite situar a articulação dos quatro eixos apresentados na Seção I.1 em comparação com os trabalhos existentes.

Capítulo III Trabalhos relacionados

Neste capítulo, são descritos os trabalhos relacionados a esta pesquisa. A revisão da literatura teve seu processo de seleção apresentado em um fluxograma baseado no PRISMA 2020 [Page et al., 2021]. A busca, realizada em abril de 2026, foi conduzida em quatro bases internacionais (Scopus, Web of Science, ACM Digital Library, ACL Anthology) e na Biblioteca Digital da SBC (SOL), utilizando termos que combinam viés/divergência anotativa, tarefas de classificação textual e amplificação preditiva (*strings* completas no Apêndice A). Por integrarem a trajetória da própria pesquisa, as publicações anteriores dos autores desta dissertação (descritas na Seção I.2), independentemente de sua indexação nas bases consultadas, não são utilizadas como comparadores externos na Tabela III.1.

As consultas formuladas em português não recuperaram registros nas bases pesquisadas com as expressões utilizadas. A tradução dos termos de busca para o inglês, executada nas mesmas cinco bases, produziu 96 textos, distribuídos entre ACM (83), ACL (7), Scopus (4), Web of Science (2) e SOL (0). A esses, foram adicionados 66 textos identificados via Google Scholar, livros, materiais de orientação e rastreamento de referências (*snowballing*), conforme prática descrita por Wohlin [2014]. A Figura III.1 apresenta o fluxograma PRISMA, detalhando as etapas de identificação, triagem, elegibilidade e inclusão.

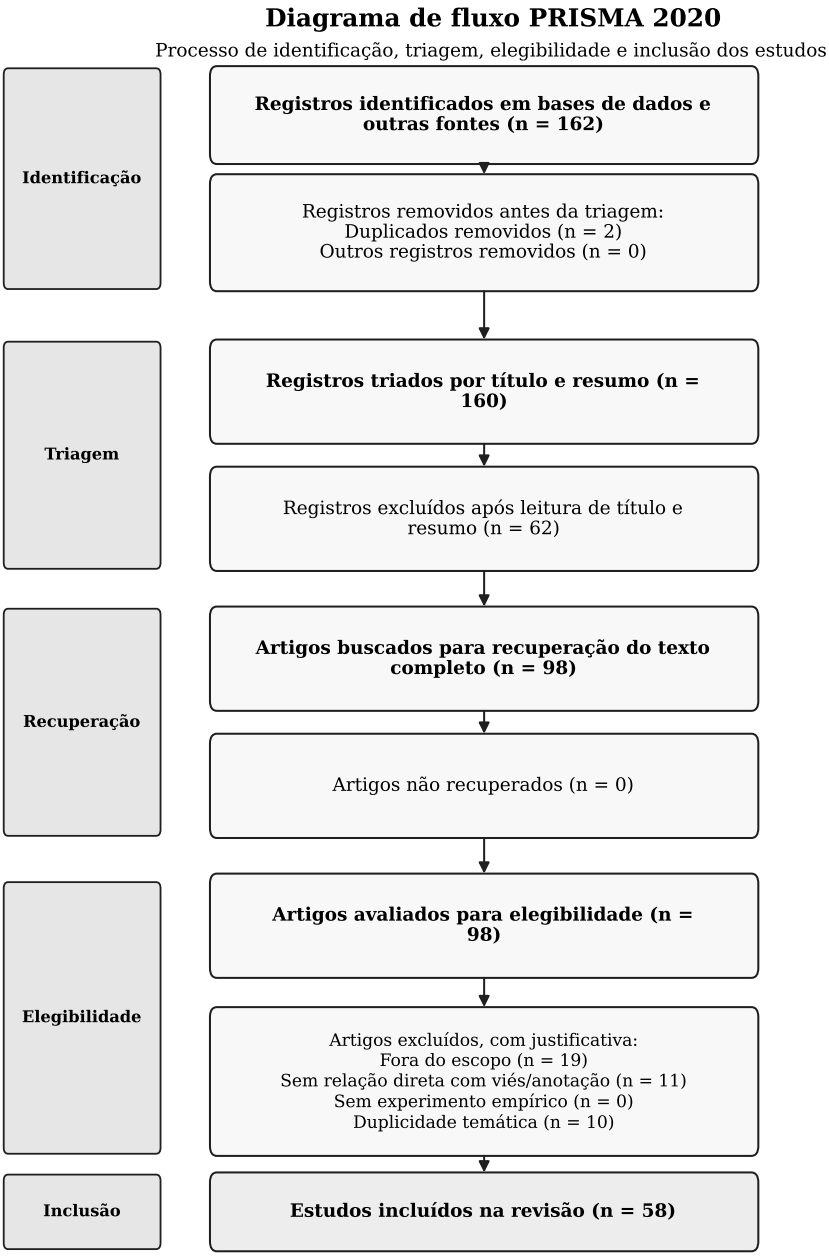


Figura III.1: Diagrama de fluxo PRISMA 2020 do processo de identificação, triagem, elegibilidade e inclusão dos estudos.

III.1 Representação da divergência anotativa

A Seção II.1 discutiu como o desacordo pode conter informação relevante sobre os julgamentos produzidos. Os trabalhos relacionados a seguir examinam formas de representar essa variação e suas consequências para a construção e a avaliação dos modelos.

Ivey et al. [2025] propõem o NUTMEG, um modelo bayesiano que busca reduzir anotações ruidosas, preservando desacordos sistemáticos entre subpopulações. A avaliação, utilizando dados sintéticos e reais, mostra que o modelo recupera os rótulos verdadeiros em presença de desacordo

sistemático melhor do que métodos tradicionais de agregação, e que classificadores treinados com os dados agregados por ele superam significativamente os treinados com agregação tradicional na tarefa de polidez, em todos os recortes demográficos, exceto raça. Na tarefa de ofensividade, as diferenças não são significativas.

As limitações da agregação majoritária em tarefas subjetivas têm motivado propostas alternativas de avaliação. Basile et al. [2021] argumentam contra os padrões-ouro tradicionais em tarefas subjetivas, nas quais a agregação prévia remove nuances interpretativas. Blodgett et al. [2020] argumentam, em uma revisão crítica da área, que tendências presentes na etapa de rotulagem se incorporam aos dados desde a origem e que sistemas treinados com esses dados tendem a herdá-las. Hovy and Prabhumoye [2021] identificam cinco fontes de viés em PLN: os dados, o processo de anotação, as representações de entrada, os modelos e o desenho da pesquisa. Prabhakaran et al. [2021] defendem a publicação de rótulos no nível do anotador individual como condição para mitigar vieses de anotação, e Davani et al. [2022] mostram que considerar a distribuição completa de rótulos individuais, em vez do voto majoritário, melhora a qualidade dos modelos em tarefas de alta variabilidade. Paullada et al. [2021] tratam os dados como produtos culturais cujas lacunas refletem as condições sociais de sua produção, e Raji et al. [2021] estendem a crítica aos *benchmarks* de avaliação.

Fleisig et al. [2024] revisam os pressupostos por trás da virada perspectivista e apontam desafios normativos ainda em aberto no tratamento de julgamentos humanos divergentes. Munir et al. [2026], em uma revisão de 346 estudos publicados entre 2020 e 2025, descrevem o paradigma do rótulo consensual como uma falácia positivista que trata o desacordo humano como ruído técnico e não como informação sociotécnica relevante. Esta pesquisa não propõe outra forma de agregar ou representar o desacordo: mantém a consolidação pela classe estritamente mais votada na primeira combinação válida de quatro votos de cada grupo e examina a divergência que permanece entre as duas fontes consolidadas.

III.2 Divergências demográficas

Uma linha de investigação examina a relação entre características dos anotadores e os julgamentos produzidos. Pei and Jurgens [2023] apresentaram o conjunto POPQUORN, no qual anotadores com o perfil demográfico identificado produziram 45.000 anotações em quatro tarefas: detecção de ofensividade, resposta a perguntas, reescrita de textos quanto à polidez e avaliação da polidez. A partir desses dados, isolaram a identidade demográfica como variável preditiva do rótulo e avaliaram quais tarefas e tipos de textos apresentavam maior peso no processo de rotulagem. O estudo atende ao recorte de gênero. A AS e a comparação entre a concordância das fontes de rótulos e a das predições dos modelos ficam fora do seu escopo.

Geva et al. [2019] partem de outra premissa: a identificação do anotador e não suas características demográficas. A pesquisa descreve um cenário de poucos indivíduos gerando muitas anotações e demonstra que a generalização é prejudicada quando a avaliação utiliza exemplos de anotadores ausentes do treinamento. Os dois trabalhos indicam que a origem do rótulo gera efeitos mensuráveis sobre o modelo, mas nenhum deles estima se a divergência entre grupos de anotadores aumenta após o treinamento.

Kuwatly et al. [2020] treinam classificadores separadamente sobre dados rotulados por grupos demográficos distintos (gênero, idioma nativo, idade e educação) e comparam o desempenho resultante. Para o gênero, os autores encontram uma concordância interanotadora, medida pelo α de Krippendorff, significativamente menor no grupo feminino (0,45 contra 0,51 no masculino). No entanto, a diferença de concordância entre os grupos não se traduziu em uma diferença significativa de F1 nas condições avaliadas.

Prabhakaran et al. [2024] propõem o GRASP para analisar a concordância dentro e entre grupos de anotadores, incluindo agrupamentos por gênero. No conjunto DICES-350, dedicado à avaliação da segurança de conversações, o agrupamento apenas por gênero não apresenta resultados estatisticamente significativos, comportamento que difere do observado em algumas interseções entre gênero e raça/etnia.

Esses resultados mostram que a análise isolada do gênero pode não captar as diferenças observadas quando outras características dos participantes também são consideradas. Stańczak and Augenstein [2021] documentam limitações persistentes da área, entre elas a suposição binária de gênero e a escassez de estudos multilíngues. Orlikowski et al. [2023] acrescentam a modelos de múltiplos anotadores camadas específicas para grupos definidos por atributos sociodemográficos e as avaliam na detecção de conteúdo tóxico. A inclusão dessas camadas, contudo, não melhorou significativamente o desempenho.

III.3 Análise de sentimentos

Na análise de sentimentos, os estudos apresentam resultados distintos sobre a relação entre o gênero dos anotadores e os julgamentos produzidos. Ding et al. [2022] mostraram que gênero, idade e origem cultural estão associados a diferenças na percepção de polaridade e na intensidade emocional. Biester et al. [2022] examinaram quatro conjuntos de dados e não encontraram diferenças estatisticamente significativas entre homens e mulheres na maioria das tarefas. Os autores identificaram um maior uso de categorias intermediárias pelos anotadores masculinos. Kumar et al. [2020] compararam modelos de AS treinados sobre opiniões estratificadas por idade e gênero dos próprios autores, coletadas em uma rede social sobre preferências de formatos de livro, e encontraram uma acurácia superior nos modelos treinados com os dados do grupo feminino.

Em seu estudo, Thelwall [2018] treinou classificadores de AS separadamente sobre conjuntos de autoria masculina e feminina, e verificou uma detecção mais precisa em textos de autoria feminina. Duas distinções o separam do recorte proposto nesta dissertação. A primeira é que o eixo de gênero ali é o do autor do texto, não o do anotador. A segunda é que a comparação opera sobre o desempenho preditivo, não sobre a concordância pareada entre as predições de dois modelos treinados em fontes anotadoras distintas.

Quanto à avaliação de sistemas, Kiritchenko and Mohammad [2018] desenvolveram o Equity Evaluation Corpus (EEC), com 8.640 sentenças em inglês, e encontraram viés estatisticamente significativo na maioria dos 219 sistemas analisados. Gupta et al. [2024] documentam viés sistemático de gênero em sistemas de AS em uma revisão sobre viés sociodemográfico.

III.4 Amplificação de viés

Zhao et al. [2017] identificaram a amplificação de associações de gênero em duas tarefas de visão computacional: a classificação de múltiplos objetos em imagens e a rotulação de papéis semânticos visuais, nas quais o modelo identifica a atividade retratada e os participantes de cada papel. Em ambas, a associação entre gênero e as categorias de saída (objetos e atividades) foi maior nas predições dos modelos do que nos dados de treinamento. Nesses estudos, a amplificação é medida pela associação entre gênero e categorias de saída. Nesta pesquisa, a medida é a concordância entre fontes de rótulos (Seção II.4).

Minatel et al. [2023] investigam como diferentes critérios de estratificação se relacionam com efeitos discriminatórios na classificação binária e observam que considerar conjuntamente a classe e o grupo sociodemográfico pode reduzir esses efeitos. Lim et al. [2024] aplicam análise de mediação causal para quantificar o quanto os componentes internos do modelo mediam o efeito de artefatos de anotação sobre as predições em tarefas de inferência textual, verificação de fatos e identificação de paráfrases.

Jentzsch and Turan [2022] verificaram viés de gênero significativo em sete modelos BERT públicos sob nove condições de treinamento e atribuíram sua origem ao pré-treinamento, e não aos dados da tarefa. Esse resultado é pertinente à delimitação experimental desta pesquisa, que utiliza TF-IDF sem representações pré-treinadas e, portanto, não incorpora essa fonte de viés.

Outros trabalhos examinam intervenções na anotação, a medição e a mitigação de viés de gênero em classificadores e o uso de informações demográficas na classificação. Toker et al. [2024] tratam do viés de ancoragem na anotação sequencial de sentimentos: um conjunto de calibração, escolhido por regras aprendidas, é rotulado no início da tarefa e reduz o erro médio dos julgamentos subsequentes. Sobhani and Delany [2024] identificam o gênero mencionado nos próprios textos do corpus para medir viés em tarefas de classificação, incluindo a AS, e derivam dessa identificação uma

variante seletiva de aumento contrafactual (GS-CDA), que troca marcadores de gênero apenas nas instâncias identificadas; a mitigação por GS-CDA é avaliada apenas nos conjuntos de discurso de ódio, enquanto a AS é considerada somente na etapa de mensuração do viés, não na de mitigação. Jiang et al. [2024] examinam a relação entre características dos anotadores e julgamentos de sexismo e misoginia. O efeito do gênero do anotador não se mantém após a correção para comparações múltiplas. Além disso, o estudo aborda estratégias de *prompting* que incorporam informações demográficas e atitudinais à classificação por modelos de linguagem.

Wan et al. [2023] treinam um preditor de discordância entre anotadores a partir do texto e de informações demográficas, em cinco conjuntos de dados subjetivos, e simulam 140 perfis demográficos artificiais (quatro categorias de gênero, sete de etnia e cinco faixas etárias) para separar a discordância proveniente da controvérsia do texto daquela que provém da composição do grupo. O conjunto de sentimentos (DynaSent) é utilizado apenas na predição a partir do texto, pois somente o SBIC e o SChem101 fornecem dados demográficos dos anotadores. Apesar das diferenças de arquitetura e de objeto experimental, os dois estudos empregam condições artificiais para investigar a divergência. Wan et al. [2023] variam a composição demográfica simulada, enquanto a presente pesquisa controla a concordância inicial entre fontes de rótulos, sem simular perfis demográficos individuais.

Pandya et al. [2024] comparam estratégias de agregação de rótulos, incluindo votação majoritária e votação minoritária, quanto ao efeito sobre a representação de opiniões minoritárias em conjuntos de dados de detecção de sexismo, e mostram que os vieses introduzidos por cada estratégia podem ser amplificados pelos modelos treinados sobre os rótulos resultantes. O estudo parte da regra de agregação dos rótulos para examinar a amplificação. A comparação pareada entre fontes consolidadas por grupo de anotadores, antes e depois do treinamento, não integra seu escopo.

Xu et al. [2026] propõem o DEM-MoE, que utiliza características demográficas para organizar especialistas na modelagem dos julgamentos. Os autores também avaliam a combinação de anotações humanas e sintéticas, com resultados que dependem da estrutura dos conjuntos examinados.

Nos trabalhos desta seção, o viés ou a amplificação é caracterizado em relação às associações entre gênero e categorias de saída, às estratégias de agregação dos rótulos ou à origem do viés nos modelos; nenhum compara a concordância entre fontes de rótulos consolidadas por grupo de anotadores com a concordância entre as predições de modelos treinados de forma pareada.

III.5 Estudos em língua portuguesa

Mozetič et al. [2016] relacionam a concordância das anotações com o desempenho de classificadores de sentimentos em diferentes idiomas. No subconjunto em português, a participação

de um único anotador impede a mensuração da concordância entre anotadores. O trabalho oferece um antecedente para relacionar anotação e classificação.

Taso et al. [2023] identificam estereótipos de gênero em representações vetoriais de palavras em português obtidas com GloVe[1]. Firmino et al. [2024] identificaram, em letras de músicas brasileiras, que o gênero feminino é descrito por predicativos relacionados à aparência, enquanto o gênero masculino é descrito por traços de personalidade. Nesse trabalho, o recorte é o conteúdo textual associado ao gênero referido, não a anotação nem a amplificação preditiva.

Silva and Moro [2024] apresentam um *pipeline* de PLN para identificar viés de gênero em obras literárias em português. O estudo analisa as representações dos personagens no conteúdo textual, sem comparar a concordância entre os grupos de anotadores antes e depois do treinamento.

A Tabela III.1 reúne os trabalhos que atendem a pelo menos um dos quatro eixos delimitados na Seção I.1, e os demais estudos discutidos neste capítulo tratam de aspectos complementares. O primeiro eixo é marcado apenas quando o gênero define os grupos de anotadores; quando se refere ao autor do texto ou ao seu conteúdo, a célula fica sem marcação. Nos estudos examinados, não foi identificada uma investigação que articule o agrupamento dos anotadores por gênero, a análise de sentimentos, a comparação pareada das concordâncias antes e depois do treinamento e o uso de textos em português brasileiro. A contribuição proposta situa-se nessa articulação, examinada com dados empíricos e cenários sintéticos controlados. O Capítulo IV apresenta os dados empíricos e sintéticos que sustentam essa investigação.

[1]Global Vectors for Word Representation: método que aprende representações numéricas de palavras a partir de suas frequências de coocorrência em um corpus.

Tabela III.1: Comparação dos trabalhos examinados segundo os quatro eixos da pesquisa. O primeiro considera o gênero do anotador como critério de agrupamento; o segundo, a análise de sentimentos como tarefa; o terceiro, a comparação entre a concordância das fontes de rótulos e a concordância das predições de modelos treinados de forma pareada; e o quarto, a utilização de textos em português brasileiro. As marcações indicam atendimento ao critério, conforme os procedimentos descritos em cada estudo.

Trabalho relacionado	**Recorte de gênero**	**Análise de sentimentos**	**Amplificação preditiva**	**Aplicação em português**
Mozetič et al. [2016]	–	✓	–	–*
Thelwall [2018]	–	✓	–	–
Kiritchenko and Mohammad [2018]	–	✓	–	–
Kuwatly et al. [2020]	✓	–	–	–
Kumar et al. [2020]	–	✓	–	–
Biester et al. [2022]	✓	✓	–	–
Ding et al. [2022]	✓	✓	–	–
Jentzsch and Turan [2022]	–	✓	–	–
Orlikowski et al. [2023]	✓	–	–	–
Pei and Jurgens [2023]	✓	–	–	–
Taso et al. [2023]	–	–	–	✓
Wan et al. [2023]	✓	✓	–	–
Firmino et al. [2024]	–	–	–	✓
Prabhakaran et al. [2024]	✓	–	–	–
Gupta et al. [2024]	–	✓	–	–
Silva and Moro [2024]	–	–	–	✓
Sobhani and Delany [2024]	–	✓	–	–
Toker et al. [2024]	–	✓	–	–
Jiang et al. [2024]	✓	–	–	–
Ivey et al. [2025]	✓	–	–	–
Xu et al. [2026]	✓	–	–	–
Esta pesquisa	✓	✓	✓	✓

* Textos em português de Portugal; o eixo de aplicação em português brasileiro não é marcado.

Capítulo IV Apresentação dos conjuntos de dados

Este capítulo descreve os dois conjuntos de dados utilizados neste trabalho. A fase empírica utiliza o corpus MQD-1222, derivado de textos da rede social de diários pessoais em português brasileiro "Meu Querido Diário" (MQD), anotado por um conjunto de 46 participantes, segmentados por gênero autodeclarado (26 masculinos e 20 femininos). A caracterização deste conjunto de dados como corpus anotado e *dataset* linguístico segue a distinção proposta por Caseli and Nunes [2026] quanto à natureza interpretativa da anotação: para as autoras, conjuntos de dados linguísticos utilizados em PLN podem ser entendidos como *datasets* quando organizados para treinamento, avaliação ou comparação de modelos, sobretudo quando suas anotações codificam classificações atribuídas por orientação humana.

A fase sintética utiliza o método de geração SynSA, composto por doze conjuntos de dados com taxas de concordância parametrizadas, projetado para isolar o efeito da divergência anotativa sob condições controladas. A Seção IV.1 detalha o corpus empírico, da coleta via PCIbex[1] ao *pipeline* de consolidação; a Seção IV.2 descreve o algoritmo de geração do SynSA e os critérios de balanceamento.

IV.1 Corpus empírico: do MQD-1465 ao MQD-1222

A fase empírica foi conduzida em conformidade com os princípios éticos da pesquisa com seres humanos e aprovada pelo Comitê de Ética em Pesquisa (CEP) sob o protocolo CAAE 82267824.8.0000.5289. O gênero dos participantes foi autodeclarado e utilizado exclusivamente como critério de estratificação analítica. O registro de cada participante contém apenas esse gênero e um identificador pseudonimizado (Seção IV.1.1), sem nome, contato ou outro dado pessoal direto. A participação ocorreu mediante termo de consentimento livre e esclarecido.

O corpus inicial, MQD-1465, reúne 1.465 frases extraídas da rede social "Meu Querido Diário" (`www.meuqueridodiario.com.br`) [Azevedo et al., 2021]. Esse material, que serve de base para a classificação textual, é composto por textos autênticos em português brasileiro, com expressões coloquiais e variações ortográficas originais.

Como etapa preliminar ao experimento de anotação, o corpus foi submetido a limpeza

[1] `https://farm.pcibex.net/`

e randomização controlada, implementadas originalmente em Python 3.13.7 com semente fixa (semente igual a 42). Essa etapa antecede a reconstrução computacional documentada no Apêndice C. Foram identificadas e removidas duas frases duplicadas (IDs 476 e 953, mantendo as ocorrências originais de IDs 475 e 952), resultando em 1.463 frases únicas, padronizadas pela remoção de espaços e aspas redundantes. O corpus randomizado foi particionado em dez blocos sequenciais de até 150 frases, sendo o décimo bloco composto por 113 frases, conforme o total disponível após a remoção das duplicatas.

IV.1.1 Coleta via PCIbex

A anotação foi conduzida por um conjunto de 46 participantes (26 do grupo masculino e 20 do grupo feminino), recrutados por meio de redes sociais, que acessaram a tarefa de forma autônoma e assíncrona, sem contato com as respostas dos demais na plataforma. Foram considerados elegíveis os participantes que satisfizeram dois critérios de inclusão: (i) concluíram pelo menos um bloco completo da tarefa de anotação no PCIbex Farm e (ii) selecionaram uma das categorias de gênero disponíveis no instrumento de coleta por meio de uma caixa de combinação que exibia apenas as opções “masculino” e “feminino”. Como a plataforma não permitia o envio parcial do bloco, os registros exportados correspondiam a blocos completos de anotação.

Cada participante anotou entre um e dez blocos de forma não uniforme. Como os blocos eram disjuntos e o número de anotadores por bloco variava, o total de julgamentos por frase em cada grupo não é fixo. A coleta encerrou-se com 13.317 julgamentos individuais, nos quais foram registradas a classificação atribuída (positiva, negativa ou neutra) e o tempo de resposta, que será reservado para análises posteriores sobre o efeito da fadiga na anotação. Assim, a exclusão incidiu apenas sobre frases sem maioria válida no pareamento final entre os grupos (empates irresolúveis, conforme definido na Seção IV.1.2), uma vez que a plataforma não registrava blocos incompletos.

Do ponto de vista textual, foram preservadas apenas as sentenças pertencentes ao corpus originalmente randomizado, após a remoção de duplicatas e a correção dos identificadores locais de bloco para identificadores globais de frase. Na etapa de consolidação, permaneceram na base final apenas as sentenças para as quais foi possível obter, em ambos os grupos analisados, uma combinação de quatro votos com classe estritamente mais votada.

Do *log* do PCIbex Farm, extraíram-se, por participante, o identificador pseudonimizado (*hash* MD5 do endereço IP), o gênero autodeclarado, o rótulo de cada frase e a duração de cada julgamento, obtida por meio do pareamento dos eventos de início e fim de cada *trial*. Reconhece-se que o *hash* do endereço IP constitui uma pseudonimização com limitações: um mesmo participante, acessando por redes distintas, gera identificadores diferentes, e endereços compartilhados podem agrupar participantes distintos. A contagem de 46 participantes corresponde ao número de identificadores

distintos observados.

As linhas de cabeçalho foram removidas e os identificadores de item foram remapeados para as posições originais no corpus randomizado. A estrutura dos *logs* e o *script* de processamento constam no Apêndice B.

Os registros foram concatenados em um único conjunto, `MQD-13317_anotacoes_totais.csv`, e segmentados por gênero autodeclarado em dois subconjuntos, com 7.015 julgamentos masculinos (`MQD-7015`) e 6.302 femininos (`MQD-6302`). Essa segmentação por gênero é o ponto de partida para a consolidação por maioria descrita a seguir, na qual cada subconjunto é tratado de forma independente até a junção final entre os dois grupos.

IV.1.2 Consolidação majoritária

Para representar cada grupo pelo seu padrão interpretativo coletivo, o rótulo de cada frase foi consolidado por voto majoritário, com base em quatro julgamentos por grupo. Fixar o mesmo número de votos nos dois grupos evita que o masculino, com mais julgamentos por frase, tenha rótulos consolidados a partir de um maior número de votos do que o feminino.

Como a quantidade de julgamentos disponíveis por frase variava, o procedimento seleciona, entre os votos de cada grupo e priorizando os registros mais antigos, a primeira combinação de quatro votos que apresenta uma classe estritamente vencedora (Equação IV.1); quando nenhuma combinação de quatro votos satisfaz esse critério, a frase é descartada naquele grupo. A consolidação por voto majoritário é uma prática estabelecida em corpora de classificação textual [Artstein and Poesio, 2008]. A perda de informação sobre a distribuição completa dos rótulos individuais, que essa prática implica e que foi criticada por Prabhakaran et al. [2021] e Davani et al. [2022], é a mesma discutida na Seção II.1, na qual se descreve a consolidação separada por gênero adotada nesta pesquisa.

Seja $C = \{\text{positiva}, \text{negativa}, \text{neutra}\}$ o conjunto de classes. Para cada combinação, define-se votos(c) como o número de votos atribuídos à classe $c \in C$. A combinação é válida quando existe uma classe estritamente vencedora, conforme a Equação IV.1:

$$\exists\, c \in C : \forall\, c' \in C \setminus \{c\},\ \text{votos}(c) > \text{votos}(c'). \tag{IV.1}$$

Com quatro votos e três classes, as configurações possíveis são 4-0-0, 3-1-0, 2-1-1 e 2-2-0. As três primeiras satisfazem a condição e definem a classe majoritária, entendida neste trabalho como a classe estritamente mais votada da combinação. Essa definição inclui a configuração 2-1-1, embora nela a classe vencedora não reúna mais da metade dos votos. A configuração de empate (2-2-0) não satisfaz o critério de maioria e a combinação que a produz é rejeitada; a frase só é descartada

naquele grupo quando nenhuma combinação disponível é válida.

A busca percorre as combinações de quatro votos na ordem de coleta. A primeira reúne os quatro votos mais antigos e, quando é válida, define o rótulo sem que os demais votos sejam considerados. Quando ela empata e a frase tem mais votos, os três primeiros são mantidos e o quarto é substituído pelos seguintes, um de cada vez. Somente se todas essas substituições empatarem, a busca passa a substituir também os votos anteriores até encontrar a primeira combinação válida.

Em uma frase cujos quatro votos mais antigos são positivo, positivo, negativo e negativo, um quinto voto neutro produz a combinação positivo, positivo, negativo, neutro (2-1-1), e o rótulo é positivo; um quinto voto negativo resulta em empate, e a busca continua até a combinação positivo, negativo, negativo, negativo (3-1-0), com rótulo negativo.

Dessa ordem decorrem duas propriedades. Uma frase com cinco ou mais votos nunca é descartada: se algum voto posterior ao quarto pertence a outra classe, a substituição desfaz o empate em favor da classe que lidera entre os três primeiros votos. Se todos repetem a classe do quarto voto, essa classe reúne ao menos três votos e vence. O desempate segue uma convenção determinística de prioridade cronológica, de modo que o rótulo pode divergir da classe mais votada no conjunto completo. Com os votos positivo, negativo, positivo, negativo, neutro, negativo e negativo, em ordem de coleta, o rótulo é positivo (combinação positivo, negativo, positivo, neutro), embora negativo seja a classe mais votada no conjunto.

Das 1.463 frases, o grupo masculino produziu 1.393 com maioria válida e 70 descartes; o feminino, 1.273 e 190 descartes. Todas as frases dispunham de pelo menos quatro votos em cada grupo, de modo que o descarte decorre exclusivamente de empates irresolúveis.

A diferença entre os descartes (190 no grupo feminino e 70 no masculino) combina duas componentes que convém separar. A primeira é a exposição ao empate: apenas frases com exatamente quatro votos em um grupo podem ser descartadas, pois uma frase com cinco ou mais votos sempre admite alguma combinação válida. Essa condição vale para 79,5% das frases do grupo feminino e para 41,0% das do masculino (Tabela IV.1), de modo que o grupo feminino chegou à consolidação com mais frases sujeitas ao descarte.

A segunda componente é a taxa de empate entre as frases expostas, calculada apenas sobre aquelas que têm exatamente quatro votos. Nesse subconjunto, em que nenhum voto adicional atenua o empate, a taxa foi de 16,3% no grupo feminino e de 11,7% no masculino ($z = 2{,}62$; $p < 0{,}01$). A comparação bruta dos descartes mistura as duas componentes e, por isso, superestima a diferença entre os grupos. A comparação condicionada isola a segunda e ainda mostra mais empates no grupo feminino. Esse resultado descreve os votos coletados. Como os conjuntos de participantes variaram entre os blocos, tanto em número quanto em composição, o estudo não separa se a diferença decorre das pessoas de cada grupo, dos blocos que anotaram ou de outros fatores. A leitura como diferença

de estilo de anotação permanece uma possibilidade a ser investigada com os julgamentos individuais preservados.

Tabela IV.1: Exposição ao descarte e taxa de empate por grupo na consolidação por maioria (N = 1.463 frases).

Medida	**Masculino**	**Feminino**
Frases com exatamente quatro votos	600	1.163
Frases com cinco ou mais votos	863	300
Frases descartadas por empate	70	190
Taxa de empate entre frases com quatro votos	11,7%	16,3%

Uma análise de sensibilidade avaliou o efeito do desempate sobre os rótulos consolidados, tomando como alternativa a regra que usa apenas os quatro julgamentos mais antigos de cada frase e a descarta em caso de empate. As duas regras só diferem nas frases cujos quatro primeiros votos empatam e que dispõem de mais votos. Em relação a essa alternativa, a regra adotada resgata do descarte 86 frases do grupo masculino e 47 do grupo feminino. Na análise de sensibilidade, a regra alternativa baseada exclusivamente nos quatro primeiros votos produziu $\kappa_{\text{anot}} = 0{,}7936$, com $N = 1.111$. A regra adotada resultou em $\kappa_{\text{anot}} = 0{,}7664$, com $N = 1.222$. Essa diferença descreve o efeito conjunto da alteração do critério de seleção e da composição do corpus consolidado. Mantido κ_{pred}, um κ_{anot} menor reduz a margem disponível para que $\Delta\kappa$ apareça como positivo e, nesse sentido, o efeito sobre a linha de base seria conservador. A análise considerou apenas o efeito sobre κ_{anot}; o comportamento de κ_{pred} sob a regra alternativa não foi avaliado.

Dos 13.317 julgamentos coletados, 11.704 foram selecionados para aplicação do critério de maioria, correspondendo a quatro votos por grupo nas 1.463 frases anotadas. Os 1.613 julgamentos restantes constituem votos excedentes, preservados nos arquivos intermediários, mas não utilizados na consolidação majoritária. No grupo masculino, foram selecionados 5.852 dos 7.015 julgamentos coletados, resultando em 1.163 votos excedentes; no grupo feminino, foram selecionados 5.852 dos 6.302 julgamentos coletados, resultando em 450 votos excedentes.

O conjunto consolidado `MQD-1222_majoritarias.csv` contém, para cada frase e por grupo de gênero, a duração média dos julgamentos, o total de classificações utilizadas no voto, a classificação majoritária, a quantidade de votos na classe majoritária e as contagens individuais de votos positivos, negativos e neutros. Uma coluna de concordância binária indica se os dois grupos convergiram para a mesma classificação majoritária. O conjunto completo de julgamentos individuais (identificador pseudonimizado, rótulo, duração e bloco de origem) permanece nos arquivos intermediários, disponíveis para análises futuras de variação intragrupal e do efeito dos blocos.

O processo descrito transforma o corpus bruto MQD-1465 no corpus MQD-1222, utilizado em todas as análises empíricas desta dissertação. O MQD-1465 corresponde ao estado bruto inicial;

a remoção das duas duplicatas produz o MQD-1463, sobre o qual o experimento foi conduzido; as 13.317 anotações individuais coletadas via PCIbex constituem o MQD-13317, segmentado por gênero e consolidado por voto majoritário; a junção interna entre os subconjuntos retém apenas frases com rótulo majoritário válido em ambos os grupos, produzindo o MQD-1222 final. A Tabela IV.2 sintetiza essa transformação.

Tabela IV.2: Evolução da volumetria dos conjuntos de dados no pré-processamento para este estudo.

Conjunto/etapa	**Unidade**	**N**	**Descrição**
MQD-1465	Frases	1.465	Corpus bruto extraído do portal.
MQD-1463	Frases	1.463	Base após remoção de duplicatas (IDs 476 e 953); corpus submetido à anotação.
MQD-13317	Julgamentos	13.317	Total de julgamentos individuais coletados via PCIbex, a partir de um conjunto de 46 participantes.
MQD-7015	Julgamentos	7.015	Subconjunto de julgamentos do grupo masculino.
MQD-6302	Julgamentos	6.302	Subconjunto de julgamentos do grupo feminino.
Seleção para maioria, masculino	Julgamentos	5.852	Quatro julgamentos selecionados por frase no grupo masculino (1.463×4).
Votos excedentes, masculino	Julgamentos	1.163	Julgamentos masculinos que não integram a combinação de quatro votos adotada em cada frase ($7.015 - 5.852$).
Seleção para maioria, feminino	Julgamentos	5.852	Quatro julgamentos selecionados por frase no grupo feminino (1.463×4).
Votos excedentes, feminino	Julgamentos	450	Julgamentos femininos que não integram a combinação de quatro votos adotada em cada frase ($6.302 - 5.852$).
Maioria válida, masculino	Frases	1.393	Frases com classe estritamente vencedora no grupo masculino; 70 frases foram descartadas por empate.
Maioria válida, feminino	Frases	1.273	Frases com classe estritamente vencedora no grupo feminino; 190 frases foram descartadas por empate.
MQD-1222	Frases	1.222	Corpus final obtido pela junção interna entre os subconjuntos masculino e feminino, retendo apenas frases com maioria válida em ambos os grupos.

A escolha do MQD-1222 como base empírica decorre da paridade estrita entre as fontes anotadoras que ele garante. Frases sem maioria válida em qualquer um dos grupos são descartadas, o que implica a perda de 241 frases em relação ao corpus randomizado (16,5% do MQD-1463). Essa perda é o custo do desenho: a metodologia proposta exige que a comparação entre fontes opere sobre as mesmas instâncias, e instâncias sem rótulo consolidado em um dos grupos não permitem comparação pareada. A volumetria final de 1.222 frases preserva a paridade estrutural entre os grupos masculino e feminino, condição necessária para a interpretação dos resultados do Capítulo VI.

IV.2 Conjuntos de dados sintéticos (SynSA-XX)

O método de geração SynSA foi projetado para isolar o efeito da taxa de concordância anotativa sobre o comportamento dos modelos. Doze conjuntos independentes foram gerados, variando apenas o parâmetro γ (taxa de concordância nominal), com valores $\gamma \in \{0{,}50;\ 0{,}55;\ 0{,}60;\ 0{,}65;\ 0{,}70;\ 0{,}75;\ 0{,}80;\ 0{,}85;\ 0{,}90;\ 0{,}95;\ 0{,}97;\ 0{,}99\}$ (SynSA-50 a SynSA-99).

O número de instâncias, a distribuição marginal entre classes, a estrutura textual, os hiperparâmetros e o procedimento de validação foram mantidos constantes, o que permite interpretar as diferenças sistemáticas observadas entre cenários como associadas à variação de γ. Para cada processo pareado, os classificadores são treinados com sementes fixas, sobre os mesmos textos e as mesmas partições de validação cruzada, variando entre as fontes apenas os rótulos de supervisão; o Capítulo V formaliza essa metodologia. Esse desenho mantém constantes as condições de treinamento entre os membros de cada par, permitindo examinar a resposta dos classificadores às diferenças entre os vetores de rótulos. A interpretação de $\Delta\kappa$ permanece condicionada aos dados gerados, às configurações dos modelos e às partições adotadas, com a incerteza amostral avaliada na Seção VI.1.8.

A estratégia complementa a instanciação empírica em um eixo específico: enquanto o MQD-1222 oferece um único valor de κ_{anot} observado em condições reais, o SynSA abrange o espectro da escala de concordância em incrementos controlados. Essa cobertura paramétrica possibilita duas análises que a instanciação empírica, isoladamente, não permite: (i) a identificação de cenários de concordância nos quais a amplificação aumenta ou diminui e (ii) a comparação entre classificadores em função do nível de concordância inicial, o que revela quais são mais sensíveis à heterogeneidade dos rótulos de supervisão.

IV.2.1 Construção dos vetores de rótulos

Cada instância sintética recebe dois rótulos, y_A e y_B, um para cada fonte de rótulos, equivalentes aos vetores de mesmo nome do corpus empírico (Capítulo V). Diferentemente do MQD-1222, esses vetores não resultam de votação: o Algoritmo 1 os gera já consolidados, com um único rótulo por instância em cada vetor e paridade estrutural garantida por construção. Assim, as duas instanciações oferecem à metodologia a mesma estrutura de dados. Elas diferem na origem dos rótulos (votação humana no MQD-1222 e geração paramétrica no SynSA) e na natureza dos textos (frases reais em português brasileiro e sequências sintéticas neutras, Seção IV.2.2).

Para cada valor de γ, construiu-se um conjunto de pares de rótulos (y_A, y_B) com três propriedades asseguradas pela construção: (i) distribuição balanceada entre as três classes, com $N/3$ instâncias por classe em cada fonte; (ii) proporção global de concordância igual à taxa efetiva

$\gamma_{ef} = \text{round}(\gamma \cdot N)/N$, que difere do valor nominal em no máximo $1/(2N)$ devido ao arredondamento da Equação IV.2; e (iii) discordâncias distribuídas de forma balanceada entre as classes, preservando as distribuições marginais e evitando que a divergência se concentre em regiões específicas do espaço das classes.

Cada conjunto sintético contém $N = 999$ instâncias, distribuídas em 333 por classe. O número de instâncias concordantes é dado pela Equação IV.2, e o de discordantes pela Equação IV.3:

$$N_{\text{conc}} = \text{round}(\gamma \cdot N), \tag{IV.2}$$

$$N_{\text{disc}} = N - N_{\text{conc}}. \tag{IV.3}$$

A atribuição dos rótulos a partir de N_{conc} e N_{disc} segue o procedimento formalizado em Carneiro et al. [2025], uma publicação anterior do mesmo programa de pesquisa (Seção I.2), adaptado no Algoritmo 1. As N_{conc} instâncias concordantes recebem rótulos idênticos para ambas as fontes, distribuídos uniformemente entre as três classes; as N_{disc} instâncias discordantes recebem rótulos distintos, com atribuição cíclica que preserva a distribuição marginal uniforme de $N/3$ instâncias por classe em cada fonte.

IV.2.2 Geração dos dados sintéticos

Os textos de cada cenário sintético foram gerados como sequências aleatórias de *tokens placeholder* na forma word_i, com i sorteado uniformemente em $[1, 500]$, resultando em um vocabulário de 500 termos distintos. O comprimento de cada texto varia uniformemente entre 20 e 100 *tokens*. A combinação de um vocabulário moderado e comprimentos variáveis produz documentos com distribuições TF-IDF não triviais, evitando degenerações na representação vetorial sem introduzir associações semânticas entre *tokens* e classes.

Os textos são semanticamente neutros e estatisticamente independentes dos rótulos: nenhuma informação lexical se correlaciona com as classes. Os modelos treinados nesse ambiente não aprendem padrões linguísticos de sentimento, respondendo apenas à estrutura de supervisão dos rótulos. Como o vocabulário, a distribuição de comprimentos e a ausência de correlação léxico-semântica são mantidos constantes entre todos os valores de γ, qualquer diferença em $\hat{y}_{\text{A}}$ e $\hat{y}_{\text{B}}$ é atribuível ao cenário de concordância entre as fontes.

A escolha de $N = 999$ atende a dois critérios. O primeiro é a divisibilidade exata por três, que garante distribuições marginais perfeitamente balanceadas e evita arredondamentos que distorceriam o componente p_e do κ de Cohen. O segundo é a estabilidade estatística: com $N \approx 10^3$ e classes balanceadas, o intervalo de confiança *bootstrap* do κ permanece estreito o suficiente para

Algoritmo 1: Geração de conjunto de dados sintético para AS, adaptado de Carneiro et al. [2025].

Entrada: N ; // número total de instâncias (múltiplo de 3)
Entrada: $\gamma \in [0, 1]$; // taxa de concordância nominal alvo
Entrada: $L_{\min}, L_{\max}$; // comprimentos mínimo e máximo dos textos
Saída: Conjunto de dados $D = \{(t_i, y_{\mathrm{A},i}, y_{\mathrm{B},i})\}_{i=1}^{N}$
$C \leftarrow \{\text{negativa}, \text{neutra}, \text{positiva}\}$; // classes de sentimento
$n_c \leftarrow N/3$; // instâncias por classe
$y_{\mathrm{A}}, y_{\mathrm{B}} \leftarrow \textsc{GerarParesBalanceados}(C, n_c, \gamma)$; // rótulos balanceados e parcialmente concordantes
$T \leftarrow \textsc{GerarTextosSinteticos}(N, L_{\min}, L_{\max})$; // entradas textuais sintéticas
$D \leftarrow \textsc{MontarDataset}(T, y_{\mathrm{A}}, y_{\mathrm{B}})$; // triplas: texto, rótulo da fonte A, rótulo da fonte B
$\textsc{Embaralhar}(D)$; // aleatorizar ordem
return D

não comprometer a leitura ordinal do coeficiente, com largura que varia de 0,0181 em SynSA-99 a 0,0945 em SynSA-50. Para um mesmo N, o alargamento acompanha o afastamento de κ em relação à unidade, um comportamento característico do estimador. Esse valor de N se aproxima do utilizado na fase empírica ($N = 1.222$, largura de 0,0610), o que evita que os efeitos do tamanho amostral confundam a comparação entre as instanciações.

Apresentados os dados, o Capítulo V descreve a metodologia proposta, composta por três módulos que medem a concordância entre as fontes de rótulos, a concordância entre as predições de modelos treinados de forma pareada e a diferença entre as duas. Os resultados obtidos com o MQD-1222 e com os conjuntos SynSA-XX são apresentados no Capítulo VI.

Capítulo V Metodologia

Este capítulo apresenta a Metodologia de Análise de Divergências Anotativas (MADA), composta por três módulos que detectam e quantificam a amplificação dessas divergências em modelos supervisionados de classificação textual. A Seção V.1 apresenta uma visão geral da metodologia. As Seções V.2 a V.4 detalham os três módulos sequenciais: a concordância entre as fontes de rótulos (linha de base), o treinamento pareado com a concordância entre as predições e a quantificação da amplificação. As escolhas com que a metodologia é executada neste estudo, incluindo a reamostragem e o critério de significância, estão reunidas na Seção VI.1.

V.1 Visão geral da MADA

Zhao et al. [2017] comparam a associação entre gênero e categorias de saída nos dados de treinamento e nas predições dos modelos. A MADA aplica essa lógica à divergência entre duas fontes de rótulos: mede a concordância entre as fontes antes do treinamento e a concordância entre as predições após ele. A pergunta específica da metodologia é como o aprendizado supervisionado transforma a divergência presente nos rótulos ao longo da generalização indutiva.

Quando a divergência está estratificada por um atributo demográfico dos anotadores, como o gênero, a amplificação corresponde a uma diferença entre grupos que cresce das anotações para as predições. Como discutido na Seção II.3, essa amplificação não demonstra, por si só, prejuízo a um grupo: sua leitura como viés de gênero depende do contexto de aplicação. A Figura V.1 apresenta o fluxo dos três módulos sequenciais que compõem a proposta metodológica, cuja notação (κ_{anot}, κ_{pred} e $\Delta\kappa$) é a definida na Seção II.4.

V.2 Módulo I: Concordância entre as fontes anotadoras

O Módulo I estima a concordância inicial entre duas fontes anotadoras que rotulam um mesmo conjunto de instâncias textuais. A saída do módulo é o coeficiente κ_{anot} e suas medidas de incerteza, que estabelecem o referencial quantitativo com o qual os Módulos II e III são comparados.

O módulo recebe como entrada os vetores y_A e y_B, contendo os rótulos consolidados das duas fontes anotadoras (fontes A e B) sobre as mesmas N instâncias com C classes possíveis. Os vetores podem resultar de uma votação entre anotadores ou ser gerados já consolidados; as duas formas

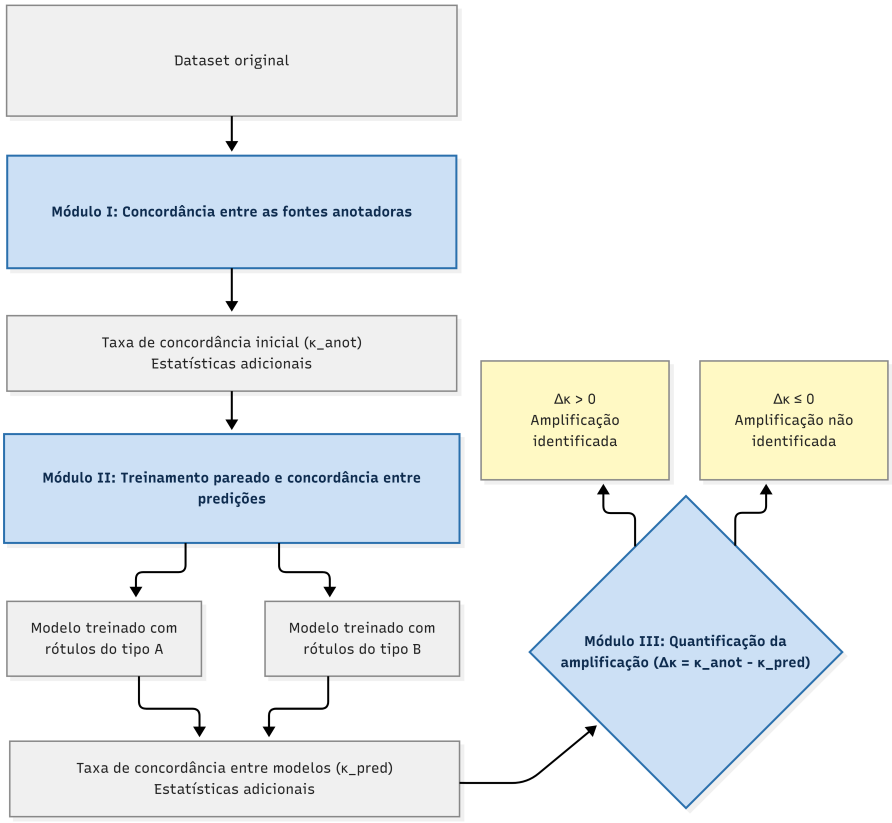


Figura V.1: Diagrama de fluxo da MADA. O fluxo é organizado em três módulos sequenciais: o Módulo I estima a concordância entre as fontes anotadoras (κ_{anot}); o Módulo II realiza o treinamento pareado de dois modelos com rótulos provenientes de fontes distintas e estima a concordância entre suas predições (κ_{pred}); o Módulo III computa $\Delta\kappa = \kappa_{\text{anot}} - \kappa_{\text{pred}}$ e classifica o resultado. A amplificação é identificada quando o limite inferior do intervalo de confiança de $\Delta\kappa$ é positivo; um intervalo que inclui zero indica resultado inconclusivo quanto à direção da alteração, e um limite superior negativo, convergência induzida.

adotadas neste estudo estão descritas nas Seções VI.1.2 e VI.1.3. A escolha do κ de Cohen, em vez do α de Krippendorff, decorre da comparação entre exatamente duas fontes consolidadas, conforme discutido na Seção II.2.

A interpretação ordinal de κ segue a escala de Landis and Koch [1977] (Tabela II.1). A escala cumpre uma dupla função: além de ser um instrumento descritivo, opera no Módulo III, oferecendo um parâmetro comparativo com base no número de faixas percorridas entre κ_{anot} e κ_{pred}. A caracterização da concordância inicial é complementada pelas estatísticas χ^2 de independência e V de Cramér, definidas na Seção II.2. Juntas, as três métricas caracterizam a relação entre as fontes em três planos: equivalência exata corrigida pelo acaso (κ), significância estatística da associação (χ^2) e magnitude normalizada da associação (V de Cramér).

A incerteza da estimativa de κ_{anot} é avaliada por meio de reamostragem *bootstrap* com B iterações (valor na Tabela VI.1). A unidade de reamostragem é a instância: em cada iteração, os N pares (y_A, y_B) são sorteados com reposição, o que preserva o pareamento, e κ é recalculado. Os percentis 2,5 e 97,5 da distribuição resultante fornecem o intervalo de confiança de 95%. Esse

intervalo descreve a variação de κ_{anot} associada à amostra de instâncias; a variação associada à amostra de anotadores de cada fonte fica fora de seu alcance.

A saída do Módulo I é composta por quatro indicadores: o coeficiente κ_{anot}, seu intervalo de confiança de 95%, a estatística χ^2 com seu p-valor e o coeficiente V de Cramér. A matriz de contingência entre y_A e y_B é preservada para a análise qualitativa dos padrões de discordância, fora da métrica do módulo.

V.3 Módulo II: Treinamento pareado e concordância entre predições

O Módulo II treina pares de classificadores sobre os mesmos textos, diferenciados exclusivamente pela fonte dos rótulos de supervisão, e estima a concordância κ_{pred} entre as predições resultantes. A saída do módulo é o κ_{pred} para cada classificador, com o desvio padrão entre *folds* como medida de estabilidade. O estimador por *fold* é apresentado na Seção VI.1.7.

Essa etapa permite avaliar se as divergências originalmente presentes nas fontes de anotação são preservadas, atenuadas ou amplificadas após o processo de aprendizado supervisionado. Como os pares de modelos compartilham os mesmos textos, a mesma representação vetorial, as mesmas partições de validação e o mesmo algoritmo de classificação, eventuais diferenças nas predições podem ser atribuídas à fonte anotadora utilizada no treinamento. Assim, o κ_{pred} mede a estabilidade da decisão algorítmica diante de rótulos consolidados provenientes de fontes distintas. O desempenho preditivo isolado de cada classificador não integra essa medida.

V.3.1 Paridade entre treinamentos

Para cada classificador, são realizados dois treinamentos pareados: o Treinamento A ajusta o classificador com y_A como vetor de supervisão, e o Treinamento B o ajusta com y_B. A paridade entre os dois é estrita: mesma representação textual, mesmos hiperparâmetros, mesma semente aleatória e mesmos *folds* de validação cruzada.

Esse desenho controla diferenças de configuração, particionamento e semente aleatória entre os membros do par, mantendo a fonte dos rótulos como a condição que varia entre os treinamentos. Assim, as diferenças entre as predições caracterizam a resposta de cada configuração de classificador à substituição de y_A por y_B nas condições experimentais adotadas. Esse controle não estima a variabilidade dos resultados diante de outras sementes ou partições de treinamento. A incerteza associada à reamostragem das instâncias é tratada na Seção VI.1.8.

V.3.2 Ajuste da representação e validação cruzada

O Módulo II não impõe uma representação textual específica: qualquer representação pode ser empregada, desde que aplicada de forma idêntica aos dois treinamentos do par. Os classificadores

avaliados neste estudo são apresentados na Seção VI.1.6. O que se formaliza aqui é o procedimento de ajuste e validação, independente da representação escolhida.

Em cada *fold* da validação cruzada, a representação é ajustada exclusivamente sobre os dados de treino daquele *fold* e aplicada, sem reajuste, ao conjunto de teste. Esse procedimento garante que a representação do conjunto de teste não incorpore informações distribucionais de instâncias não observadas durante o treinamento, seguindo a prática padrão de avaliação com validação cruzada [Cawley and Talbot, 2010]. Os dois modelos do par, treinados sobre y_A e y_B, compartilham a mesma representação, ajustada sobre o mesmo conjunto de treino de cada *fold*. Essa simetria preserva a comparabilidade pareada: qualquer diferença na concordância entre as predições é atribuível às diferenças entre os vetores de rótulos, uma vez que as representações são idênticas.

A validação cruzada é estratificada em K *folds*, com a estratificação computada sobre y_A e as mesmas divisões aplicadas ao treinamento sobre y_B. A partição é fixa e reaplicada integralmente ao treinamento sobre y_B, o que preserva a paridade exigida pelo desenho (Seção V.3.1). A preservação das proporções de classe nos *folds* é garantida apenas para y_A (Seção II.6). A semente aleatória é fixada na inicialização do particionador. Em cada *fold* k, o modelo é ajustado sobre as $K-1$ partições restantes e gera predições sobre a partição retida. Ao término dos K *folds*, as predições *out-of-fold* são concatenadas em vetores $\hat{y}_A$ e $\hat{y}_B$ que cobrem as N instâncias exatamente uma vez. Os valores adotados para K, a semente e a representação estão na Seção VI.1.

V.4 Módulo III: Quantificação da amplificação

O Módulo III compara as estimativas produzidas pelos Módulos I e II e quantifica a amplificação, entendida como o caso em que a concordância entre as predições dos modelos, medida por κ_{pred}, é inferior à concordância entre as fontes, medida por κ_{anot}. A comparação entre κ_{anot} e κ_{pred} permite verificar se o processo de aprendizado supervisionado reduziu ou ampliou a distância originalmente observada entre as fontes de anotação. O Módulo III atua como etapa integradora da MADA, convertendo essa comparação em uma medida de propagação de divergência anotativa; os três cenários interpretativos possíveis são detalhados na Seção V.4.1.

V.4.1 Definição de $\Delta\kappa$

A amplificação é definida pela diferença entre a concordância inicial entre as fontes de rótulos e a concordância entre as predições dos modelos pareados:

$$\Delta\kappa \;=\; \kappa_{\text{anot}} \;-\; \kappa_{\text{pred}}. \tag{V.1}$$

A diferença $\Delta\kappa$ admite três interpretações descritivas: valores positivos indicam menor

concordância entre as predições do que entre as fontes de rótulos; valores negativos indicam maior concordância entre as predições; e o valor zero corresponde à igualdade entre as duas medidas. A decisão inferencial considera o intervalo de confiança dessa diferença. Identifica-se evidência de amplificação quando o limite inferior do intervalo é estritamente positivo e evidência de convergência quando o limite superior é estritamente negativo. Quando o intervalo inclui zero, o resultado é inconclusivo quanto à direção da alteração, não permitindo afirmar amplificação, convergência ou preservação. O procedimento de estimação desse intervalo é apresentado na Seção VI.1.8.

V.4.2 Deslocamento entre categorias como recurso descritivo auxiliar

O valor numérico de $\Delta\kappa$ não captura inteiramente o impacto qualitativo da variação de concordância entre grupos de anotadores e modelos de classificação. Dois experimentos podem apresentar magnitudes de $\Delta\kappa$ semelhantes e, ainda assim, produzir deslocamentos interpretativos distintos, caso os valores de κ_{anot} e κ_{pred} se situem em categorias diferentes da escala de Landis and Koch [1977]. Para tornar esse contraste analiticamente visível, este trabalho adota, como recurso descritivo auxiliar, o conceito de *deslocamento entre categorias*: o número de fronteiras entre categorias consecutivas da escala de referência cruzadas entre a categoria ocupada por κ_{anot} e a ocupada por κ_{pred}.

O deslocamento entre categorias opera em quatro graus. Denomina-se *nulo* quando κ_{anot} e κ_{pred} pertencem à mesma categoria; *restrito* quando uma única fronteira é cruzada; *amplo* quando duas fronteiras são cruzadas; e *acentuado* quando três ou mais fronteiras são cruzadas. Essas denominações não derivam da nomenclatura de Landis and Koch e não a substituem; referem-se à extensão do deslocamento sobre essa escala, independentemente do valor absoluto de κ em cada um dos dois estados. As limitações inerentes a esse recurso são reconhecidas: as fronteiras da escala de referência são convencionais, não empíricas, e cruzamentos em regiões distintas da escala têm peso qualitativo diferente, aspecto que é considerado na interpretação dos resultados (Capítulo VI). O deslocamento entre categorias complementa $\Delta\kappa$ sem substituí-lo, funcionando como enquadramento narrativo que facilita a comparação entre experimentos com perfis de variação heterogêneos. Esse deslocamento não define a direção da diferença pontual, determinada pelo sinal de $\Delta\kappa$, nem constitui um critério de significância estatística. A análise *bootstrap* complementar é descrita separadamente na Seção VI.1.8.

Definidos os três módulos, o Capítulo VI reúne as configurações experimentais (número de *folds*, semente, representação textual, classificadores e número de iterações do *bootstrap*) e relata os resultados da aplicação da MADA ao corpus empírico e aos cenários sintéticos. Os critérios de decisão sobre $\Delta\kappa$ (Seção V.4.1) são aplicados a cada combinação de classificador e conjunto de dados.

Capítulo VI Experimentos

Este capítulo reúne as configurações experimentais e reporta os resultados das duas instanciações da MADA: a empírica, sobre o corpus MQD-1222, e a sintética, sobre os doze cenários propostos (SynSA-50 a SynSA-99). A Seção VI.1 apresenta as configurações experimentais; a Seção VI.2 relata os achados empíricos; a Seção VI.3 apresenta os resultados sintéticos e a Seção VI.4 confronta as duas instanciações, posicionando o caso empírico no espaço de comportamentos descrito sob controle paramétrico. O procedimento experimental é o descrito na Seção VI.1 e é idêntico nas duas instanciações, que diferem apenas pela natureza dos dados de entrada.

VI.1 Configurações experimentais

Esta seção reúne as escolhas com as quais a MADA foi executada neste estudo. Os módulos do Capítulo V são válidos para quaisquer duas fontes de rótulos, representações textuais e classificadores. As decisões apresentadas aqui são, ao contrário, parâmetros de instanciação: a variável que define as fontes, os dados sobre os quais a metodologia é aplicada, a representação dos textos, o esquema de validação cruzada, os algoritmos com seus hiperparâmetros e a reamostragem usada na inferência. Alterar qualquer uma delas define outro experimento sobre a mesma metodologia.

A Seção VI.1.1 apresenta a variável estratificadora, e as Seções VI.1.2 e VI.1.3 descrevem as instanciações empírica e sintética. As Seções VI.1.4, VI.1.5 e VI.1.6 tratam da representação textual, da validação cruzada e dos classificadores. A Seção VI.1.7 define o cálculo de κ_{pred}, e a Seção VI.1.8 apresenta a reamostragem e o critério de significância de $\Delta\kappa$. A Seção VI.1.9 apresenta a estratégia de integração entre as instanciações. A Tabela VI.1 consolida os valores adotados. Os resultados das Seções VI.2 a VI.4 foram obtidos com esses valores, com hiperparâmetros padrão do *scikit-learn*, exceto onde indicado.

Tabela VI.1: Configuração experimental consolidada da representação textual, da validação cruzada, dos algoritmos supervisionados e do procedimento de *bootstrap*.

Componente	Parâmetro	Valor
Representação textual por TF-IDF		
	Faixa de n-gramas	$(1, 3)$
	Máximo de atributos	10.000
	Frequência mínima de documento	`min_df` $= 3$
	Frequência máxima de documento	`max_df` $= 0{,}90$
	Remoção de acentos	Não (`None`)
	Ponderação sublinear	Sim
	Normalização	ℓ_2
	Stopwords	Lista definida no código; ver Apêndice C.2
Validação cruzada		
	Número de *folds* (K)	5
	Estratificação	Por $\mathbf{y}_A$
	Semente aleatória	Fixa, para reprodutibilidade (42)
Algoritmos supervisionados, com hiperparâmetros padrão do *scikit-learn*, exceto onde indicado		
SVM	Kernel	Linear
	C, regularização	1,0
	Semente aleatória	Fixa (42)
Naive Bayes	Distribuição	Multinomial
	α, suavização	1,0
Random Forest	Número de árvores	100
	Critério de divisão	Gini
	Profundidade máxima	Sem limite
	Semente aleatória	Fixa (42)
Logistic Regression	Penalização	ℓ_2
	C, regularização inversa	1,0
	Solver	`lbfgs`
	Máximo de iterações	1.000
Bootstrap		
	Iterações	10.000
	Intervalo de confiança	95%

Notas. TF-IDF corresponde a *Term Frequency-Inverse Document Frequency*. SVM corresponde a *Support Vector Machine*. A variável $\mathbf{y}_A$ representa o vetor de rótulos utilizado para estratificação das partições. Os parâmetros do *bootstrap* aplicam-se aos Módulos I e III. Diferem do padrão do *scikit-learn*: *kernel* linear (SVM), máximo de 1.000 iterações (LR) e semente fixa (SVM e RF).

VI.1.1 Variável estratificadora

A variável adotada para estratificar as fontes anotadoras é o gênero autodeclarado, com quatro votos por frase em cada grupo: y_A recebe o rótulo consolidado do grupo masculino e y_B o do grupo feminino, ambos obtidos pelo procedimento descrito na Seção VI.1.2. A escolha do gênero autodeclarado como variável estratificadora foi apresentada na Introdução, e a Seção II.3 delimita seu alcance. O gênero funciona, nesse desenho, como uma instância de característica binária que permite parear duas fontes anotadoras, sobre a qual a metodologia proposta opera. A escolha reflete a relevância social e disponibilidade de dados, sem demonstrar que o efeito medido seja exclusivo ou mais acentuado para essa variável, ressalva retomada na Seção VII.2. Os estudos em língua portuguesa examinados estão na Seção III.5, e o caráter binário do critério, instrumental ao desenho experimental, é discutido na Seção VII.4.

O instrumento de coleta disponibilizou apenas as categorias masculino e feminino. Assim, a estratificação utilizada representa as categorias registradas nesse instrumento e não abrange a diversidade das identidades de gênero. Essa restrição delimita a população representada e o alcance das comparações, sem constituir uma proposta de classificação geral de gênero.

VI.1.2 Instanciação empírica

A consolidação dos rótulos individuais segue a regra da classe estritamente mais votada entre quatro votos, descrita na Seção IV.1.2. Das 1.463 frases submetidas à anotação, 241 foram excluídas por não admitirem classe vencedora em ao menos um dos grupos (70 no grupo masculino e 190 no feminino, com 19 comuns a ambos), o que resulta no MQD-1222, que conta com 1.222 frases, com y_A e y_B definidos sobre as mesmas instâncias. A exclusão não incide igualmente sobre os dois grupos (Tabela IV.1), assimetria discutida na Seção VII.2, e o κ_{anot} da Seção VI.2.1 refere-se ao subconjunto retido.

VI.1.3 Instanciação sintética

A instanciação sintética é conduzida sobre o SynSA, gerado pelo método descrito no Capítulo IV e composto por doze conjuntos paramétricos (SynSA-50 a SynSA-99) com taxas de concordância nominal $\gamma \in \{50, 55, 60, 65, 70, 75, 80, 85, 90, 95, 97, 99\}\%$. Cada conjunto contém $N = 999$ instâncias, com distribuição perfeitamente balanceada entre as três classes (333 instâncias por classe em cada fonte). A construção dos vetores de rótulos e a geração dos textos sintéticos seguem o algoritmo descrito no Capítulo IV, com a semente aleatória fixada em 42, a mesma da instanciação empírica, aplicada à geração dos conjuntos, ao particionamento da validação cruzada e ao procedimento *bootstrap*.

A finalidade da instanciação sintética é isolar o efeito da taxa de concordância anotativa sobre o comportamento dos modelos. Como os textos são gerados como sequências aleatórias de *placeholders*, sem correlação semântica com os rótulos, qualquer diferença observada nas predições é atribuída à estrutura de supervisão e não ao conteúdo lexical. Isso permite caracterizar o comportamento da MADA em função de um único parâmetro controlado (γ), mantendo todos os demais aspectos da metodologia idênticos à instanciação empírica.

O procedimento de representação, validação cruzada, *bootstrap* e cálculo das métricas é integralmente idêntico ao adotado na instanciação empírica. A lista de *stopwords* da Tabela VI.1 não atua sobre textos gerados artificialmente, mas manter todos os parâmetros constantes garante que qualquer diferença observada entre as duas instanciações seja atribuível à natureza dos dados, com o procedimento mantido fixo.

VI.1.4 Representação textual

Nas duas instanciações deste estudo, a representação textual adotada é o TF-IDF. A opção por uma representação deliberadamente não contextual, dependente apenas da distribuição lexical do corpus de treinamento, permite atribuir qualquer amplificação ao aprendizado sobre os rótulos, sem a interferência de vieses latentes que modelos baseados em *transformers* incorporam no pré-treinamento sobre grandes corpora [Jentzsch and Turan, 2022; Shah et al., 2020]. Essa escolha delimita o escopo das conclusões às arquiteturas avaliadas, questão retomada como limitação na Seção VII.2; a extensão da MADA a outras representações, incluindo modelos baseados em *transformers*, é discutida como direção de trabalho futuro na Seção VII.4.

O vetorizador considera n-gramas de tamanho de 1 a 3, no máximo 10.000 atributos, frequência mínima de documento igual a 3 e máxima de 0,90, ponderação sublinear e normalização ℓ_2, sem remoção de acentos e com a lista de *stopwords* definida no código (Tabela VI.1). As versões das bibliotecas utilizadas na execução dos *notebooks* e a lista de *stopwords* são apresentadas no Apêndice C.

VI.1.5 Validação cruzada

A avaliação utiliza validação cruzada estratificada com $K = 5$ *folds* (em que a estratificação é computada sobre y_A) e as mesmas partições são aplicadas ao treinamento sobre y_B. A semente do particionador é fixa (42) nas duas instanciações. O procedimento de ajuste e de validação, que independe desses valores, está descrito na Seção V.3.2.

Com $K = 5$, cada partição retida contém cerca de 20% das instâncias: aproximadamente 244 no MQD-1222 e 200 em cada cenário sintético. As predições *out-of-fold* de cada modelo são concatenadas em vetores $\hat{y}_A$ e $\hat{y}_B$ que cobrem as instâncias exatamente uma vez, e é sobre esses

vetores que se calcula a matriz de contingência global e o V de Cramér (Seção VI.1.7).

VI.1.6 Classificadores avaliados

Quatro classificadores são avaliados, utilizando os hiperparâmetros padrão do *scikit-learn*, exceto onde indicado (Tabela VI.1): *Support Vector Machine* (SVM), *Naive Bayes* (NB) multinomial, *Random Forest* (RF) e *Logistic Regression* (LR) com regularização ℓ_2. A escolha abrange paradigmas indutivos distintos: margem linear, modelo probabilístico generativo, comitê de árvores e modelo linear discriminativo, o que permite verificar se a amplificação é uma propriedade de uma família específica de algoritmos ou um comportamento recorrente entre elas.

No caso do SVM, adotou-se a implementação *SVC* com *kernel* linear, parâmetro de regularização $C = 1{,}0$ e semente fixa. Assim, o classificador é tratado neste estudo como um modelo de margem linear aplicado à representação TF-IDF dos textos. Essa escolha preserva a comparabilidade com a Regressão Logística, que também é linear no espaço de atributos, ao mesmo tempo em que permite contrastar esses modelos com o Naive Bayes Multinomial e o Random Forest.

VI.1.7 Cálculo de κ_{pred}

A concordância entre as predições dos dois modelos do par é estimada por *fold*. Para cada *fold* k, computa-se:

$$\kappa^{(k)} = \kappa\left(\hat{y}_A^{(k)}, \hat{y}_B^{(k)}\right), \quad k = 1, \ldots, K. \tag{VI.1}$$

O valor reportado é a média aritmética dos K valores de $\kappa^{(k)}$:

$$\kappa_{\text{pred}} = \frac{1}{K}\sum_{k=1}^{K} \kappa^{(k)}. \tag{VI.2}$$

Essa agregação por *fold* permite reportar o desvio padrão dos K valores como medida de estabilidade entre *folds*, componente central da saída do Módulo II.

O V de Cramér, por sua vez, é calculado sobre a matriz de contingência da concatenação global das predições e não por *fold*: a granularidade de cada *fold* individual produziria células esparsas na fronteira entre classes, sobretudo na classe neutra, tornando a estimativa de V instável. A concatenação global fornece uma medida da magnitude da associação, independente do particionamento e complementar ao κ_{pred}.

VI.1.8 Significância estatística

A incerteza de $\Delta\kappa$ foi examinada por meio de *bootstrap* percentílico, com $B = 10.000$ reamostragens com reposição e intervalo de confiança de 95% [Efron and Tibshirani, 1994].

Em cada iteração, as predições *out-of-fold* foram reamostradas separadamente dentro de cada um dos K *folds*, preservando o tamanho original das partições e o pareamento entre as predições dos modelos. O coeficiente κ foi recalculado em cada fold, e a concordância preditiva foi obtida pela média aritmética desses valores, conforme a Seção VI.1.7.

Denotando por $\kappa_{\text{pred}}^{*(b)}$ a média dos coeficientes na reamostragem b, a estatística utilizada foi:

$$\Delta\kappa^{*(b)} = \kappa_{\text{anot,obs}} - \frac{1}{K}\sum_{k=1}^{K}\kappa^{*(b,k)}.$$

Os percentis 2,5 e 97,5 da distribuição resultante fornecem o intervalo *bootstrap* de 95% de $\Delta\kappa$. Um limite inferior estritamente positivo constitui evidência de amplificação segundo o critério inferencial adotado.

Cada execução utiliza um gerador de números aleatórios inicializado com a semente declarada no ambiente experimental. O procedimento mantém fixo o valor observado de κ_{anot} e condiciona a inferência às predições e às partições observadas, sem incorporar a variabilidade decorrente de novos treinamentos, outras partições de validação cruzada ou da amostragem dos anotadores.

VI.1.9 Estratégia de integração entre as instanciações

A aplicação da MADA em contexto empírico e sintético tem caráter complementar. A instanciação empírica estabelece se o fenômeno de amplificação ocorre em condições reais de anotação, com toda a complexidade lexical e semântica inerente ao processo. A instanciação sintética caracteriza o comportamento dessa amplificação sob controle paramétrico, revelando como a taxa de concordância inicial e a arquitetura do classificador modulam a magnitude da amplificação e o deslocamento entre categorias. As duas instanciações são analiticamente independentes. Cada uma pode ser executada e interpretada de forma autônoma, e a validade dos resultados de uma não depende dos resultados da outra.

A estratégia de integração opera em dois movimentos. O primeiro é a ancoragem quantitativa: o valor empírico de κ_{anot} está posicionado entre os valores de κ_{anot} observados nos cenários sintéticos (e não entre as taxas nominais γ), o que identifica o cenário paramétrico mais próximo do caso real. Essa abordagem permite avaliar se a magnitude empírica de $\Delta\kappa$ é compatível com o comportamento esperado para o nível de concordância observado.

O segundo é a análise de propensão diferencial: a comparação entre classificadores ao longo dos cenários sintéticos revela quais arquiteturas são mais sensíveis à heterogeneidade anotativa, e a consistência ou inconsistência desse padrão no caso empírico fornece evidências adicionais sobre a natureza do comportamento investigado.

A paridade entre as duas instanciações é uma condição necessária para a integração. Diferenças

sistemáticas entre os resultados das duas instanciações são interpretadas à luz da natureza dos dados (textos reais contra textos sintéticos semanticamente neutros) e da variação controlada do parâmetro γ.

A Seção VI.2 relata os resultados empíricos, a Seção VI.3 os resultados sintéticos e a Seção VI.4 a integração entre eles.

VI.2 Resultados empíricos

A instanciação empírica aplicou a MADA (Capítulo V), com as configurações da Seção VI.1, ao corpus MQD-1222, anotado por dois grupos segmentados por gênero autodeclarado. O objetivo foi verificar, em condições reais de anotação, se as divergências anotativas associadas ao gênero do anotador foram preservadas, atenuadas ou amplificadas pelos modelos treinados sobre os rótulos de cada grupo.

Os resultados empíricos são apresentados com base na sequência analítica definida no Capítulo V. Inicialmente, reporta-se a concordância entre as fontes anotadoras, estimada no Módulo I a partir dos rótulos majoritários masculino e feminino. Em seguida, apresentam-se os resultados do Módulo II, no qual pares de classificadores são treinados sobre os mesmos textos, diferenciando-se apenas pela fonte anotadora utilizada. Por fim, o Módulo III integra essas duas etapas ao calcular a amplificação de divergência ($\Delta\kappa$), permitindo avaliar a divergência preditiva após o aprendizado supervisionado.

VI.2.1 Módulo I: Concordância entre as fontes anotadoras

O grupo masculino atribuiu 450 rótulos negativos, 291 neutros e 481 positivos; o feminino, 446 negativos, 365 neutros e 411 positivos (Figura VI.1). A assimetria mais marcada está nos rótulos neutros: 365 contra 291, valores que indicam uma maior concentração relativa do grupo feminino na classe neutra em comparação com o grupo masculino.

Os vetores majoritários $\mathbf{y}_A$ (grupo masculino) e $\mathbf{y}_B$ (grupo feminino) são a referência contra a qual os Módulos II e III são medidos. A concordância entre eles foi estimada pelo κ de Cohen [1960], com a estatística χ^2 e o V de Cramér como medidas auxiliares sobre a matriz de contingência (Seção V.2).

A Figura VI.2 apresenta essa matriz de contingência. A predominância das ocorrências ao longo da diagonal principal reflete um elevado grau de concordância entre os grupos. As maiores concentrações absolutas recaíram sobre as classes negativa e positiva, com 401 e 387 concordâncias diretas, respectivamente. A classe neutra apresentou a dispersão relativa mais acentuada quando se toma o grupo feminino como referência: dos 365 textos rotulados como neutros por ele, 245 (67,1%) receberam o mesmo rótulo do grupo masculino, 43 foram rotulados como negativos e 77

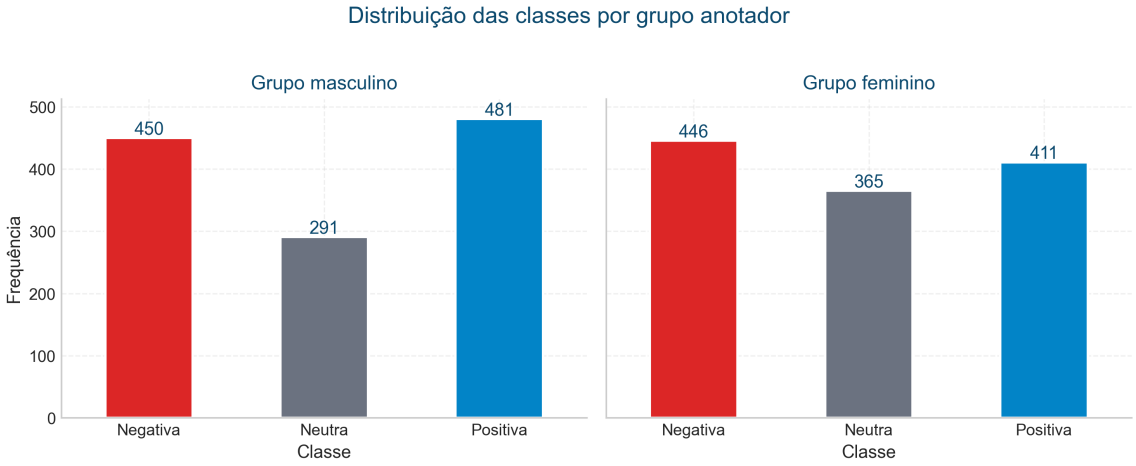


Figura VI.1: Distribuição das classes por grupo de anotadores no conjunto de dados MQD-1222. O grupo feminino atribuiu proporcionalmente mais rótulos neutros (365 contra 291) e menos rótulos positivos (411 contra 481), sugerindo maior concentração relativa em rótulos de polaridade atenuada.

como positivos. Tomando o grupo masculino como referência, a concordância por classe é de 89,1% (negativa), 84,2% (neutra) e 80,5% (positiva). A maior concentração fora da diagonal está nos 77 textos rotulados como positivos pelo grupo masculino e como neutros pelo grupo feminino, o que indica que a fronteira semântica entre neutralidade e positividade constituiu o principal ponto de ambiguidade entre os grupos.

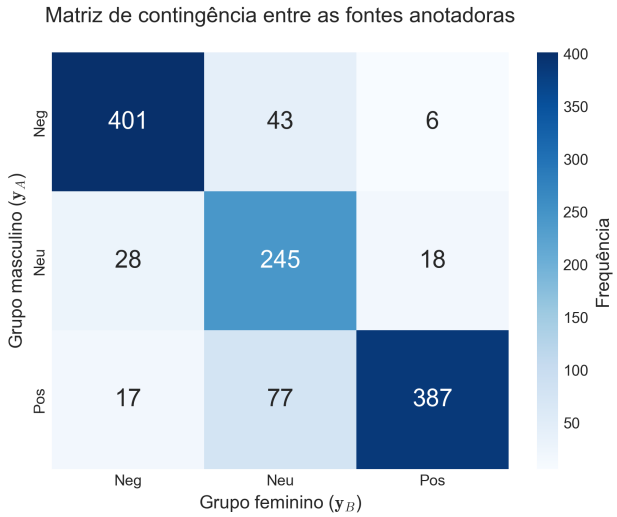


Figura VI.2: Matriz de contingência entre as anotações majoritárias dos grupos masculino e feminino no corpus MQD-1222. A intensidade de cor é proporcional à frequência absoluta. A concentração ao longo da diagonal principal sugere o elevado alinhamento direto entre os grupos.

O coeficiente obtido foi $\kappa_{\text{anot}} = 0{,}7664$, com Intervalo de Confiança (IC) de 95% igual a [0,7348; 0,7958], situando-se na faixa de concordância *substancial* segundo os critérios de Landis and Koch [1977]. Esse valor é a concordância entre as fontes anotadoras antes de qualquer etapa de modelagem e constitui a referência de comparação para os módulos subsequentes. A significância estatística da associação entre os grupos anotadores (masculino e feminino) foi confirmada pelo

teste qui-quadrado ($\chi^2 = 1441{,}03$, $p < 0{,}001$), e o coeficiente V de Cramér ($V_{\text{Cramér}} = 0{,}7679$), que indica uma associação de magnitude substancial entre as distribuições dos dois grupos.

VI.2.2 Módulo II: Treinamento pareado e concordância entre predições

A Figura VI.3 apresenta o κ_{pred} de cada algoritmo, calculado entre as predições dos dois treinamentos pareados e contrastado com o valor de referência κ_{anot}. Todos os quatro algoritmos reduziram a concordância entre os grupos comparados: SVM = 0,4776; NB = 0,4680; RF = 0,5019; LR = 0,5140. O desvio padrão entre *folds* foi de 0,0626 (SVM), 0,0861 (NB), 0,0650 (RF) e 0,0618 (LR). Os quatro valores situam-se na faixa *moderada* de Landis and Koch [1977], uma faixa interpretativa abaixo do $\kappa_{\text{anot}} = 0{,}7664$, classificado como substancial.

Qualquer redução de κ_{pred} em relação a κ_{anot} produz $\Delta\kappa > 0$. Sob condições de aprendizagem idênticas, isso significa que a diferença entre os vetores de rótulos está associada a uma divergência maior entre as decisões dos modelos. A escala de Landis and Koch [1977] acrescenta uma camada descritiva: quando a queda cruza o limiar entre duas faixas adjacentes, os modelos passam a concordar entre si em uma faixa diferente da ocupada pelas fontes anotadoras. Esse deslocamento qualifica a magnitude de $\Delta\kappa$, mas não integra o critério de identificação da amplificação, que depende do limite inferior do intervalo de confiança de $\Delta\kappa$ (Seção VI.1.8). Todos os resultados correspondem aos hiperparâmetros padrão da Tabela VI.1; a sensibilidade de $\Delta\kappa$ à variação de hiperparâmetros não foi avaliada neste estudo (Seção VII.2).

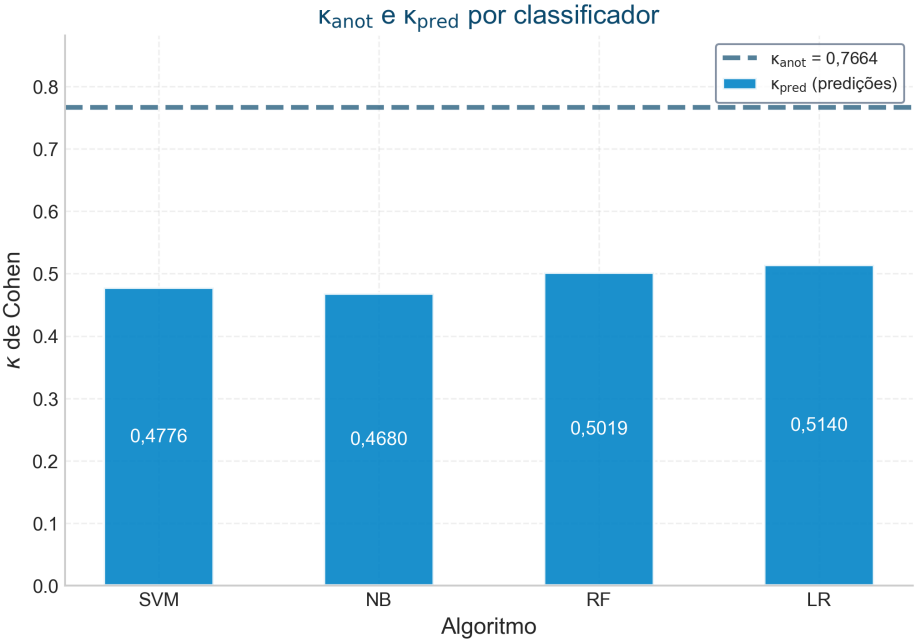


Figura VI.3: Comparação entre κ_{anot} e κ_{pred} por classificador, no corpus MQD-1222. A linha tracejada demarca o valor de referência κ_{anot}. Todos os modelos apresentaram redução sistemática da concordância após o treinamento supervisionado, com κ_{pred} variando entre 0,4680 (NB) e 0,5140 (LR), na faixa moderada de [Landis and Koch, 1977].

A estrutura interna das discordâncias entre os modelos pareados é detalhada na Figura VI.4, que apresenta as matrizes de contingência entre as predições dos modelos masculino e feminino para cada classificador. A inspeção das diagonais principais revela que, em todos os casos, a concordância direta predominou, com concentrações mais elevadas nas classes negativa e positiva.

Contudo, os padrões de discordância diferiram qualitativamente entre os algoritmos. O NB exibiu a maior dispersão fora da diagonal na classe positiva: 199 instâncias preditas como positivas pelo modelo masculino foram classificadas como negativas pelo modelo feminino, um valor substancialmente superior ao observado no SVM (128) e no LR (124). Essa assimetria é coerente com o maior $\Delta\kappa$ registrado pelo NB. Na fronteira entre polaridades, o NB discorda em 204 instâncias nos dois sentidos (199 e 5), contra 23 entre as fontes anotadoras (17 e 6; Figura VI.2), o que situa a origem dessa discordância no treinamento, em uma escala muito superior à observada nos rótulos. O RF, por sua vez, apresentou a maior célula de concordância na classe positiva (447), o que indica que, apesar da amplificação moderada em termos de κ, o modelo tende a convergir para o polo positivo independentemente da fonte de rótulos, possivelmente como reflexo da distribuição de votos majoritários nessa classe. O V de Cramér, calculado sobre essas matrizes, acompanha a ordenação do κ_{pred} e permanece entre 0,4785 e 0,5199 (Tabela VI.2), abaixo do valor de 0,7679 obtido entre as fontes anotadoras, o que indica que a redução de concordância não se restringe ao alinhamento estrito e abrange também a magnitude da associação entre as distribuições.

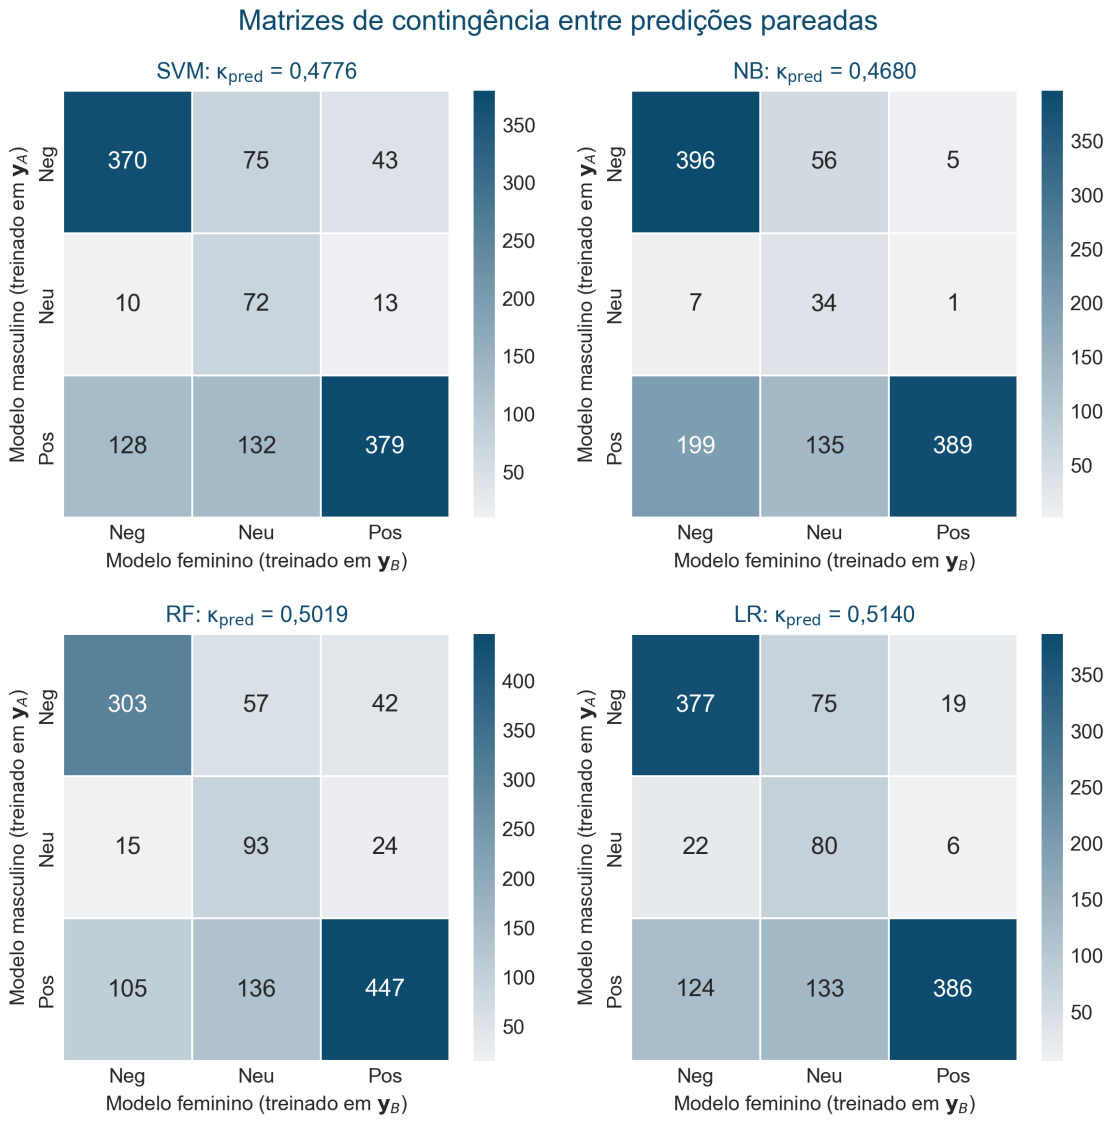


Figura VI.4: Matrizes de contingência entre as predições dos modelos masculino e feminino para cada um dos quatro classificadores avaliados no corpus MQD-1222. A diagonal principal concentra as concordâncias diretas entre os pares de modelos. As discordâncias fora da diagonal revelam padrões qualitativamente distintos entre os algoritmos: o NB apresenta maior dispersão na fronteira entre as classes negativa e positiva (199 instâncias), enquanto o RF exibe a maior célula de concordância absoluta na classe positiva (447). Os valores de κ_{pred} nos títulos dos subgráficos correspondem aos da Tabela VI.2 e resultam da média dos cinco κ por *fold* (Equação VI.2); por resultarem de uma agregação não linear, diferem em no máximo 0,0016 do κ recalculado sobre a matriz agregada aqui exibida (0,4792, 0,4665, 0,5034 e 0,5133 para SVM, NB, RF e LR).

VI.2.3 Módulo III: Quantificação da amplificação ($\Delta\kappa$)

A Tabela VI.2 consolida o $\Delta\kappa$ por classificador. Todos os modelos apresentaram $\Delta\kappa > 0$, com IC de 95% que não incluiu zero, rejeitando a hipótese nula de ausência de amplificação (teste unilateral ao nível de 2,5%, Seção VI.1.8). O NB registrou a maior magnitude (+0,2984) e o LR a menor (+0,2524), com uma média de 0,2760 ($\sigma = 0{,}0212$). O desvio reduzido entre os quatro valores sugere uma magnitude semelhante da amplificação nas quatro arquiteturas, e todos os classificadores

perdem uma faixa da escala de Landis and Koch [1977]: dois modelos treinados sobre os mesmos textos, diferenciados apenas pela fonte dos rótulos, passam a concordar em grau moderado, enquanto as fontes anotadoras concordam em grau substancial.

Tabela VI.2: Resultados consolidados da instanciação empírica (MQD-1222). O deslocamento é classificado pelo número de faixas de Landis and Koch [1977] percorridas entre o κ_{anot} e o κ_{pred}: 0 = nulo; 1 = restrito; 2 = amplo; ≥ 3 = acentuado. O V de Cramér é calculado sobre a matriz de contingência global das predições pareadas, conforme a Seção VI.1.7. As estatísticas χ^2 associadas são 573,08 (SVM), 559,49 (NB), 630,99 (RF) e 660,48 (LR), todas com $p < 0{,}001$.

Classificador	κ_{pred}	$\Delta\kappa$	V de Cramér	Deslocamento	IC bootstrap de 95% de $\Delta\kappa$
SVM	0,4776	+0,2888	0,4842	Restrito (1 faixa)	[+0,2510; +0,3279]
Naive Bayes	0,4680	+0,2984	0,4785	Restrito (1 faixa)	[+0,2625; +0,3352]
Random Forest	0,5019	+0,2645	0,5081	Restrito (1 faixa)	[+0,2266; +0,3036]
Logistic Regression	0,5140	+0,2524	0,5199	Restrito (1 faixa)	[+0,2161; +0,2897]
Fontes anotadoras: $\kappa_{\text{anot}} = 0{,}7664$ $V_{\text{Cramér}} = 0{,}7679$					
Entre os quatro classificadores: $\overline{\Delta\kappa} = 0{,}2760$ $\sigma = 0{,}0212$					

Nota: Os valores pontuais de κ_{pred} e $\Delta\kappa$ utilizam a média dos coeficientes calculados por fold. Os intervalos *bootstrap* são obtidos por reamostragem pareada dentro de cada fold, seguida do recálculo da média dos coeficientes. O valor observado de κ_{anot} permanece fixo durante as reamostragens.

Os resultados empíricos indicam amplificação em todos os modelos, com deslocamento restrito e magnitudes próximas entre si ($\overline{\Delta\kappa} = 0{,}2760$, $\sigma = 0{,}0212$). Para verificar se essa proximidade reflete uma propriedade dos dados ou dos algoritmos, a instanciação sintética replica o experimento sobre conjuntos com concordância inicial controlada, o que permite observar o comportamento dos modelos sob condições conhecidas e independentes do conteúdo linguístico.

VI.3 Resultados sintéticos

A instanciação sintética permitiu examinar a amplificação sob diferentes níveis controlados de concordância inicial. Manipulando diretamente a taxa de concordância nominal γ entre duas fontes de rótulos e mantendo constante o restante do procedimento experimental, conforme descrito na Seção VI.1.3, foram construídos doze cenários independentes, de SynSA-50 a SynSA-99, com γ no intervalo de 50% a 99%. Essa configuração permite observar o comportamento da MADA em um ambiente controlado, no qual a divergência entre as fontes anotadoras é introduzida de forma explícita e parametrizada.

Diferentemente da instanciação empírica, em que as diferenças entre grupos decorrem de julgamentos reais e de múltiplos fatores não diretamente controláveis, os cenários sintéticos permitem avaliar como diferentes níveis de concordância inicial se propagam ao longo do treinamento dos classificadores. Assim, os resultados desta etapa funcionam como uma análise de sensibilidade da metodologia, verificando se a amplificação medida por $\Delta\kappa$ responde de maneira coerente à variação

sistemática da concordância entre fontes.

VI.3.1 Módulo I: Concordância entre as fontes anotadoras

O primeiro passo da instanciação sintética garantiu que os conjuntos construídos de forma parametrizada pudessem reproduzir, de forma controlada e fiel, os níveis de concordância previamente estipulados entre as duas fontes sintéticas. Para cada cenário, calculou-se o coeficiente κ_{anot}, considerando exclusivamente os rótulos das fontes, antes de qualquer etapa de treinamento supervisionado.

A Tabela VI.3 apresenta os valores de concordância alvo e os respectivos κ_{anot} observados em cada conjunto de dados sintético, enquanto a Figura VI.3 ilustra o posicionamento desses valores nas faixas interpretativas de Landis and Koch [1977], sobrepondo-se à linha de referência do corpus empírico.

Tabela VI.3: Concordância entre as fontes anotadoras nos cenários sintéticos.

Conjunto	**Alvo (%)**	$\boldsymbol{\kappa}_{\text{anot}}$
SynSA-99	99	0,9850
SynSA-97	97	0,9550
SynSA-95	95	0,9249
SynSA-90	90	0,8498
SynSA-85	85	0,7748
SynSA-80	80	0,6997
SynSA-75	75	0,6246
SynSA-70	70	0,5495
SynSA-65	65	0,4745
SynSA-60	60	0,3994
SynSA-55	55	0,3243
SynSA-50	50	0,2507

Observa-se um comportamento monotonicamente decrescente de κ_{anot} à medida que a concordância nominal programada é reduzida. A variação acompanha sistematicamente os níveis de concordância alvo, indicando coerência entre o parâmetro de geração e o coeficiente efetivamente observado. Essa regularidade sugere que o mecanismo de geração paramétrica preservou a estrutura de divergência planejada, sem a introdução de assimetrias adicionais.

A distância entre as duas colunas da Tabela VI.3 decorre da definição do coeficiente κ e independe da precisão do gerador. A coluna Alvo reporta a proporção nominal de concordância bruta (p_o) parametrizada na geração de cada conjunto, ao passo que κ_{anot} reporta essa mesma concordância corrigida pela concordância esperada ao acaso (p_e), conforme a Equação II.1. Como o esquema sintético distribui as instâncias de forma balanceada entre as três classes de sentimento ($p_e \approx 1/3$), a correção desloca sistematicamente os valores observados para abaixo do valor nominal, com a distância entre as colunas ampliando-se nos cenários de concordância mais baixa: em SynSA-99, a

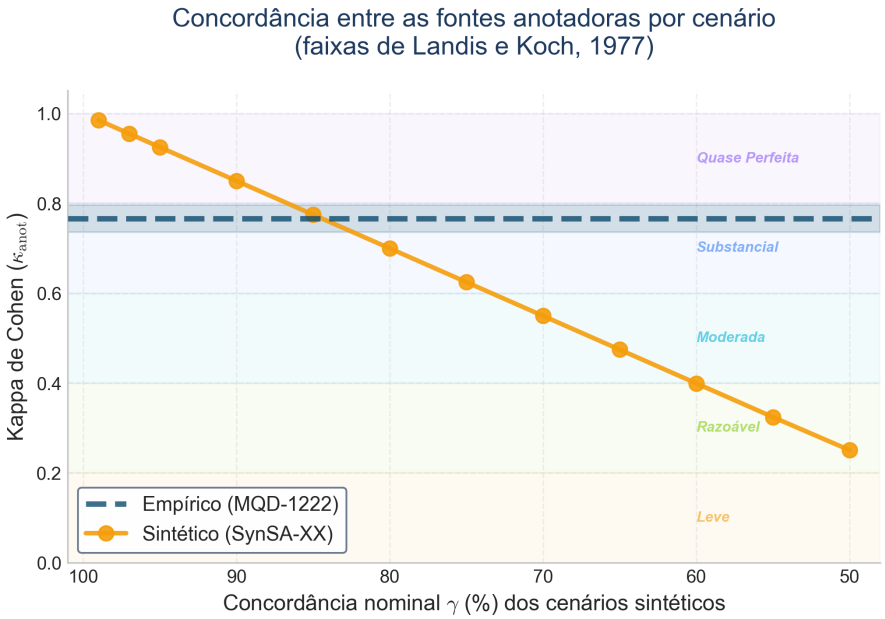


Figura VI.5: Comparação entre os valores de κ_{anot} obtidos nos doze cenários sintéticos, representados por SynSA-XX, e o valor empírico de referência do MQD-1222.

diferença é de 0,5 ponto percentual; em SynSA-50, de 24,9 pontos. A aderência dos valores de κ_{anot} aos valores teóricos correspondentes à Equação II.1, com desvios restritos à quarta casa decimal, é o que atesta a fidelidade do procedimento de geração às taxas parametrizadas.

No corpus empírico, a concordância bruta entre as duas fontes é de 84,5% (1.033 de 1.222 instâncias com o mesmo rótulo consolidado, na diagonal da Figura VI.2). Esse valor fica entre os cenários SynSA-80 e SynSA-85, cujas concordâncias brutas são fixadas pelo método de geração, o que permite situar o corpus empírico no gradiente sintético.

Em termos de κ_{anot}, o valor empírico (0,7664) fica entre SynSA-80 (0,6997) e SynSA-85 (0,7748), e SynSA-85 está contido no IC de 95% do valor empírico ([0,7348; 0,7958]), o que o torna o cenário sintético mais próximo (Figura VI.5). Esse resultado permite interpretar os cenários sintéticos como extensões parametrizadas do contexto empírico, com a divergência inicial manipulada de forma gradual e mensurável ao longo da escala de concordância.

VI.3.2 Módulo II: Treinamento pareado e concordância entre as predições

Seguindo o fluxo metodológico proposto, o Módulo II da instanciação sintética avaliou como cada algoritmo respondeu a diferentes níveis de concordância inicial entre as fontes sintéticas (grupos de anotação gerados parametricamente pelo SynSA). A Figura VI.6 apresenta os valores de κ_{pred} calculados entre os pares de predições para cada classificador em relação aos doze cenários sintéticos, em contraste com a curva de κ_{anot} original (linha tracejada amarela).

O RF apresentou um comportamento sistematicamente distinto dos demais classificadores em todos os doze conjuntos de dados sintéticos. Enquanto SVM, NB e LR acompanharam a curva de

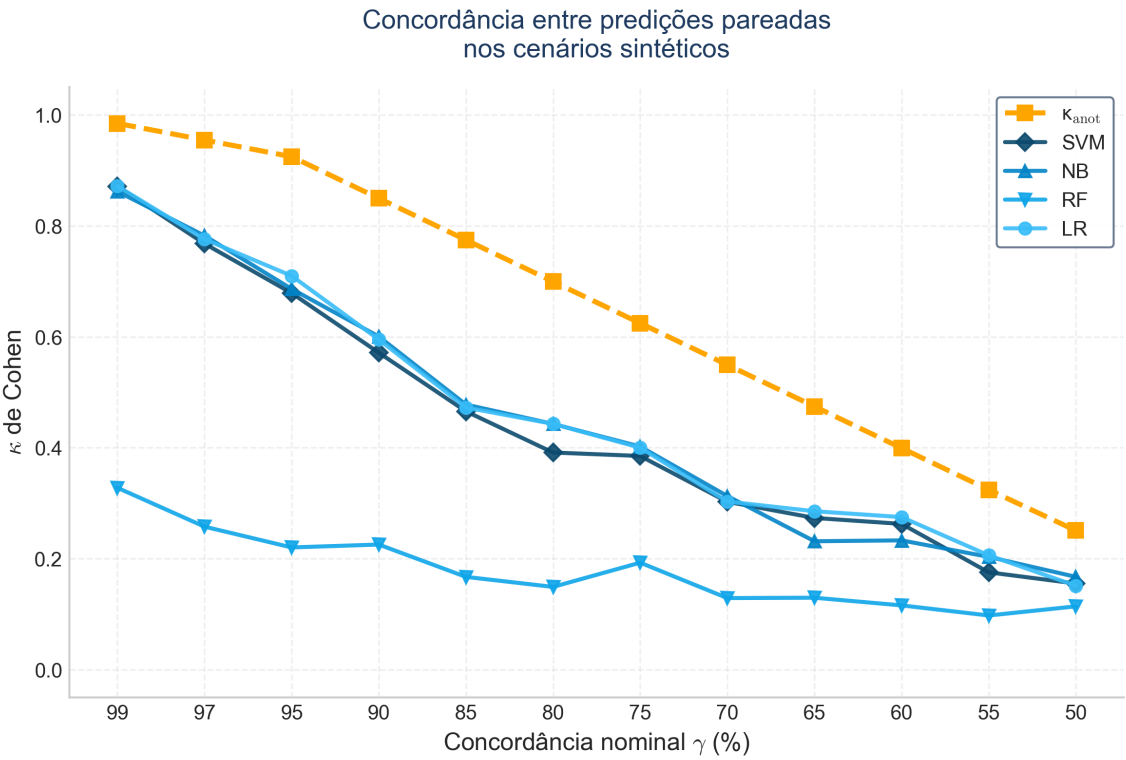


Figura VI.6: Evolução de κ_{pred} em função da taxa de concordância dos conjuntos de dados sintéticos, por classificador. A linha tracejada amarela representa os valores dos kappas originais (κ_{anot}). Todos os modelos apresentam κ_{pred} sistematicamente inferiores à concordância original em toda a extensão da escala. O RF exibe os menores valores em todos os cenários, indicando maior redução de concordância sob as condições avaliadas, enquanto SVM, NB e LR seguem trajetórias aproximadamente paralelas entre si.

κ_{anot} com valores de κ_{pred} próximos entre si em cada cenário, alcançando a faixa quase perfeita ($\kappa > 0{,}80$) no cenário de maior concordância (0,8716, 0,8622 e 0,8718), o RF permaneceu na faixa razoável (κ entre 0,22 e 0,33) em todos os conjuntos de alta concordância (SynSA-99 a SynSA-90).

VI.3.3 Módulo III: Quantificação da amplificação ($\Delta\kappa$)

O Módulo III foi aplicado a cada um dos doze cenários sintéticos (Seção V.4). A Tabela VI.4 consolida os valores de $\Delta\kappa$ e o deslocamento entre categorias da escala de Landis and Koch [1977] para todos os modelos e cenários. O mapa de deslocamento da Figura VI.6 complementa a tabela com uma representação visual que facilita a identificação de padrões nas duas dimensões: modelos e níveis de concordância.

As faixas de Landis and Koch [1977] foram aplicadas com limite superior inclusivo (por exemplo, $\kappa = 0{,}60$ pertence à faixa moderada).

A análise transversal dos resultados revelou dois achados centrais. O primeiro diz respeito ao comportamento não linear do RF. Ao contrário dos demais modelos, que apresentaram valores de $\Delta\kappa$ próximos entre si em cada cenário (diferença máxima de 0,0541, em SynSA-65), o RF exibiu

Tabela VI.4: Amplificação ($\Delta\kappa$) e deslocamento entre as faixas de Landis and Koch [1977] por classificador nos cenários sintéticos. Nulo (0 faixas), restrito (1 faixa), amplo (2 faixas) e acentuado (≥ 3 faixas).

	SVM		**NB**		**RF**		**LR**	
Conjunto de dados	$\Delta\kappa$	Desl.	$\Delta\kappa$	Desl.	$\Delta\kappa$	Desl.	$\Delta\kappa$	Desl.
SynSA-99	0,1134	Nulo	0,1228	Nulo	0,6571	Acentuado	0,1132	Nulo
SynSA-97	0,1869	Restrito	0,1726	Restrito	0,6972	Acentuado	0,1789	Restrito
SynSA-95	0,2460	Restrito	0,2385	Restrito	0,7046	Acentuado	0,2149	Restrito
SynSA-90	0,2784	Amplo	0,2492	Restrito	0,6244	Acentuado	0,2546	Amplo
SynSA-85	0,3091	Restrito	0,2968	Restrito	0,6076	Acentuado	0,3022	Restrito
SynSA-80	0,3083	Amplo	0,2567	Restrito	0,5506	Acentuado	0,2567	Restrito
SynSA-75	0,2394	Amplo	0,2224	Restrito	0,4318	Acentuado	0,2245	Restrito
SynSA-70	0,2470	Restrito	0,2366	Restrito	0,4206	Amplo	0,2465	Restrito
SynSA-65	0,2010	Restrito	0,2430	Restrito	0,3449	Amplo	0,1889	Restrito
SynSA-60	0,1367	Nulo	0,1664	Nulo	0,2836	Restrito	0,1244	Nulo
SynSA-55	0,1489	Restrito	0,1211	Nulo	0,2268	Restrito	0,1183	Nulo
SynSA-50	0,0955	Restrito	0,0835	Restrito	0,1367	Restrito	0,0995	Restrito

uma amplificação acentuada nos casos de alta concordância inicial, alcançando $\Delta\kappa = 0{,}7046$ no cenário SynSA-95. Esse comportamento é contraintuitivo: seria esperado que cenários com fontes anotadoras muito similares entre si produzissem modelos igualmente similares.

Uma explicação plausível reside nas próprias características do algoritmo. O RF, ao agregar árvores de decisão por voto majoritário, é mais sensível a pequenas variações nos rótulos de treinamento do que classificadores lineares regularizados. Em contextos de alta concordância, as discordâncias residuais entre as fontes são quantitativamente escassas, mas podem ter um impacto desproporcional sobre as fronteiras de decisão aprendidas. Essa explicação está de acordo com a literatura sobre variância em *ensembles* [Hastie et al., 2009], mas requer análise complementar (por exemplo, a identificação das instâncias em que os modelos pareados discordam) para ser caracterizada de forma definitiva; a Seção VII.2 retoma essa ressalva ao discutir as particularidades preditivas do RF como limitação do estudo.

O segundo achado refere-se ao comportamento dos modelos lineares e probabilísticos. SVM, NB e LR apresentaram $\Delta\kappa$ entre 0,0835 e 0,3091 ao longo dos doze cenários, com diferença máxima de 0,0541 entre os três em um mesmo cenário. A Figura VI.6 ilustra essa diferenciação para o cenário SynSA-85, que tem $\kappa_{\text{anot}} = 0{,}7748$ mais próximo do valor empírico observado no MQD-1222, tornando-o especialmente relevante como referência de interpretação cruzada entre as duas instanciações.

Para SVM, NB e LR, a amplificação tende a crescer com a concordância nominal até SynSA-85, com oscilações pontuais (o NB passa de +0,2430 em SynSA-65 para +0,2224 em SynSA-75). O RF apresenta outro perfil: máximo em SynSA-95 (+0,7046) e +0,6571 em SynSA-99. Nos cenários de

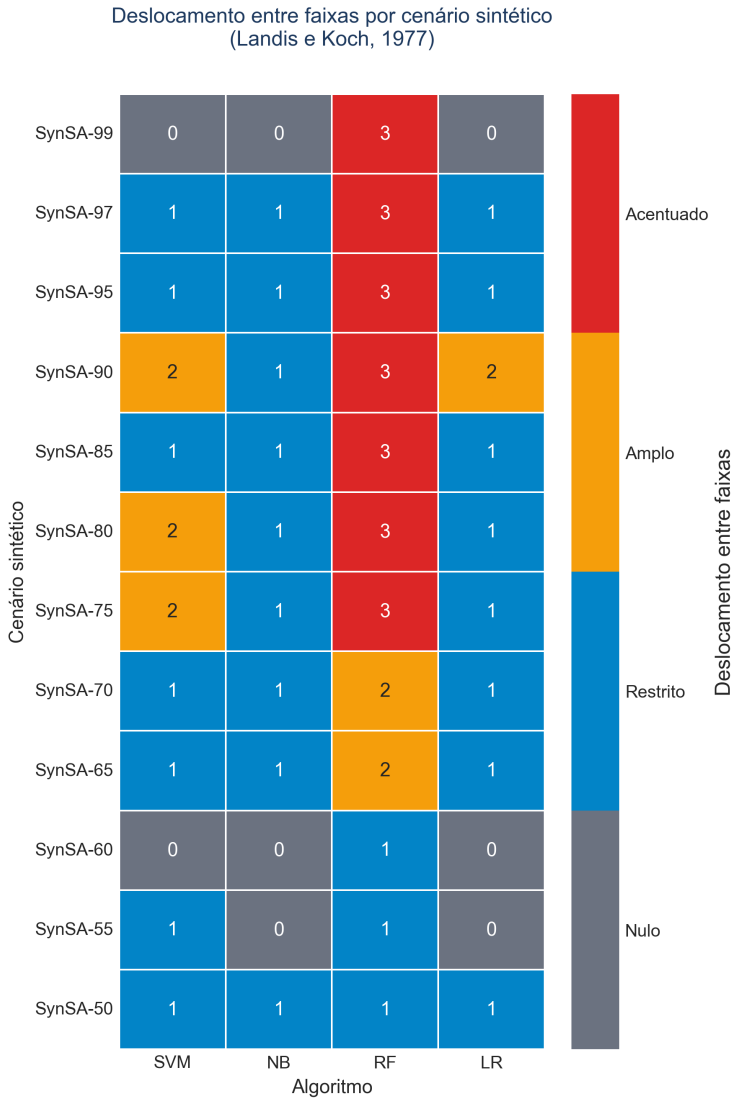


Figura VI.7: Deslocamento entre as faixas de Landis and Koch [1977] para os conjuntos de dados sintéticos. Cada célula indica o deslocamento por faixas interpretativas perdidas entre κ_{anot} e κ_{pred}: cinza = nulo; azul = restrito; laranja = amplo; vermelho = acentuado. A coluna RF apresenta deslocamento acentuado de SynSA-99 a SynSA-75, amplo em SynSA-70 e SynSA-65 e restrito de SynSA-60 a SynSA-50; SVM, NB e LR concentram deslocamentos restritos.

concordância muito baixa (SynSA-50 a SynSA-60), o crescimento é limitado pelo teto de $\Delta\kappa$: como κ_{anot} já é pequeno (0,2507 em SynSA-50) e $\Delta\kappa = \kappa_{\text{anot}} - \kappa_{\text{pred}}$ não supera κ_{anot} quando $\kappa_{\text{pred}} \geq 0$, resta pouca margem para amplificação. Nos cenários de concordância muito alta, o limite de SVM, NB e LR é de outra natureza: as duas fontes rotulam quase todas as instâncias da mesma forma, de modo que há pouca divergência anotativa a ser amplificada.

VI.4 Resultados integrados: evidência empírica e controle sintético

A etapa final do capítulo integra os achados das duas instanciações, avaliando se o comportamento observado no contexto empírico é compatível com os padrões revelados pela

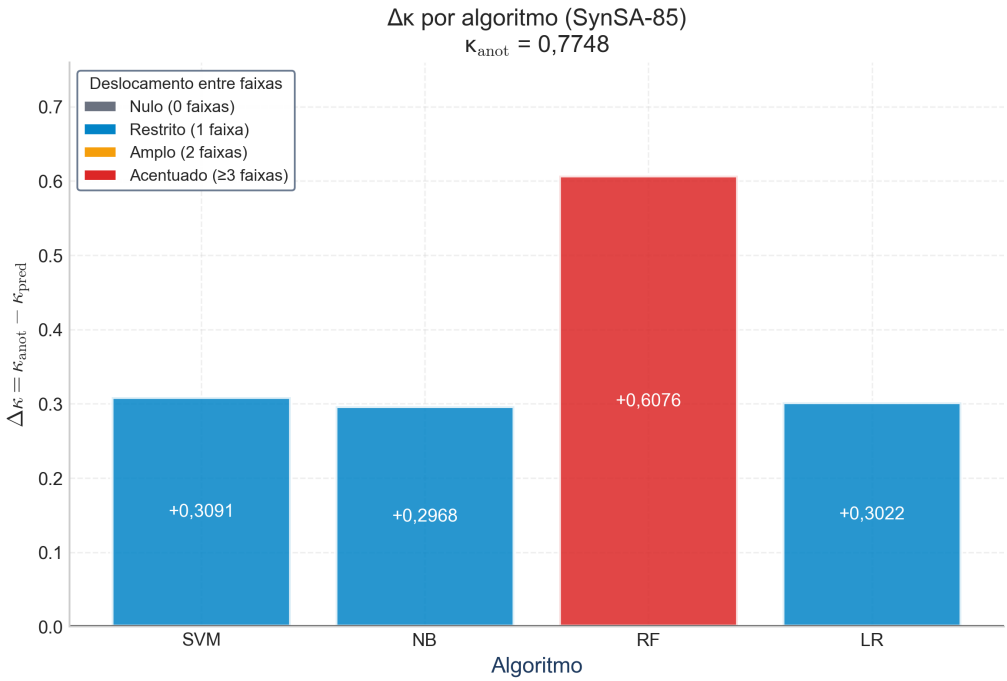


Figura VI.8: Amplificação de divergências ($\Delta\kappa$) por algoritmo no cenário SynSA-85 (concordância nominal de 85%, $\kappa_{\text{anot}} = 0{,}7748$), com codificação de cor segundo o deslocamento entre as faixas propostas por Landis and Koch [1977]. O RF apresenta deslocamento acentuado (+0,6076, 3 faixas), enquanto SVM (+0,3091), NB (+0,2968) e LR (+0,3022) apresentam deslocamento restrito (1 faixa). Esse cenário é o mais próximo do contexto empírico do MQD-1222 e constitui o principal ponto de articulação interpretativa entre as duas instanciações.

experimentação sintética. A comparação situa o caso empírico na curva sintética e, por si só, não distingue uma propriedade do processo de aprendizagem de uma particularidade do MQD-1222.

VI.4.1 Cenário empírico vs. cenário sintético

A análise entre as duas abordagens é facilitada pelos valores estabelecidos no Módulo I: o valor $\kappa_{\text{anot}} = 0{,}7664$ observado no MQD-1222 posiciona-se entre SynSA-80 ($\kappa_{\text{anot}} = 0{,}6997$) e SynSA-85 ($\kappa_{\text{anot}} = 0{,}7748$). Essa proximidade de κ_{anot} permite selecionar SynSA-80 e SynSA-85 como referências descritivas para a comparação. Ela não implica, contudo, uma proximidade necessária entre os valores de $\Delta\kappa$, pois as instanciações diferem na relação entre os atributos textuais e as classes. A comparação examina, portanto, semelhanças e diferenças entre resultados obtidos sob níveis próximos de concordância inicial, sem pressupor equivalência entre os problemas de aprendizagem.

Isso implica que, se a amplificação empírica for compatível com o comportamento descrito sinteticamente, os valores de $\Delta\kappa$ do MQD-1222 devem estar próximos aos valores observados nesses dois cenários. A Figura VI.9 apresenta, para três dos quatro algoritmos, a curva de $\Delta\kappa$ sintético sobreposta ao valor empírico correspondente (linha tracejada), permitindo avaliar visualmente essa correspondência.

Nos cenários vizinhos do κ_{anot} empírico (SynSA-80 e SynSA-85), o $\Delta\kappa$ sintético é +0,3083 e +0,3091 para o SVM, +0,2567 e +0,2968 para o NB e +0,2567 e +0,3022 para o LR. O valor empírico do SVM (+0,2888) fica 0,0195 e 0,0203 abaixo desses pontos, e o do LR (+0,2524) fica 0,0043 e 0,0498 abaixo. O NB (+0,2984) ultrapassa os dois, por 0,0417 em SynSA-80 e por 0,0016 em SynSA-85, que é o máximo da curva sintética do NB. Para os três classificadores, a diferença em relação aos cenários vizinhos é de no máximo 0,05.

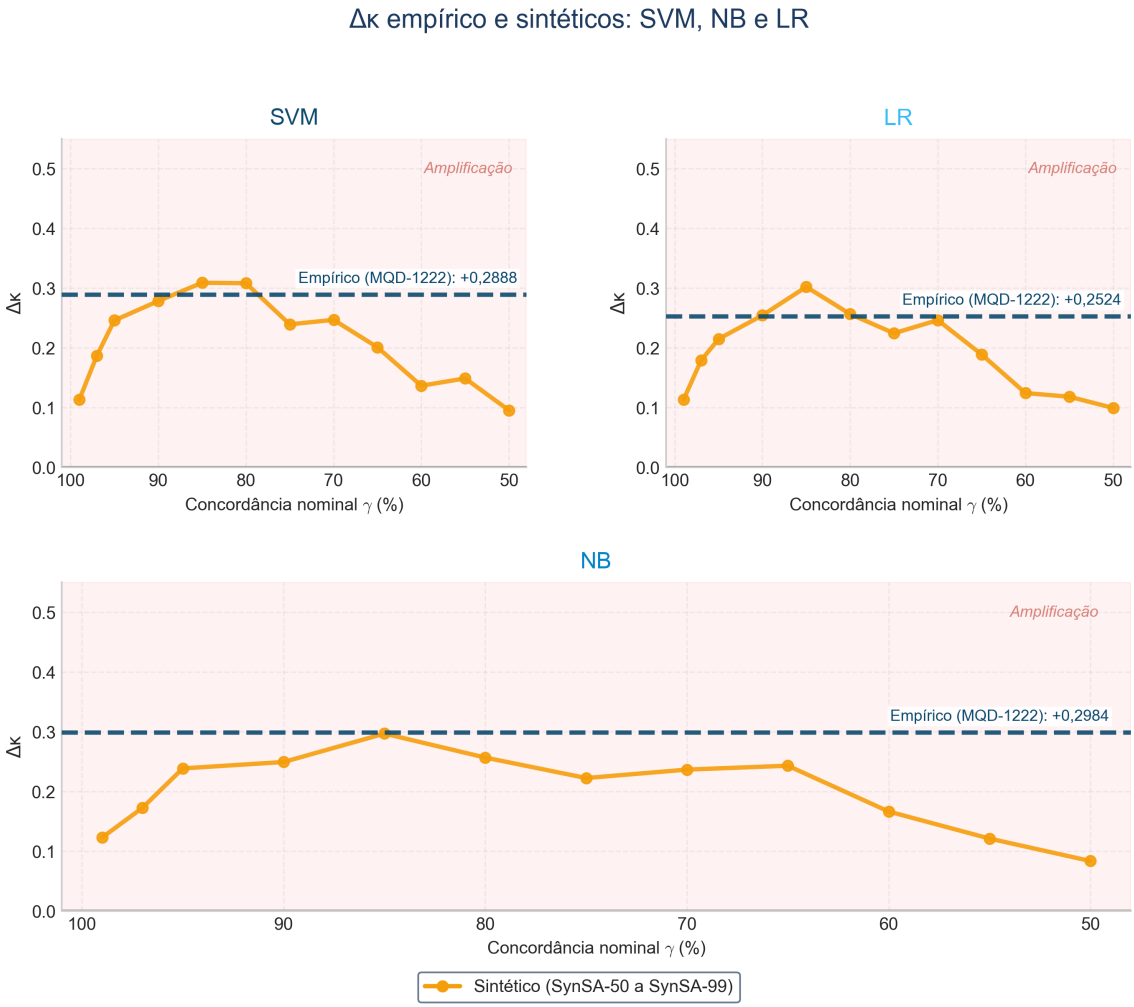


Figura VI.9: $\Delta\kappa$ por classificador: valor empírico (MQD-1222) sobreposto à curva sintética (SynSA-50 a SynSA-99). O fundo delimita a região de amplificação ($\Delta\kappa > 0$). A linha tracejada horizontal representa o $\Delta\kappa$ empírico de cada classificador; a curva laranja representa o $\Delta\kappa$ sintético em função do nível de concordância nominal.

O RF diverge dos demais (Figura VI.10). O valor empírico (+0,2645) fica 0,2861 abaixo de SynSA-80 (+0,5506) e 0,3431 abaixo de SynSA-85 (+0,6076), embora esteja dentro do intervalo percorrido pela curva sintética do RF (+0,1367 a +0,7046), na região de concordâncias nominais próximas a 60%. Uma explicação plausível está na ausência de informação lexical sobre as classes nos textos sintéticos (Seção IV.2.2): o RF ajusta árvores a atributos independentes dos rótulos, e uma diferença pequena entre os vetores de rótulos pode produzir estruturas de árvore distintas,

enquanto nos textos reais a informação lexical pode estabilizá-las. Essa explicação não foi testada diretamente neste estudo (Seção VII.2).

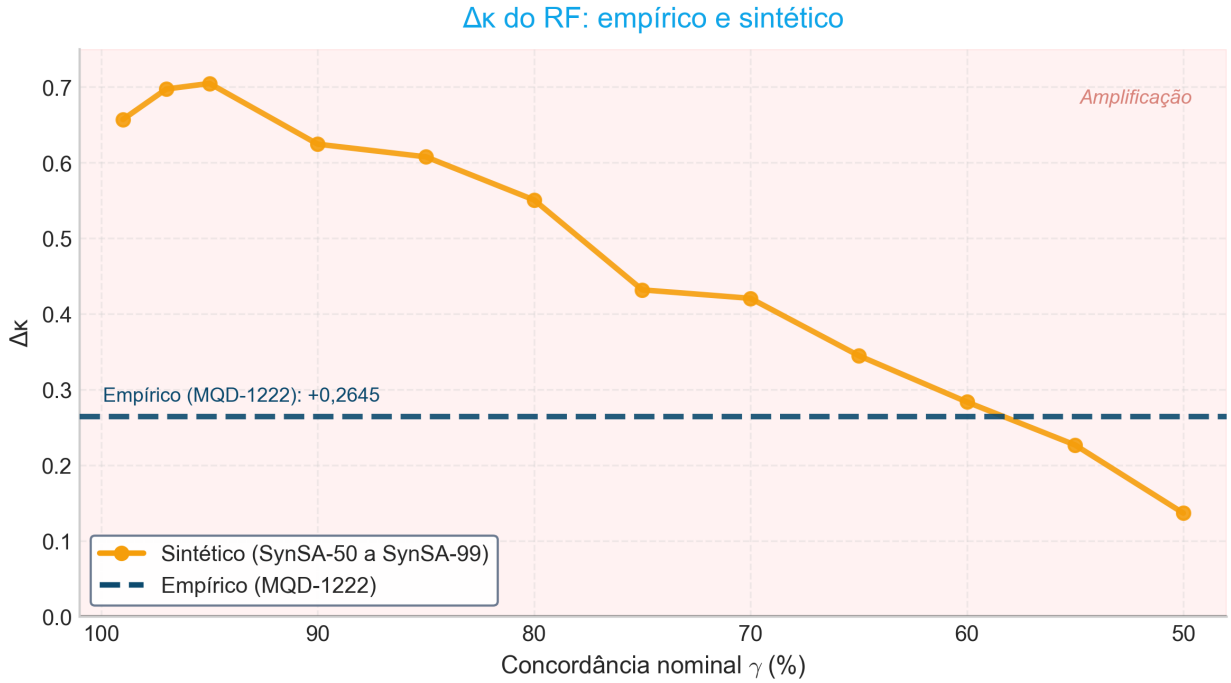


Figura VI.10: Para o RF, o valor empírico ($\Delta\kappa = 0{,}2645$) aproxima-se dos valores de concordância nominal de 60% da curva sintética e é inferior ao resultado de SynSA-85 ($\Delta\kappa = 0{,}6076$), cenário com κ_{anot} próximo ao do corpus empírico. Essa comparação é descritiva e não pressupõe que a curva sintética determine a magnitude esperada em textos reais.

VI.4.2 Intervalos *bootstrap* da análise complementar

Nas duas instanciações, os resultados pontuais de $\Delta\kappa$, calculados a partir da média dos kappas por fold, foram positivos em todas as 52 combinações avaliadas. Na análise *bootstrap*, realizada por reamostragem pareada dentro de cada fold e com a concordância inicial mantida fixa, os intervalos também permaneceram inteiramente positivos.

Na instanciação empírica, os intervalos de 95% foram: SVM [+0,2510; +0,3279], NB [+0,2625; +0,3352], RF [+0,2266; +0,3036] e LR [+0,2161; +0,2897]. Esses intervalos caracterizam a incerteza do estimador médio por fold, condicionada às predições e às partições observadas, sem incorporar a variabilidade da concordância inicial.

Nas 52 combinações avaliadas, a menor magnitude pontual de $\Delta\kappa$ foi +0,0835, para NB em SynSA-50. Na análise *bootstrap* complementar dos cenários sintéticos, o menor limite inferior foi +0,0322, também para NB em SynSA-50.

O conjunto de resultados mostra recorrência da direção positiva nas análises conduzidas, sem estabelecer equivalência entre as agregações utilizadas. As 52 combinações não constituem evidências estatisticamente independentes, e a análise atual não incorpora novos treinamentos, nem

a variação conjunta da concordância inicial e da concordância preditiva. A interpretação inferencial permanece limitada ao procedimento descrito na Seção VI.1.8.

VI.4.3 Síntese interpretativa

A Figura VI.11 sintetiza visualmente a correspondência entre as duas instanciações por meio de um gráfico comparativo de setas direcionais. Para cada classificador, os pares empírico (MQD-1222) e sintético (média SynSA) são representados nas faixas interpretativas de Landis and Koch [1977], com setas que ilustram a transição de κ_{anot} para κ_{pred}. Essa representação permite identificar, em um único plano visual, tanto a magnitude da amplificação (comprimento da seta) quanto o deslocamento entre categorias (número de faixas percorridas).

Observou-se que, para os três modelos lineares e probabilísticos (SVM, NB e LR), os perfis empíricos e sintéticos foram semelhantes na direção e no deslocamento predominantemente restrito, e a magnitude empírica ficou a no máximo 0,05 da dos cenários vizinhos SynSA-80 e SynSA-85 (Seção VI.4.1); em relação à média dos doze cenários, o $\Delta\kappa$ empírico é maior (+0,2888 contra +0,2092 no SVM, +0,2984 contra +0,2008 no NB e +0,2524 contra +0,1936 no LR), pois a média abrange concordâncias de 50% a 99%.

O RF constituiu a exceção já antecipada na análise sintética: o cenário empírico registrou um deslocamento restrito ($\Delta\kappa = +0{,}2645$, 1 faixa), ao passo que, nos cenários sintéticos, o RF registrou um deslocamento que atingiu a maior magnitude média ($\overline{\Delta\kappa} = +0{,}4738$), classificado como amplo ou acentuado na maioria dos cenários (Tabela VI.4). Uma explicação plausível para esse contraste é a sensibilidade do algoritmo à ausência de conteúdo semântico nos textos sintéticos, conforme discutido na Seção VI.4.1.

As duas instanciações permitem quatro afirmações: (i) $\Delta\kappa$ foi positivo nas 52 combinações (no MQD-1222 e nos doze cenários sintéticos), o que indica que a amplificação não se restringe a um único conjunto de dados; (ii) a magnitude de $\Delta\kappa$ depende da concordância inicial e do algoritmo, e o RF apresentou as maiores magnitudes de amplificação na maioria dos cenários sintéticos avaliados, enquanto SVM, NB e LR diferiram entre si em no máximo 0,0541 em cada cenário; (iii) o valor empírico $\kappa_{\text{anot}} = 0{,}7664$ fica entre os valores de SynSA-80 e SynSA-85; (iv) nos cenários SynSA-80 e SynSA-85, os $\Delta\kappa$ empíricos de SVM, NB e LR diferem dos sintéticos em no máximo 0,05 (o do NB excede o de SynSA-85, máximo da curva do NB, em 0,0016), enquanto o do RF fica 0,2861 e 0,3431 abaixo, ainda dentro do intervalo percorrido por sua curva (0,1367 a 0,7046).

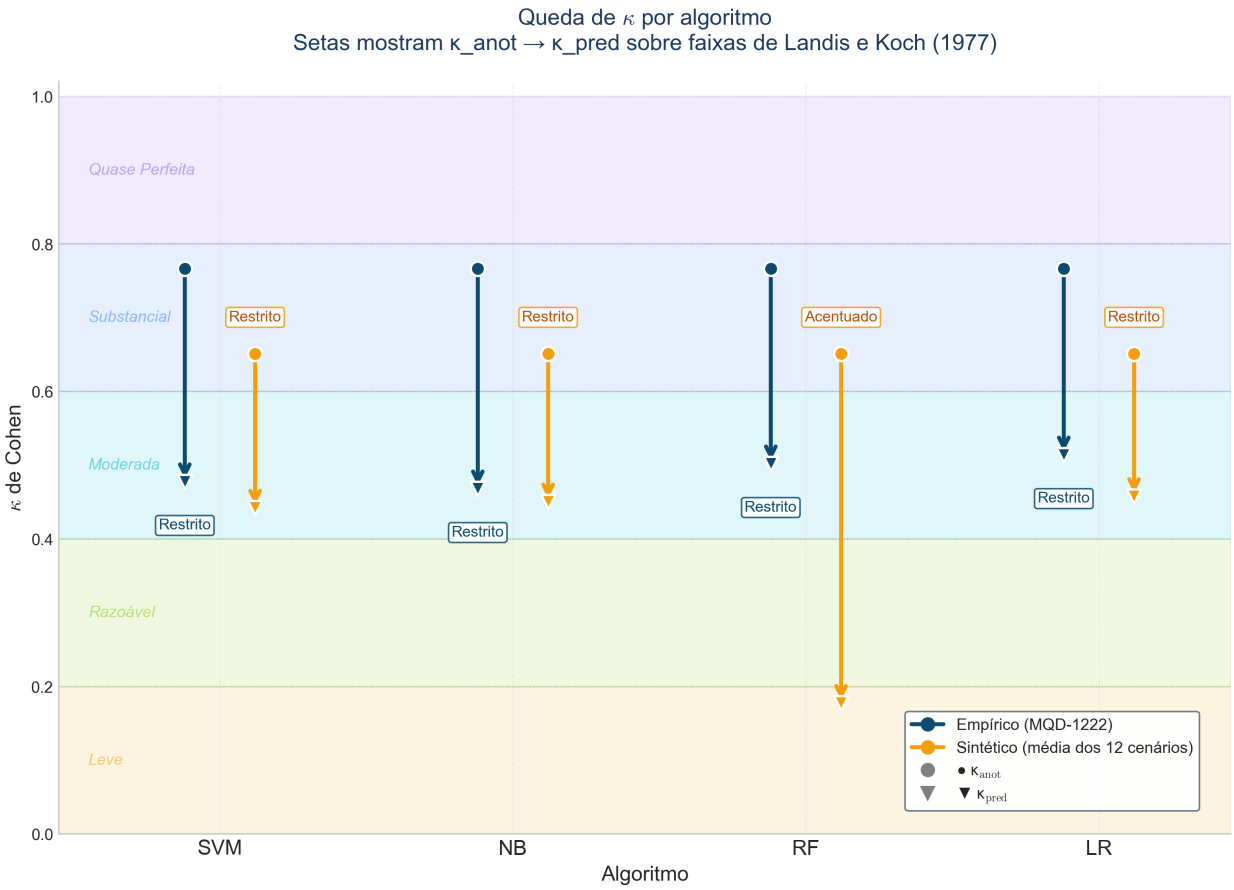


Figura VI.11: Amplificação de divergências: queda de κ por classificador nas instanciações empírica (MQD-1222) e sintética (média SynSA). As setas ilustram a transição de κ_{anot} (linha de base) para κ_{pred} (predições); a seta sintética parte da média de κ_{anot} dos doze cenários (0,6510). As setas são posicionadas sobre as faixas interpretativas de Landis and Koch [1977]. As anotações indicam a magnitude ($\Delta\kappa$) e o número de faixas percorridas em cada caso. Na instanciação empírica, todos os classificadores percorrem uma faixa (deslocamento restrito). Na sintética, SVM, NB e LR concentram deslocamentos nulos ou de uma faixa, com deslocamento amplo em três cenários do SVM e em um do LR, enquanto o RF atinge a maior magnitude média ($\overline{\Delta\kappa} = +0{,}4738$) e percorre três faixas em sete cenários, duas em dois e uma nos três restantes (Tabela VI.4).

Capítulo VII Conclusões

Na análise de sentimentos em português brasileiro, a pesquisa buscou responder se a divergência entre os rótulos consolidados dos grupos de anotadores, definidos pelo gênero autodeclarado, reaparece de forma mais significativa nas predições de classificadores treinados com os rótulos de cada grupo. A comparação foi estabelecida entre a concordância das duas fontes (os grupos feminino e masculino) antes do treinamento (κ_{anot}) e a concordância entre as predições depois dele (κ_{pred}), ambas medidas pelo κ de Cohen, e a amplificação corresponde a $\Delta\kappa = \kappa_{\text{anot}} - \kappa_{\text{pred}} > 0$. Os experimentos usaram o corpus MQD-1222 (1.222 sentenças de diário, anotadas por 46 anotadores), doze cenários sintéticos de concordância parametrizada (SynSA-50 a SynSA-99) e quatro classificadores (SVM, NB, RF e LR).

A pergunta desdobra-se em três dimensões: (i) se a amplificação ocorre, (ii) em que magnitude, e (iii) como essa magnitude varia entre as configurações de classificadores avaliados e entre os níveis de concordância inicial considerados. O Capítulo VI responde às três. Houve $\Delta\kappa$ pontual positivo em todas as 52 combinações avaliadas, considerando a média dos kappas por *fold* como estimador de concordância preditiva. A análise *bootstrap*, realizada por reamostragem pareada dentro dos *folds* e com a concordância inicial mantida fixa, também produziu evidências de amplificação nas condições avaliadas. O procedimento inferencial utiliza o mesmo estimador médio por *fold* adotado nos resultados pontuais, mantendo sua interpretação condicionada às predições e às partições observadas.

No corpus empírico, com $\kappa_{\text{anot}} = 0{,}7664$, o $\Delta\kappa$ ficou entre 0,2524 (LR) e 0,2984 (NB). Nos cenários sintéticos, a magnitude variou com a concordância inicial e com o classificador, e o RF apresentou os maiores valores de $\Delta\kappa$.

A ocorrência de redução da concordância nas duas instanciações sustenta a utilidade da MADA para caracterizar a transformação das diferenças entre fontes de supervisão no protocolo avaliado. O desenho pareado mantém constantes os textos, as configurações dos classificadores, as sementes e as partições entre os membros de cada par, permitindo examinar a resposta dos modelos à mudança dos rótulos de treinamento. Esse controle não estima a variabilidade diante de outras realizações experimentais, nem estabelece um mecanismo geral de amplificação.

VII.1 Síntese dos achados

A magnitude de $\Delta\kappa$ difere entre as instanciações e entre os classificadores. No corpus empírico, os quatro classificadores produziram um deslocamento restrito e homogêneo ($\Delta\kappa$ médio de 0,2760, com dispersão descritiva $\sigma = 0{,}0212$ entre os quatro classificadores; Tabela VI.2), o que equivale a uma faixa de Landis and Koch [1977] a menos, da concordância substancial entre os grupos ($\kappa_{\text{anot}} = 0{,}7664$) para a moderada entre as predições dos quatro classificadores.

A fase sintética mostrou que a semelhança entre os quatro classificadores no corpus empírico não se reproduz nos dados sintéticos: o RF apresenta $\Delta\kappa$ superior ao dos demais na maior parte dos cenários, inclusive na faixa de concordância do corpus. Ao varrer a concordância inicial de 50% a 99%, o Random Forest alcançou um deslocamento acentuado entre categorias nos cenários de alta concordância ($\Delta\kappa = 0{,}7046$ em SynSA-95), enquanto SVM, NB e LR se concentraram em deslocamento nulo ou restrito, com um grau amplo em três cenários do SVM, em um do LR e em nenhum do NB. A ausência de informação lexical sobre as classes nos textos sintéticos constitui uma possível explicação para o pico observado no Random Forest, conforme discutido na Seção VII.2. Como esse mecanismo não foi investigado diretamente, o valor não pode ser atribuído exclusivamente à divergência entre as fontes.

O valor empírico $\kappa_{\text{anot}} = 0{,}7664$ fica entre os de SynSA-80 (0,6997) e SynSA-85 (0,7748). Uma explicação plausível para a diferença do RF entre as instanciações, ainda não testada, é que a informação lexical dos textos reais (ausente nos textos sintéticos) estabilize as árvores (Seções VI.4.1 e VII.2). No nível dos rótulos, as distribuições marginais diferem entre os grupos: o grupo feminino atribuiu proporcionalmente mais rótulos neutros do que o masculino (365 contra 291), o que é compatível com uma maior concentração desse grupo em casos de polaridade menos marcada (Figura VI.1).

VII.2 Limitações

As escolhas que tornaram este estudo controlável também limitam o alcance do que ele pode afirmar. As limitações reunidas nesta seção, contudo, não pesam da mesma forma sobre a leitura dos resultados. Uma delas toca diretamente a interpretação do fenômeno central e é tratada separadamente, antes das demais, enquanto as outras delimitam o alcance da metodologia proposta, sem comprometer o achado central. Essa delimitação é esperada em estudos dessa natureza.

Especificidade da variável estratificadora. O gênero foi adotado como um elemento comparável entre as fontes anotadoras, uma instância da classe mais ampla de variáveis binárias sobre as quais a metodologia proposta pode operar. Essa escolha de escopo não distingue entre duas leituras do $\Delta\kappa$ observado: uma é que a divergência medida decorre de algo específico ao

gênero como categoria, e a outra é que decorre da heterogeneidade anotativa presente em qualquer bipartição dos 46 participantes, independentemente do critério de divisão. O desenho pareado mantém constantes os textos, as partições e as configurações dos classificadores entre os membros de cada par, permitindo examinar as diferenças associadas às fontes de rótulos nas condições avaliadas. Esse controle não elimina a variabilidade associada a outras realizações de treinamento, nem distingue, dentro da divergência observada, a parcela especificamente atribuível ao gênero da que poderia ocorrer em bipartições arbitrárias dos participantes.

Os resultados caracterizam a concordância entre duas fontes de rótulos definidas pelo gênero autodeclarado dos participantes. Entretanto, as análises apresentadas não estabelecem se esse critério de agrupamento produz uma amplificação distinta daquela que seria observada em bipartições não orientadas pelo gênero. Portanto, o recorte demográfico identifica as fontes comparadas, mas não demonstra a especificidade do efeito em relação ao gênero. Entre as limitações discutidas nesta seção, esta é a que mais diretamente qualifica o que pode ser afirmado sobre a origem do $\Delta\kappa$ medido.

Agregação da concordância e inferência. O estudo utiliza a média dos kappas por *fold*, tanto na estimativa pontual da concordância preditiva quanto no procedimento *bootstrap*. A reamostragem é realizada sobre os pares de predições dentro de cada *fold*, com o recálculo dos cinco coeficientes e obtenção de sua média, mantendo a concordância anotativa observada como referência fixa.

Os intervalos de confiança resultantes caracterizam a variabilidade desse estimador condicionada às predições e às partições observadas. O procedimento não incorpora novos treinamentos nem propaga integralmente a incerteza da concordância anotativa. Assim, a inferência permanece restrita ao desenho experimental avaliado, sem abranger outras realizações de treinamento ou amostras de anotadores.

Dependência entre as combinações e comportamento do Random Forest. As 52 combinações avaliadas (Capítulo VI) não constituem 52 testes estatisticamente independentes do teste de ausência de amplificação: os quatro classificadores de cada instanciação compartilham o mesmo corpus, os mesmos *folds* de validação cruzada e, no caso sintético, o mesmo mecanismo de geração paramétrica. A ausência de resultados inconclusivos ou de evidência de convergência induzida nesse conjunto não decorre de uma impossibilidade lógica do desenho pareado, que admite $\Delta\kappa \leq 0$ por definição (Seção V.4.1); ela é compatível com a heterogeneidade anotativa presente em todos os cenários testados. Esse padrão equivale a evidência convergente de duas linhas de análise complementares, a empírica e a sintética, cada uma com quatro classificadores que compartilham dados e partições.

A interpretação dos valores elevados de $\Delta\kappa$ do RF nos cenários sintéticos requer considerar a

ausência de informação textual sobre as classes. Nesse ambiente, a concordância entre as predições caracteriza a resposta das configurações avaliadas às diferenças entre as fontes de supervisão, sem representar a aprendizagem de padrões linguísticos de sentimento. A maior redução de concordância observada no RF é compatível com uma sensibilidade superior dessa configuração às alterações dos rótulos, mas o mecanismo responsável não foi investigado diretamente. Por isso, sua magnitude não deve ser transferida para contextos reais nem atribuída à família de algoritmos, independentemente dos hiperparâmetros adotados.

Consolidação da anotação e identificação de participantes. A anotação envolveu 46 participantes (26 do grupo masculino e 20 do grupo feminino). O rótulo de cada frase foi consolidado pela classe estritamente mais votada entre quatro votos por grupo, e a cobertura dos dez blocos não foi uniforme entre os participantes (Capítulo IV). Essa consolidação, embora suficiente para estabelecer a classe vencedora, descarta a dispersão entre os anotadores individuais: o κ entre grupos reflete o padrão coletivo consolidado, e a heterogeneidade interna de cada grupo fica fora da medida.

O descarte de frases por empate também não incide igualmente sobre os dois grupos: a taxa de empate é maior no grupo feminino, mesmo quando condicionada às frases com exatamente quatro votos (Tabela IV.1), o que sugere que o filtro aplicado aos registros retém as duas fontes anotadoras sob taxas de seleção distintas. Estudos futuros com mais votos por frase e cobertura uniforme dos blocos permitirão estimativas mais precisas de κ_{anot} e $\Delta\kappa$ e a investigação de interações entre gênero e outras variáveis sociodemográficas [Pei and Jurgens, 2023].

A contagem de 46 participantes deriva de identificadores pseudonimizados por *hash* do endereço IP (Seção IV.1.1), um método sujeito a duas fontes de imprecisão em direções opostas: um mesmo participante acessando por redes distintas gera identificadores diferentes, inflando a contagem aparente, enquanto participantes distintos que compartilham um endereço podem ser agrupados sob um único identificador, reduzindo-a. Essa limitação não se aplica à análise de concordância pareada, que opera sobre os rótulos consolidados por grupo e dispensa a identidade individual dos anotadores.

Escopo experimental e validade externa. Os resultados obtidos devem ser interpretados no contexto das escolhas experimentais adotadas: representação TF-IDF, quatro classificadores clássicos e validação cruzada estratificada com partições pareadas. Os classificadores foram avaliados com os hiperparâmetros apresentados na Tabela VI.1, que correspondem predominantemente aos valores padrão do *scikit-learn*, com as exceções explicitamente indicadas. A sensibilidade de $\Delta\kappa$ à configuração de cada algoritmo não foi examinada.

Esse desenho permite examinar a variação da concordância entre fontes anotadoras sob condições experimentais pareadas, mas seus resultados não cobrem arquiteturas neurais profundas, modelos

baseados em *transformers* ou estratégias de aprendizado que incorporem explicitamente a identidade ou a distribuição individual dos anotadores. A amplificação observada vale, nesta dissertação, como evidência recorrente na aplicação da metodologia proposta dentro desse escopo.

Três eixos adicionais limitam a validade externa dos resultados: (i) o domínio textual, (ii) a magnitude observada e (iii) o idioma. O *corpus* MQD-1222 é composto exclusivamente por textos de um diário pessoal, com linguagem informal, narrativa em primeira pessoa e proporções praticamente iguais de rótulos positivos e negativos quando somados os dois grupos (36,5% e 36,7%, com 26,8% de neutros); a extensão para notícias, avaliações de produtos, postagens em redes sociais ou domínios como saúde, política e educação não é imediata, uma vez que a subjetividade e a expressão emocional assumem papéis distintos em textos técnicos, jornalísticos ou argumentativos.

Quanto à magnitude, os valores de $\Delta\kappa$ da fase empírica correspondem a um deslocamento restrito na escala de Landis and Koch [1977] (média de 0,2760, $\sigma = 0{,}0212$), com significância confirmada por *bootstrap* em todos os quatro modelos; na fase sintética, a magnitude variou com a concordância inicial: para SVM, NB e LR, foi menor nos cenários de concordância mais baixa e atingiu o máximo em SynSA-85, enquanto o RF registrou os maiores valores nos cenários de alta concordância. Os valores aqui reportados, portanto, não se transferem automaticamente para outros corpora sem validação própria.

Por fim, o estudo foi conduzido exclusivamente em português brasileiro, com anotadores recrutados no contexto sociocultural do país, onde normas de gênero e convenções linguísticas assumem formas particulares; replicar a MADA em outros idiomas e contextos culturais permitiria avaliar a universalidade do fenômeno e a robustez do $\Delta\kappa$ como instrumento de mensuração.

VII.3 Contribuições

As três contribuições desta pesquisa formam uma cadeia. A contribuição metodológica torna a amplificação uma grandeza mensurável, o que viabiliza a contribuição empírica, pois permite aplicar a mesma métrica a um corpus real e a um conjunto controlado de cenários sintéticos. Por fim, a convergência entre essas duas aplicações fundamenta a contribuição teórica ao identificar a fonte anotadora como um componente relevante para a interpretação do padrão observado.

Do ponto de vista metodológico, a principal contribuição desta pesquisa consiste na formalização de uma proposta modular capaz de separar três níveis analíticos distintos: a divergência anotativa, a divergência preditiva e a diferença entre ambas. Essa separação, operacionalizada pela métrica $\Delta\kappa$ e pelo deslocamento entre categorias da escala de Landis and Koch [1977], permite investigar a amplificação como um fenômeno mensurável e comparável entre contextos distintos. É essa mensurabilidade que sustenta a contribuição seguinte, aplicada tanto ao corpus empírico quanto aos cenários sintéticos.

Do ponto de vista empírico, o estudo reúne evidências sobre divergências anotativas por gênero em AS para o português brasileiro, um domínio pouco representado na literatura sobre viés em PLN [Stańczak and Augenstein, 2021]. A convergência entre as duas instanciações, conduzidas sobre dados reais e sobre cenários sintéticos parametrizados, é o que confere à contribuição teórica seu fundamento.

Do ponto de vista teórico, os resultados mostram que as diferenças entre as fontes de rótulos podem estar acompanhadas de uma redução na concordância entre as predições, mesmo sem o uso de representações pré-treinadas. Esse achado situa as fontes de supervisão entre os componentes relevantes para a análise do comportamento dos modelos. Sua interpretação como viés, contudo, depende de critérios adicionais sobre o contexto de aplicação, as assimetrias produzidas e suas consequências, não decorrendo exclusivamente de $\Delta\kappa > 0$.

Como instrumento diagnóstico, a MADA permite verificar se a concordância entre duas fontes de supervisão se reduz após o treinamento de modelos pareados. A identificação de $\Delta\kappa > 0$ pode orientar a inspeção das matrizes de discordância, das distribuições de classes e das regras de consolidação dos rótulos. Entretanto, a métrica não determina, isoladamente, qual fonte é mais adequada, qual classificador deve ser adotado ou se a divergência produz dano. Essas decisões dependem dos objetivos e dos critérios do contexto de aplicação.

VII.4 Trabalhos futuros

Os resultados apresentados nesta dissertação decorrem das instanciações empírica e sintética da MADA, cujos experimentos foram reconstruídos e executados nos ambientes Windows e Google Colab. A verificação de reprodutibilidade computacional confirmou os principais resultados, dentro do escopo avaliado e com as ressalvas documentadas. A consolidação editorial do texto e a incorporação das sugestões da banca constituem etapas distintas da execução experimental.

A consolidação metodológica estabeleceu a correspondência entre o estimador pontual de κ_{pred} e o procedimento de reamostragem utilizado na inferência. Os intervalos de confiança de $\Delta\kappa$ foram calculados, mantendo a concordância anotativa observada como referência fixa, conforme descrito na Seção VI.1.8.

Esta pesquisa abre perspectivas de trabalhos futuros em quatro direções: (i) a condução de testes estatísticos formais sobre as diferenças entre os $\Delta\kappa$ dos quatro classificadores, extensão natural da análise de robustez; (ii) um controle com bipartições arbitrárias dos 46 participantes, não correlacionadas ao gênero, para verificar se o $\Delta\kappa$ observado é específico dessa estratificação (Seção VII.2); (iii) a análise qualitativa das frases com maior grau de divergência entre os grupos de anotadores, junto com um estudo do impacto da fadiga na qualidade da rotulagem, medida pelos tempos de resposta previamente coletados; e (iv) a investigação de se a possível diferença na robustez

do rótulo majoritário entre os grupos (Seção IV.1.2), decorrente da disponibilidade desigual de votos excedentes, contribui para a sensibilidade elevada do Random Forest a divergências residuais em cenários de alta concordância (Seções VI.4.3 e VII.2), o que distinguiria um efeito de ruído de rótulo de origem mecânica de um efeito de divergência anotativa genuína.

Outra expansão viável aponta para as questões sociodemográficas que foram isoladas neste estudo. A extensão da estratificação para categorias de gênero não binárias e para outras variáveis sociodemográficas permitiria verificar se a amplificação se repete em recortes além do binário adotado aqui. Em termos de arquitetura, a prevalência de modelos pré-treinados em aplicações contemporâneas de classificação textual torna relevante investigar se a amplificação se manifesta (e em que magnitude) em arquiteturas baseadas em *transformers*.

Outra direção promissora é o uso da MADA como instrumento de monitoramento durante o treinamento: o $\Delta\kappa$ pode operar como critério de parada, sinalizando o momento em que a divergência entre as fontes anotadoras atinge uma magnitude considerada inaceitável para o contexto de aplicação. A validação da MADA em outros corpora, domínios e configurações experimentais permitirá avaliar a estabilidade do $\Delta\kappa$ como instrumento de mensuração fora do contexto em que foi desenvolvido.

O percurso que separa esta qualificação da defesa está organizado no cronograma da Figura VII.1, distribuído entre novembro de 2026 e janeiro de 2027. As primeiras semanas concentram as correções críticas apontadas pela banca e a revisão estrutural, capítulo a capítulo, da introdução às limitações; a fase intermediária revisita a metodologia e verifica figuras e tabelas; o trecho final reserva-se à leitura integral, ao ajuste do resumo e do *abstract*, à formatação segundo as normas vigentes e à preparação da apresentação, culminando na defesa. O calendário traduz em prazos a posição em que este trabalho se encontra: um resultado central já sustentado pelas análises conduzidas até esta etapa e uma agenda definida para transformá-lo na versão final da dissertação.

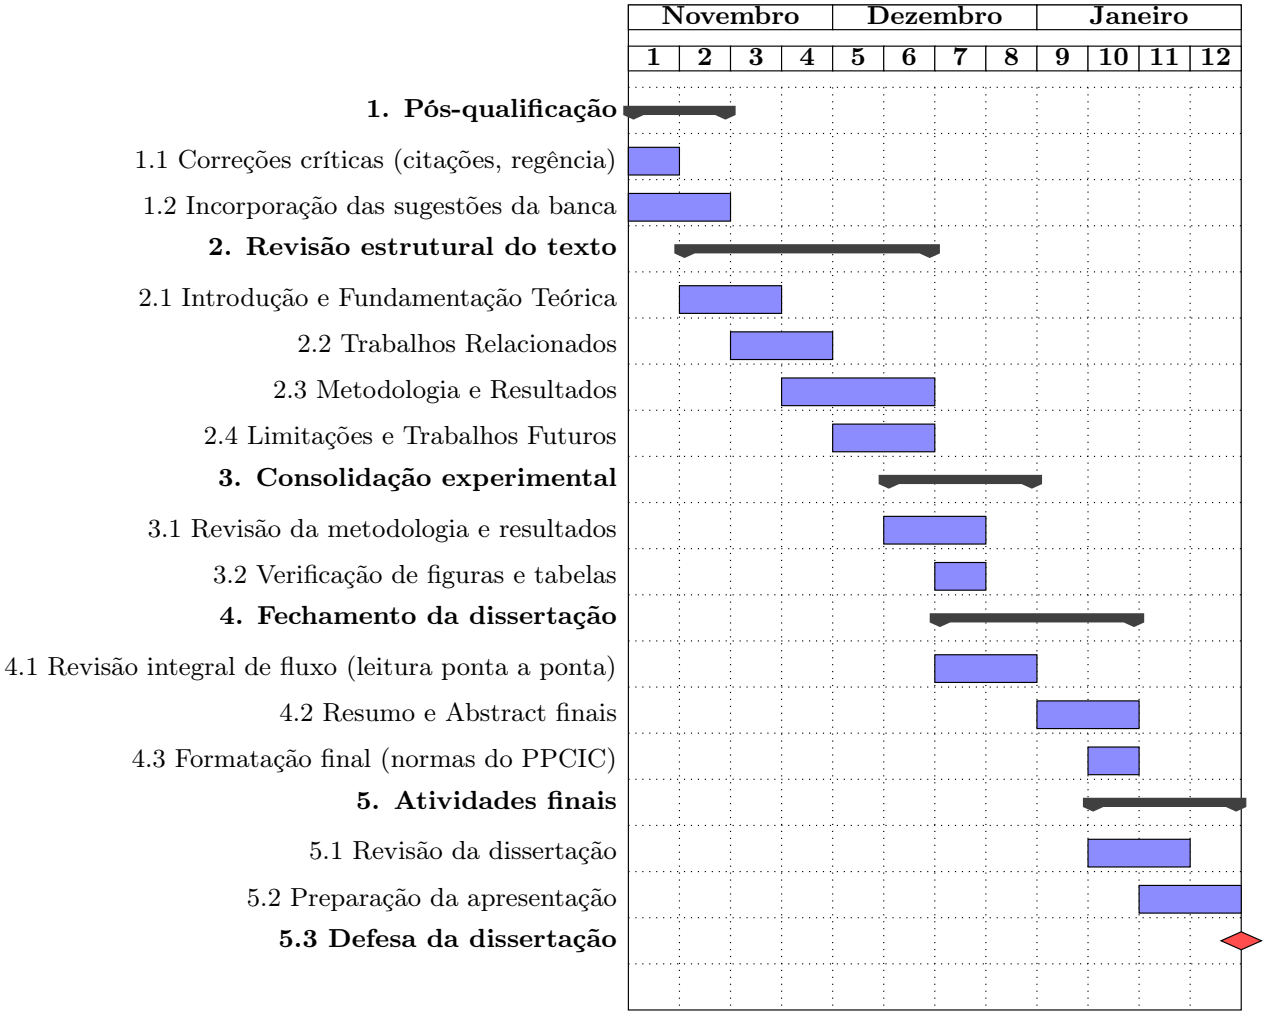


Figura VII.1: Cronograma das atividades previstas entre a qualificação e a defesa da dissertação. Os números na faixa superior indicam as semanas de cada mês, de novembro de 2026 a janeiro de 2027. Fonte: elaboração própria.

Apêndice A *Strings* de busca da revisão da literatura

Este apêndice apresenta as *strings* de busca utilizadas na revisão da literatura descrita no Capítulo III. A busca foi conduzida em quatro bases internacionais (Scopus, Web of Science, ACM Digital Library, ACL Anthology) e na Biblioteca Digital da Sociedade Brasileira de Computação (SOL), seguindo as diretrizes do PRISMA 2020 [Page et al., 2021].

A.1 *String* em português brasileiro

A primeira *string* foi construída em português brasileiro, com o objetivo de identificar trabalhos publicados na literatura nacional. Os termos foram combinados por operadores booleanos (`AND`, `OR`) em três blocos conceituais: terminologia da anotação, tarefa de classificação e fenômeno de amplificação.

```
("viés do anotador"OR "viés de anotação"OR "discordância entre anotadores"OR
"variação de rótulo humano"OR "demografia do anotador"OR "viés de rótulo"OR
"anotação subjetiva") AND ("análise de sentimentos"OR "classificação de
texto") AND ("amplificação de viés"OR "viés preditivo"OR "viés algorítmico"OR
"aprendizado de máquina")
```

A execução dessa *string* nas cinco bases não retornou resultados. Como a *string* exige a combinação simultânea dos três blocos conceituais, o resultado nulo pode decorrer tanto da cobertura dos estudos disponíveis quanto da especificidade dos termos empregados. A identificação posterior de trabalhos brasileiros por rastreamento de referências (Seção III.5), dedicados principalmente ao gênero no conteúdo textual e não à anotação, não permite distinguir conclusivamente essas possibilidades.

A.2 *String* em inglês

A ausência de resultados em português motivou a tradução da *string* para o inglês, preservando a estrutura de três blocos conceituais:

```
("annotator bias"OR "annotation bias"OR "annotator disagreement"OR "human label
variation"OR "annotator demographics"OR "label bias"OR "subjective annotation")
```

```
AND ("sentiment analysis"OR "text classification") AND ("bias amplification"OR
"predictive bias"OR "algorithmic bias"OR "machine learning")
```

A execução da versão em inglês, conduzida nas mesmas cinco bases, retornou 96 textos, distribuídos entre ACM Digital Library (83), ACL Anthology (7), Scopus (4) e Web of Science (2). A esses, foram adicionados 66 textos identificados via Google Scholar, livros, materiais discutidos em orientação e rastreamento de referências (*snowballing*), conforme a prática descrita por Wohlin [2014].

Os quantitativos apresentados correspondem aos registros consolidados durante a revisão. Entretanto, os históricos individuais das consultas e das decisões de triagem não foram preservados, o que limita a verificação independente do processo de recuperação e seleção dos estudos.

Apêndice B *Pipeline* de processamento dos logs do PCIbex

Este apêndice documenta o pipeline de processamento aplicado aos logs brutos coletados via plataforma PCIbex Farm, que culmina na construção do *dataset* MQD-1222 utilizado na instanciação empírica da MADA. O objetivo é evidenciar a sequência de etapas de transformação dos dados e garantir a reprodutibilidade conceitual do processo. Os algoritmos centrais são apresentados em pseudocódigo, no mesmo formato do Algoritmo 1 do Capítulo IV.

B.1 Visão geral do pipeline

O pipeline opera em cinco etapas sequenciais:

1. Extração dos logs brutos exportados pela PCIbex Farm.
2. *Parsing* e estruturação dos eventos em registros tabulares de anotação (Algoritmo 2).
3. Segmentação por gênero autodeclarado.
4. Consolidação dos rótulos por voto majoritário estrito (Algoritmo 3).
5. Junção interna entre os dois grupos consolidados, produzindo o *dataset* final.

A volumetria de cada etapa de transformação está consolidada na Tabela IV.2 do Capítulo IV.

B.2 Etapa 1: extração dos *logs* brutos

A PCIbex Farm exporta os *logs* experimentais em formato CSV, com uma linha por evento registrado durante a sessão do participante. Cada arquivo corresponde a um dos dez blocos do experimento e contém eventos de início e fim de cada *trial*, eventos de seleção de rótulo e metadados do participante (identificador pseudonimizado via *hash* MD5 e gênero autodeclarado). Os arquivos brutos são concatenados em um único conjunto de eventos antes do *parsing*.

B.3 Etapa 2: *parsing* e estruturação dos eventos

Os registros brutos são convertidos em anotações tabulares. Para cada anotação, são extraídos: identificador pseudonimizado do participante, gênero autodeclarado, identificador da frase no corpus original, rótulo atribuído e tempo de resposta. O Algoritmo 2 formaliza o procedimento.

A correção do identificador de frase, na linha 7 do algoritmo, é uma etapa crítica. O PCIbex numera os itens sequencialmente dentro de cada bloco do experimento; o *parsing* aplica o deslocamento correspondente para recuperar o identificador original no corpus randomizado de 1.463 frases. Sem essa correção, anotações de blocos distintos seriam erroneamente atribuídas ao mesmo identificador.

Algoritmo 2: *Parsing* dos eventos da PCIbex em registros de anotação

Entrada: Conjunto de eventos brutos E extraídos dos logs CSV

Entrada: Mapeamento B entre número de bloco e deslocamento no corpus

Saída: Tabela de anotações $T = \{(p_i, g_i, f_i, r_i, t_i)\}_{i=1}^{n}$

1 $T \leftarrow \emptyset$;

2 **foreach** *participante* p *identificado em* E **do**

3 $g \leftarrow$ gênero autodeclarado de p; `// evento de seleção de gênero`

4 **foreach** *trial* j *realizado por* p **do**

5 $r \leftarrow$ rótulo selecionado em j; `// positivo, negativo ou neutro`

6 $b \leftarrow$ número do bloco em que j ocorre;

7 $f \leftarrow$ identificador local de j + deslocamento $B[b]$; `// correção para o corpus`

8 $t \leftarrow$ *timestamp* de fim − *timestamp* de início de j;

9 $T \leftarrow T \cup \{(p, g, f, r, t)\}$;

10 **Retorna** T;

B.4 Etapa 3: segmentação por gênero autodeclarado

A tabela de anotações T é particionada em dois subconjuntos distintos T_M e T_F, contendo, respectivamente, as anotações dos participantes que se autodeclararam do gênero masculino e feminino. A segmentação produz dois arquivos intermediários que servem de entrada para a Etapa 4.

B.5 Etapa 4: consolidação por voto majoritário

Para cada frase do corpus, o rótulo majoritário de cada grupo é determinado pela primeira combinação de quatro votos com classe estritamente vencedora, priorizando os registros mais antigos (consistente com o Capítulo IV). O critério adotado é o de maioria estrita: uma frase é considerada com rótulo majoritário válido quando uma classe recebe estritamente mais votos que cada uma das demais. As configurações 4-0-0, 3-1-0 e 2-1-1 satisfazem o critério, pois apresentam uma única classe estritamente mais votada. A configuração de empate (2-2-0) não o satisfaz, e a combinação que a produz é rejeitada; a frase só é descartada no grupo correspondente quando nenhuma combinação de quatro votos é válida, o que ocorre apenas em frases com exatamente quatro votos (Seção IV.1.2).

O descarte é aplicado independentemente em cada grupo. Uma frase descartada por empate no grupo masculino pode ter um rótulo majoritário válido no grupo feminino e vice-versa; a reconciliação entre os dois grupos é feita na Etapa 5.

Algoritmo 3: Consolidação por voto majoritário estrito

Entrada: Subconjunto de anotações T_G de um grupo G

Entrada: Conjunto de classes $C = \{\text{positiva}, \text{negativa}, \text{neutra}\}$

Saída: Dicionário M_G que mapeia identificador de frase para rótulo majoritário válido

```
M_G ← ∅;
foreach frase f presente em T_G do
    V_f ← votos de f em T_G, ordenados por timestamp crescente;
    sel ← NULO;
    foreach combinação Q de quatro votos em V_f (ordem temporal) do
        v ← contagem de votos por classe em Q;
        c* ← arg max_{c∈C} v[c];
        if v[c*] > v[c'] para todo c' ∈ C \ {c*} then
            sel ← c*;                          // primeira quádrupla com pluralidade
            break;
    if sel ≠ NULO then M_G[f] ← sel;
    else frase descartada do grupo;
Retorna M_G;
```

As estatísticas descritivas e inferenciais associadas a esta etapa, incluindo a cobertura de votos por grupo, a taxa de empate condicionada e a análise de sensibilidade entre os dois critérios de seleção, são geradas pelo mesmo *notebook* e registradas em `registro_estatistico_consolidacao.csv`.

B.6 Etapa 5: geração do *dataset* final

O *dataset* MQD-1222 é obtido pela junção interna entre os dois grupos consolidados M_M (grupo masculino) e M_F (grupo feminino). Apenas frases com rótulo majoritário válido em ambos os grupos são preservadas, garantindo paridade estrita na comparação entre fontes anotativas.

Para cada frase preservada, o *dataset* registra: o texto original, o rótulo majoritário do grupo masculino, o rótulo majoritário do grupo feminino, as contagens individuais de votos por classe em cada grupo, a duração média dos julgamentos por grupo e um indicador binário de concordância entre os rótulos majoritários. Esses campos sustentam tanto as análises descritivas reportadas no Capítulo VI quanto análises adicionais sobre fadiga e variação intragrupal, disponíveis para trabalhos futuros.

B.7 Reprodutibilidade

O pipeline descrito neste apêndice utiliza procedimentos determinísticos de transformação dos registros. A randomização inicial do corpus de 1.463 frases, realizada antes do experimento na PCIbex Farm, empregou uma semente fixa de valor 42, permitindo reproduzir a ordenação gerada sob as mesmas condições de implementação. O mesmo valor de semente foi adotado na configuração de validação cruzada descrita na Seção VI.1.5. A aplicação dos Algoritmos 2 e 3 sobre os *logs* brutos, seguida da junção interna descrita na Etapa 5, produz o *dataset* MQD-1222 utilizado em toda a fase empírica desta pesquisa.

O código-fonte completo do pipeline pode ser disponibilizado mediante solicitação ao autor. As informações complementares sobre o ambiente computacional e a lista de *stopwords* utilizadas pelo vetorizador TF-IDF são apresentadas no Apêndice C.

Apêndice C Ambiente computacional e recursos de pré-processamento

Este apêndice registra informações complementares de reprodutibilidade associadas à execução dos notebooks utilizados na geração dos resultados empíricos e sintéticos. As versões das bibliotecas foram obtidas programaticamente no ambiente de execução, a partir dos próprios notebooks, e registradas como metadados auxiliares do experimento. Também é apresentada a lista de *stopwords* utilizada na etapa de representação textual por TF-IDF.

C.1 Ambiente computacional

A Tabela C.1 apresenta as versões dos principais componentes registrados no ambiente Windows utilizado na reconstrução e execução dos notebooks em 17 de outubro de 2026. A execução correspondente no Google Colab utilizou Python 3.13.16. As diferenças de ambiente foram consideradas na auditoria de reprodutibilidade computacional, cujo alcance permanece restrito às verificações efetivamente realizadas.

Tabela C.1: Ambiente computacional utilizado na execução dos notebooks.

Componente	**Versão**
Python	3.13.15
pandas	2.3.0
numpy	2.3.0
matplotlib	3.10.3
scikit-learn	1.7.0
scipy	1.15.3
seaborn	0.13.2
statsmodels	0.14.4
nltk	não instalado
joblib	1.5.2

Os procedimentos de reamostragem *bootstrap* utilizam geradores locais do *NumPy* (`np.random.default_rng`), inicializados a partir das sementes declaradas. Isso elimina a dependência de um estado aleatório global compartilhado entre as reamostragens, favorecendo a reprodução dos resultados sob as mesmas condições de execução, sem dispensar as dependências entre as células dos *notebooks*.

C.2 Stopwords utilizadas no TF-IDF

A representação textual adotada nos experimentos utilizou uma lista de stopwords em português definida diretamente no código e mantida constante nas instanciações empírica e sintética. A lista não deriva de recursos léxicos externos, como o módulo de stopwords do NLTK, que não foi utilizado em nenhuma etapa do pipeline; sua origem no próprio código elimina a dependência de versões de bibliotecas de terceiros para essa configuração. A lista foi extraída programaticamente do ambiente de execução para permitir a rastreabilidade da configuração aplicada pelo vetorizador TF-IDF.

Tabela C.2: *Stopwords* em português utilizadas no pré-processamento textual.

Stopwords
a, agora, ainda, algum, ali, antes, ao, aquela, aquele, aqui, aquilo, as, até, bem, com, como, da, dar, das, de, depois, do, dos, e, ela, elas, ele, eles, em, então, essa, esse, esta, estar, este, eu, fazer, foi, há, ir, isso, isto, já, lhe, lá, mais, mal, mas, me, menos, meu, meus, minha, minhas, muito, na, nada, nas, nem, nenhum, no, nos, nossa, nosso, nunca, não, nós, o, onde, os, ou, para, por, quais, qual, quando, que, saber, se, sem, sempre, ser, seu, seus, sim, sob, sobre, sua, suas, só, também, te, ter, todo, tu, tudo, um, uma, ver, você, vocês, vós, à, às, é

A presença do registro explícito do ambiente computacional e da lista de *stopwords* não altera o desenho experimental, mas torna verificáveis duas decisões de implementação relevantes: as versões das bibliotecas utilizadas e o vocabulário funcional removido durante a construção da representação TF-IDF.

Referências

Abdullah, T. e Ahmet, A. Deep learning in sentiment analysis: Recent architectures. *ACM Computing Surveys*, 55(8):1–37, 2023.

Alm, C. O. Subjective natural language problems: Motivations, applications, characterizations, and implications. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies*, HLT '11, pages 107–112, Portland, Oregon, USA. Association for Computational Linguistics, 2011.

Artstein, R. e Poesio, M. Survey article: Inter-coder agreement for computational linguistics. *Computational linguistics*, 34(4):555–596, 2008.

Azevedo, G. D., Pettine, G., Feder, F., Portugal, G., Mendes, C. O. S., Ribeiro, R. C., Mauro, R. C., Junior, F. P., e Guedes, G. Nat: Towards an emotional agent. In *Proceedings of the 16th Iberian Conference on Information Systems and Technologies (CISTI)*. IEEE Computer Society, 2021.

Basile, V., Fell, M., Fornaciari, T., Hovy, D., Paun, S., Plank, B., Poesio, M., e Uma, A. We need to consider disagreement in evaluation. In *Proceedings of the 1st workshop on benchmarking: past, present and future*, pages 15–21, 2021.

Bender, E. M. e Friedman, B. Data statements for natural language processing: Toward mitigating system bias and enabling better science. *Transactions of the Association for Computational Linguistics*, 6:587–604, 2018.

Biester, L., Sharma, V., Kazemi, A., Deng, N., Wilson, S., e Mihalcea, R. Analyzing the effects of annotator gender across 4 NLP tasks. In *Proceedings of the 1st Workshop on Perspectivist Approaches to NLP @LREC2022*, pages 10–19, Marseille, France. European Language Resources Association, 2022.

Blodgett, S. L., Barocas, S., Daumé III, H., e Wallach, H. Language (technology) is power: A critical survey of "bias" in NLP. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 5454–5476, Online. Association for Computational Linguistics, 2020.

Bowman, S. R., Angeli, G., Potts, C., e Manning, C. D. A large annotated corpus for learning natural language inference. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, Lisbon, Portugal. Association for Computational Linguistics, 2015.

Carneiro, E., Feitosa, A., e Guedes, G. When annotators disagree: A controlled evaluation of gender bias in sentiment analysis using synthetic datasets. In *Proceedings of the XVI Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana (STIL 2025)*, 2025.

Caseli, H. M. e Nunes, M. V., editors. *Processamento de linguagem natural: Conceitos, Técnicas e Aplicações em Português*. BPLN, 4 edition, 2026.

Cawley, G. C. e Talbot, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11:2079–2107, 2010.

Cohen, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960.

Davani, A. M., Díaz, M., e Prabhakaran, V. Dealing with disagreements: Looking beyond the majority vote in subjective annotations. *Transactions of the Association for Computational Linguistics*, 10:92–110, 2022.

Davidson, T., Warmsley, D., Macy, M., e Weber, I. Automated hate speech detection and the problem of offensive language. In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 11, pages 512–515, 2017.

Ding, Y., You, J., Machulla, T.-K., Jacobs, J., Sen, P., e Höllerer, T. Impact of annotator demographics on sentiment dataset labeling. *Proc. ACM Hum.-Comput. Interact.*, 6(CSCW2), 2022.

Efron, B. e Tibshirani, R. J. *An introduction to the bootstrap*. Chapman and Hall/CRC, 1994.

Feinstein, A. R. e Cicchetti, D. V. High agreement but low kappa: I. The problems of two paradoxes. *Journal of Clinical Epidemiology*, 43(6):543–549, 1990.

Feitosa, A., Carneiro, E., e Guedes, G. Beyond systematic bias: Investigating gender differences in portuguese text classification annotation patterns. In *Proceedings of the XX Simpósio Brasileiro de Banco de Dados e Mineração de Conhecimento (KDMiLe 2025)*, 2025.

Feitosa, A., Fasano, A., e Guedes, G. MQD-1222: um dataset de análise de sentimentos em português brasileiro com anotação pareada por gênero. In *Anais do XV Brazilian Workshop on Social Network Analysis and Mining*, pages 269–275, Porto Alegre, RS, Brasil. SBC, 2026.

Firmino, V. P., Lopes, J. N. d. S., e Reis, V. Q. Identificando padrões de sexismo na música brasileira através do processamento de linguagem natural. In *Anais do XI Encontro de Computação de Mato Grosso do Sul (ECMS 2024)*, Campo Grande, Brasil. SBC, 2024.

Fleisig, E., Blodgett, S. L., Klein, D., e Talat, Z. The perspectivist paradigm shift: Assumptions and challenges of capturing human labels. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 2279–2292, 2024.

Freitas, C. Dataset e corpus. In Caseli, H. d. M. e Nunes, M. d. G. V., editors, *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*, chapter 13. BPLN, 4 edition, 2026.

Geiger, R. S., Cope, D., Ip, J., Lotosh, M., Shah, A., Weng, J., e Tang, R. "garbage in, garbage out"revisited: What do machine learning application papers report about human-labeled training data? *Quantitative Science Studies*, 2(3):795–827, 2021.

Geiger, R. S., Yu, K., Yang, Y., Dai, M., Qiu, J., Tang, R., e Huang, J. Garbage in, garbage out? do machine learning application papers in social computing report where human-labeled training data comes from? In *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*, pages 325–336. Association for Computing Machinery, 2020.

Géron, A. *Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. O'Reilly Media, Inc., Sebastopol, CA, 2 edition, 2019.

Geva, M., Goldberg, Y., e Berant, J. Are we modeling the task or the annotator? an investigation of annotator bias in natural language understanding datasets. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, pages 1161–1166, Hong Kong, China. Association for Computational Linguistics, 2019.

Gupta, V., Narayanan Venkit, P., Wilson, S., e Passonneau, R. Sociodemographic bias in language models: A survey and forward path. In Faleńska, A., Basta, C., Costa-jussà, M., Goldfarb-Tarrant, S., e Nozza, D., editors, *Proceedings of the 5th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, pages 295–322, Bangkok, Thailand. Association for Computational Linguistics, 2024.

Hastie, T., Tibshirani, R., e Friedman, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, NY, 2 edition, 2009.

Havens, L., Terras, M., Bach, B., e Alex, B. Uncertainty and inclusivity in gender bias annotation: An annotation taxonomy and annotated datasets of british english text. In *Proceedings of the 4th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, pages 140–152, Seattle, Washington. Association for Computational Linguistics, 2022.

Hovy, D. e Prabhumoye, S. Five sources of bias in natural language processing. *Language and Linguistics Compass*, 15(8):e12432, 2021.

Ivey, J., Gauch, S., e Jurgens, D. Nutmeg: Separating signal from noise in annotator disagreement. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 2874–2887, Suzhou, China. Association for Computational Linguistics, 2025.

Izbicki, R. e Santos, T. M. d. *Aprendizado de máquina: uma abordagem estatística*. Rafael Izbicki, São Carlos, SP, 1 edition, 2020.

Jentzsch, S. e Turan, C. Gender bias in bert - measuring and analysing biases through sentiment rating in a realistic downstream classification task. In *Proceedings of the 4th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, page 184–199, Seattle, Washington. Association for Computational Linguistics, 2022.

Jiang, A., Vitsakis, N., Dinkar, T., Abercrombie, G., e Konstas, I. Re-examining sexism and misogyny classification with annotator attitudes. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 15103–15125, Miami, Florida, USA. Association for Computational Linguistics, 2024.

Joachims, T. Text categorization with support vector machines: Learning with many relevant features. In *European Conference on Machine Learning (ECML 1998)*, pages 137–142, Berlin Heidelberg, Germany. Springer, 1998.

Karam, H., Cai, M., Palliyil, V., Phatthanachaisuksiri, L., Suhre, N., e Kaßens-Noor, E. Mapping AI's role in supporting or hindering the achievement of SDGs: A systematic review for AI in government. *Open Research Europe*, 5:101, 2025.

Kenyon-Dean, K., Ahmed, E., et al. Sentiment analysis: It's complicated! In *Proceedings of the 2018 Conference of the NAACL: HLT*, pages 1886–1895, New Orleans, Louisiana. Association for Computational Linguistics, 2018.

Kiritchenko, S. e Mohammad, S. Examining gender and race bias in two hundred sentiment analysis systems. In *Proceedings of the Seventh Joint Conference on Lexical and Computational Semantics (*SEM 2018)*, pages 43–53, New Orleans, Louisiana. Association for Computational Linguistics, 2018.

Kirk, H. R., Yin, W., Vidgen, B., e Röttger, P. Semeval-2023 task 10: Explainable detection of online sexism. In *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)*, pages 2193–2210, Toronto, Canada. Association for Computational Linguistics, 2023.

Kumar, S. et al. Exploring impact of age and gender on sentiment analysis using machine learning. *Electronics*, 9(2):374, 2020.

Kuwatly, H. A., Wich, M., e Groh, G. Identifying and measuring annotator bias based on annotators' demographic characteristics. In *Proceedings of the Fourth Workshop on Online Abuse and Harms*, page 184–190, Online. Association for Computational Linguistics, 2020.

Landis, J. R. e Koch, G. G. The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174, 1977.

Lim, S. S., Udomcharoenchaikit, C., Limkonchotiwat, P., Chuangsuwanich, E., e Nutanong, S. Identifying and mitigating annotation bias in natural language understanding using causal mediation analysis. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 11548–11563, 2024.

Minatel, D. et al. Data stratification analysis on the propagation of discriminatory effects in binary classification. In *Anais do 11º Symposium on Knowledge Discovery, Mining and Learning (KDMiLe)*, pages 73–80, Belo Horizonte, MG. Sociedade Brasileira de Computação, 2023.

Mozetič, I., Grčar, M., e Smailović, J. Multilingual twitter sentiment classification: The role of human annotators. *PLOS ONE*, 11(5):e0155036, 2016.

Munir, S., Mah, B., Kalsi, K., Kapania, S., Posada, J., Law, E., Wang, D., e Ahmed, S. I. The consensus trap: Dissecting subjectivity and the "ground truth" illusion in data annotation. In *The 2026 ACM Conference on Fairness, Accountability, and Transparency*, 2026.

Orlikowski, M., Röttger, P., Cimiano, P., e Hovy, D. The ecological fallacy in annotation: Modeling human label variation goes beyond sociodemographics. In Rogers, A., Boyd-Graber, J., e Okazaki, N., editors, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 1017–1029, Toronto, Canada. Association for Computational Linguistics, 2023.

Page, M. J., McKenzie, J. E., Bossuyt, P. M., et al. The prisma 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, 372:n71, 2021.

Pandya, M., Moosavi, N., e Maynard, D. Exploring the influence of label aggregation on minority voices: Implications for dataset bias and model training. *arXiv preprint arXiv:2412.04025*, 2024.

Paullada, A. et al. Data and its (dis)contents: A survey of dataset development and use in machine learning research. *Patterns*, 2(11):100336, 2021.

Pavlick, E. e Kwiatkowski, T. Inherent disagreements in human textual inferences. *Transactions of the Association for Computational Linguistics*, 7:677–694, 2019.

Pei, J. e Jurgens, D. When do annotator demographics matter? measuring the influence of annotator demographics with the popquorn dataset. In *Proceedings of the 17th linguistic annotation workshop (LAW-XVII)*, pages 252–265, 2023.

Plank, B. The "problem" of human label variation: On ground truth in data, modeling and evaluation. In *Proceedings of the 2022 conference on empirical methods in natural language processing*, pages 10671–10682, 2022.

Prabhakaran, V., Davani, A. M., e Diaz, M. On releasing annotator-level labels and information in datasets. In *Proceedings of the Joint 15th Linguistic Annotation Workshop (LAW) and 3rd Designing Meaning Representations (DMR) Workshop*, pages 133–138, Punta Cana, Dominican Republic, 2021.

Prabhakaran, V., Homan, C. M., Aroyo, L., Mostafazadeh Davani, A., Parrish, A., Taylor, A., Diaz, M., Wang, D., e Serapio-García, G. GRASP: A disagreement analysis framework to assess group associations in perspectives. In Duh, K., Gomez, H., e Bethard, S., editors, *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 3473–3492, Mexico City, Mexico. Association for Computational Linguistics, 2024.

Raji, I. D., Bender, E. M., et al. Ai and the everything in the whole wide world benchmark. In *Proceedings of the NeurIPS 2021 Datasets and Benchmarks Track*, pages 1–10. NeurIPS, 2021.

Rajpurkar, P., Zhang, J., Lopyrev, K., e Liang, P. SQuAD: 100,000+ questions for machine comprehension of text. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 2383–2392, Austin, Texas. Association for Computational Linguistics, 2016.

Ross, B., Rist, M., Carbonell, G., Cabrera, B., Kurowsky, N., e Wojatzki, M. Measuring the reliability of hate speech annotations: The case of the european refugee crisis. *CoRR*, abs/1701.08118, 2017.

Röttger, P., Vidgen, B., Hovy, D., e Pierrehumbert, J. Two contrasting data annotation paradigms for subjective nlp tasks. In *Proceedings of the 2022 conference of the North American chapter of the association for computational linguistics: human language technologies*, pages 175–190, 2022.

Shah, D. S., Schwartz, H. A., e Hovy, D. Predictive biases in natural language processing models: A conceptual framework and overview. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 5248–5264. Association for Computational Linguistics, 2020.

Silva, M. O. e Moro, M. M. Nlp pipeline for gender bias detection in portuguese literature. In *Anais do Seminário Integrado de Software e Hardware (SEMISH)*, pages 1–10, Brasília, Brazil. Sociedade Brasileira de Computação, 2024.

Sobhani, N. e Delany, S. J. Towards fairer NLP models: Handling gender bias in classification tasks. In *Proceedings of the 5th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, pages 167–178. Association for Computational Linguistics, 2024.

Socher, R., Perelygin, A., Wu, J., Chuang, J., Manning, C. D., Ng, A., e Potts, C. Recursive deep models for semantic compositionality over a sentiment treebank. In *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing*, pages 1631–1642, Seattle, Washington, USA. Association for Computational Linguistics, 2013.

Stańczak, K. e Augenstein, I. A survey on gender bias in natural language processing. *arXiv preprint arXiv:2112.14168*, 2021.

Taso, F. T. S., Reis, V. Q., e Martinez, F. V. Discriminação algorítmica de gênero: Estudo de caso e análise no contexto brasileiro. In *Anais do IV Workshop sobre as Implicações da Computação na Sociedade (WICS 2023)*, pages 229–240, Porto Alegre, Brasil. SBC, 2023.

Thelwall, M. Gender bias in machine learning for sentiment analysis. *Online Information Review*, 42(3):343–354, 2018.

Toker, I., Sarne, D., e Schler, J. Intelligent calibration for bias reduction in sentiment corpora annotation process. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38:10172–10179, 2024.

Uma, A. N., Fornaciari, T., Hovy, D., Paun, S., Plank, B., e Poesio, M. Learning from disagreement: A survey. *Journal of Artificial Intelligence Research*, 72:1385–1470, 2021.

Wan, R., Kim, J., e Kang, D. Everyone's voice matters: Quantifying annotation disagreement using demographic information. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(12):14523–14530, 2023.

Waseem, Z. e Hovy, D. Hateful symbols or hateful people? predictive features for hate speech detection on twitter. In *Proceedings of the NAACL Student Research Workshop*, pages 88–93, San Diego, California. Association for Computational Linguistics, 2016.

Williams, A., Nangia, N., e Bowman, S. R. A broad-coverage challenge corpus for sentence understanding through inference. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 1112–1122, New Orleans, Louisiana. Association for Computational Linguistics, 2018.

Wohlin, C. Guidelines for snowballing in systematic literature studies and a replication in software engineering. In *Proceedings of the 18th International Conference on Evaluation and Assessment in Software Engineering (EASE 2014)*, pages 1–10. ACM, 2014.

Xu, Y., Derricks, V., Earl, A., e Jurgens, D. Modeling annotator disagreement with demographic-aware experts and synthetic perspectives. In Liakata, M., Moreira, V. P., Zhang, J., e Jurgens, D., editors, *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 41260–41294, San Diego, California, United States. Association for Computational Linguistics, 2026.

Zhao, J., Wang, T., Yatskar, M., Ordonez, V., e Chang, K.-W. Men also like shopping: Reducing gender bias amplification using corpus-level constraints. In *Proceedings of the 2017 conference on empirical methods in natural language processing*, pages 2979–2989, 2017.